

bs4 ds

Demoren

September 2025

№1

Распишите итерационную процедуру ЕМ-алгоритма и значение ELBO для метода Дэвида-Скина.

Напомним, функция неполного правдоподобия в данной модели имеет вид

$$p_{\pi, \rho}(N, Y) = \prod_{i \in I} \prod_{k \in K} \left(\overbrace{\left(\underbrace{\text{вер-ть выбора}}_{\text{этого класса}} \underbrace{\left(\prod_{u \in U} \prod_{\ell \in K} \underbrace{\left(\overbrace{n_{i\ell}^u \text{ раз поставлена}}_{\text{метка } \ell} \underbrace{(\pi_{k\ell}^u)^{n_{i\ell}^u}}_{\text{фиксируем пользователя } u} \right)}_{\text{фиксируем для него истинный класс } k} \right)}_{\text{рассматриваем объект } i} \right)}^{Y_{ik} \text{ выбор класса}} \right) \rightarrow \max_{\pi, \rho}$$

где

- * $N = n_{i\ell}^u$ –; наблюдаемые данные, $n_{i\ell}^u$ –; количество раз, при которых разметчик $u \in U$ поставил класс $\ell \in K$ объекту $i \in I$;
- * $Y_{ik} = I\{\text{объект } i \text{ класса } k\}$ –; латентные величины;
- * $\pi_{k\ell}^u$ –; вероятность того, что разметчик u поставил класс ℓ вместо правильного класса k , параметр модели;
- * ρ_k –; вероятность класса k , параметр модели.

□

Е-шаг.

$$q(y) = p_{\alpha\beta\pi}(y|x) \propto p_{\alpha\beta\pi}(y, x) = \prod_{i=1}^n p_{\alpha\beta\pi}(y_i, x_i)$$

Тогда распределение на Y будет иметь вид $q(y) = \prod_{i=1}^n q_i(y_i)$, где:

$$q_i(y_i) \propto \prod_{k \in K} \left(\rho_k \prod_{u \in U} \prod_{\ell \in K} (\pi_{k\ell}^u)^{n_{i\ell}^u} \right)^{Y_{ik}}$$

Обозначим

$$\gamma_{ik} = \frac{\rho_k \prod_{u \in U} \prod_{\ell \in K} (\pi_{k\ell}^u)^{n_{i\ell}^u}}{\sum_{k \in K} \rho_k \prod_{u \in U} \prod_{\ell \in K} (\pi_{k\ell}^u)^{n_{i\ell}^u}}$$

ELBO

Запишем ELBO:

$$\begin{aligned} \mathcal{L}(\rho, \pi, q) = & \sum_{i \in I} \sum_{k \in K} \gamma_{ik} \left[\log \rho_k + \sum_{u \in U} \sum_{\ell \in K} n_{i\ell}^u \log \pi_{k\ell}^u \right] \\ & - \sum_{i \in I} \sum_{k \in K} \gamma_{ik} \log \gamma_{ik}. \end{aligned}$$

М-шаг

Для оптимизации ρ имеем систему:

$$\begin{cases} \sum_{i \in I} \sum_{k \in K} \gamma_{ik} \log \rho_k \rightarrow \max_{\rho} \\ \sum_{k \in K} \rho_k = 1 \\ \rho_k \geq 0 \end{cases}$$

Как видим, это просто обновление веса смеси, его мы уже получили на прошлых лекциях. Т.о. $\rho_k = \frac{1}{|I|} \sum_{i \in I} \gamma_{ik}$

Для оптимизации по π^u опять имеем систему:

$$\begin{cases} \sum_{i \in I} \sum_{k \in K} \sum_{\ell \in K} \gamma_{ik} n_{i\ell}^u \log \pi_{k\ell}^u \rightarrow \max_{\pi} \\ \sum_{\ell \in K} \pi_{k\ell}^u = 1 \end{cases} \quad \forall k \in K$$

Запишем лагранжиан для этой системы:

$$J(\pi, \lambda) = \sum_{i \in I} \sum_{k \in K} \sum_{\ell \in K} \gamma_{ik} n_{i\ell}^u \log \pi_{k\ell}^u + \sum_{k \in K} \lambda_k \left(\sum_{\ell \in K} \pi_{k\ell}^u - 1 \right)$$

Дифференцирую по π_{kl}^u получим:

$$\frac{\partial J}{\partial \pi_{kl}^u} = \sum_{i \in I} \gamma_{ik} n_{i\ell}^u \frac{1}{\pi_{kl}^u} + \lambda_k = 0$$

Откуда:

$$\pi_{kl}^u = - \frac{\sum_{i \in I} \gamma_{ik} n_{i\ell}^u}{\lambda_k}$$

Для того чтобы найти λ_k воспользуемся вторым уравнением системы:

$$\sum_{\ell \in K} - \frac{\sum_{i \in I} \gamma_{ik} n_{i\ell}^u}{\lambda_k} = 1 \Rightarrow \lambda_k = - \sum_{\ell \in K} \sum_{i \in I} \gamma_{ik} n_{i\ell}^u$$

В итоге

$$\pi_{kl}^u = \frac{\sum_{i \in I} \gamma_{ik} n_{i\ell}^u}{\sum_{\ell \in K} \sum_{i \in I} \gamma_{ik} n_{i\ell}^u}$$

Итерационная процедура

1. **Инициализация:** задать начальные значения параметров ρ_k и $\pi_{k\ell}^u$.

2. **Е-шаг:** для каждого объекта $i \in I$ вычислить апостериорные вероятности классов:

$$\gamma_{ik} = \frac{\rho_k \prod_{u \in U} \prod_{\ell \in K} (\pi_{k\ell}^u)^{n_{i\ell}^u}}{\sum_{k' \in K} \rho_{k'} \prod_{u \in U} \prod_{\ell \in K} (\pi_{k'\ell}^u)^{n_{i\ell}^u}}.$$

3. **М-шаг:** обновить параметры:

$$\rho_k = \frac{1}{|I|} \sum_{i \in I} \gamma_{ik}, \quad \pi_{k\ell}^u = \frac{\sum_{i \in I} \gamma_{ik} n_{i\ell}^u}{\sum_{i \in I} \gamma_{ik} \sum_{\ell' \in K} n_{i\ell'}^u}.$$

4. **Проверка сходимости:** вычислить ELBO:

$$\mathcal{L}(\rho, \pi, q) = \sum_{i \in I} \sum_{k \in K} \gamma_{ik} \left[\log \rho_k + \sum_{u \in U} \sum_{\ell \in K} n_{i\ell}^u \log \pi_{k\ell}^u \right] - \sum_{i \in I} \sum_{k \in K} \gamma_{ik} \log \gamma_{ik},$$

и остановиться при достижении критерия сходимости.

5. **Повтор:** вернуться к шагу 2, пока ELBO не стабилизируется.

■

№4

Пусть выборка $X_1, \dots, X_n$ имеет распределение смеси с неизвестным количеством компонент. Данные поступают последовательно, причем постепенно могут появляться новые кластеры, а старые ; исчезать. Это означает, что мы не можем один раз по всей выборке определить оптимальное количество кластеров на основе какого-либо функционала.

Такая задача может иметь смысл, например, для новостных агрегаторов, блог-платформ, социальных сетей. Мы можем получить векторное представление объектов (тексты статей, видеоролики), и далее для них решать задачу кластеризации. Но периодически могут появляться новые группы новостей, новые тренды, которые хотелось бы уметь автоматически выделять в отдельный кластер. В то же время, кластеры для устаревших новостей или трендов хотелось бы исключать. Возникает потребность в модели кластеризации, в которой можно автоматически добавлять новые кластеры, периодически обновляться на новых данных, а также "на лету" добавлять новые кластеры и удалять старые.

Определим модель следующим образом

- * $\theta_1, \theta_2, \dots \sim G_0$; параметры каждого кластера, имеющие некоторое распределение G_0 , являющееся базовым распределением в процессе stick-breaking;
- * $V_1, V_2, \dots \sim \text{Beta}(1, \alpha)$; параметры доли отламываемой палки в процессе stick-breaking;
- * $\pi_k = V_k \prod_{j=1}^{k-1} (1 - V_j)$; параметры вероятностей кластеров;
- * $Y_1, \dots, Y_n$; номера кластеров в виде one-hot векторов, то есть $Y_i = (Y_{ik})_{k=1}^{\infty}$, где $Y_{ik} \in \{0, 1\}$ и $P(Y_{ik} = 1 \mid \pi) = \pi_k$;
- * $X_1, \dots, X_n$; выборка, в которой условное распределение $(X_i \mid Y_{ik} = 1, \theta = t)$ описывается плотностью $p_{t_k}(x)$.

Совместное распределение всех величин в такой модели имеет вид

$$p(x, y, v, t) = \overbrace{\left[\prod_{k=1}^{\infty} g_0(t_k) \rho_{\alpha}(v_k) \right]}^{\text{выбор параметров кластеров}} \prod_{i=1}^n \prod_{k=1}^{\infty} \overbrace{\left[v_k \prod_{j=1}^{k-1} (1 - v_j) \cdot p_{t_k}(x_i) \right]}^{\text{вер-ть кластера}}^{y_{ik}},$$

где g_0 – плотность распределения G_0 , а ρ_{α} – плотность распределения $Beta(1, \alpha)$. Формула отличается от формулы совместного распределения простой смеси тем, что в данном случае параметры кластера случайны, и самих кластеров бесконечно.

Рассмотрим вариационное семейство, в котором наборы $(\theta_k)_{k=1}^{\infty}, (V_k)_{k=1}^{\infty}, (Y_i)_{i=1}^n$ независимы, причем распределение каждого из этих наборов произвольное.

1

Выполните шаг для обновления распределения $(Y_i)_{i=1}^n$. На основе полученного распределения предложите условия, при которых

* можно исключить все кластеры с номерами больше K ,

* можно исключить некоторые кластеры с номерами меньше K .

□

Проще говоря, требуется выполнить Е-шаг.

$$q(y) = p_{V\theta}(y|x) \propto p_{V\theta}(y, x) = \prod_{i=1}^n p_{V\theta}(x_i, y_i)$$

Тогда $q(y) = \prod_{i=1}^n q_i(y_i)$, где (учтем что первая скобка для всех одинаковая)

$$\begin{aligned} q_i(y_i) &\propto \left[\prod_{k=1}^{\infty} g_0(t_k) \rho_{\alpha}(v_k) \right] \prod_{k=1}^{\infty} \left[\left(v_k \prod_{j=1}^{k-1} (1 - v_j) \right) \cdot p_{t_k}(x_i) \right]^{y_{ik}} \\ &\propto \prod_{k=1}^{\infty} \left[\left(v_k \prod_{j=1}^{k-1} (1 - v_j) \right) \cdot p_{t_k}(x_i) \right]^{y_{ik}} \end{aligned}$$

В итоге, учитывая нормировку:

$$q_i(y_{ik}) = \gamma_{ik} = \frac{\pi_k \cdot p_{t_k}(x_i)}{\sum_{l=1}^{\infty} \pi_l \cdot p_{t_l}(x_i)}$$

Если суммарная вероятность кластеров с номерами больше K достаточно мала, то их можно исключить, как мы делали в третьем номере например.

Аналогично можно поступить с кластерами с номерами меньше K , то есть вероятность того, что объект ему принадлежит должна быть крайне низкой.

■

2

Выполните шаг для обновления распределения $(V_k)_{k=1}^\infty$. Проинтерпретируйте параметры полученного распределения. На основе полученного распределения предложите условие, при котором стоит добавить новые кластеры.

□

В следующих 2 пунктах от нас требуется выписать М-шаг.

Для начала выпишем ELBO:

$$\begin{aligned} \mathcal{L}(\theta, V, q) = & \sum_{k=1}^{\infty} \log(g_0(t_k)) + \sum_{k=1}^{\infty} \log(\rho_\alpha(v_k)) + \sum_{i=1}^n \sum_{s=1}^{\infty} \gamma_{is} \log(v_s) \\ & + \sum_{i=1}^n \sum_{s=1}^{\infty} \sum_{j=1}^{s-1} \gamma_{is} \log(1 - v_j) + \sum_{i=1}^n \sum_{k=1}^{\infty} \gamma_{ik} \log(p_{t_k}(x_i)) - \sum_{i=1}^n \sum_{k=1}^{\infty} \gamma_{ik} \log(\gamma_{ik}) \end{aligned}$$

Вспомним, что $\rho_\alpha(x) = \frac{(1-x)^{\alpha-1}}{B(1, \alpha)}$. Тогда $\rho'_\alpha(x) = -\frac{(\alpha-1) \cdot (1-x)^{\alpha-2}}{B(1, \alpha)} = -\frac{(\alpha-1)\rho_\alpha(x)}{1-x}$

Теперь продифференцируем по v_k :

$$\begin{aligned} \frac{\partial \mathcal{L}}{\partial v_k} = & \frac{\rho'_\alpha(v_k)}{\rho_\alpha(v_k)} - \sum_{i=1}^n \sum_{s=k+1}^{\infty} \gamma_{is} \frac{1}{1 - v_k} + \frac{1}{v_k} \sum_{i=1}^n \gamma_{ik} \\ = & -\frac{\alpha-1}{1-v_k} + \frac{1}{v_k} \sum_{i=1}^n \gamma_{ik} - \frac{1}{1-v_k} \sum_{i=1}^n \sum_{s=k+1}^{\infty} \gamma_{is} = 0 \end{aligned}$$

Откуда:

$$v_k = \frac{\sum_{i=1}^n \gamma_{ik}}{\sum_{i=1}^n \gamma_{ik} + \sum_{i=1}^n \sum_{s=k+1}^{\infty} \gamma_{is} + \alpha - 1}$$

Первое слагаемое в знаменателе можно интерпретировать, как среднее количество точек попавших в кластер k . Второе как среднюю "массу" оставшихся доступных точек, причем если она велика то следует добавить еще кластеров.

■

3

Выпишите шаг для обновления распределения $(\theta_k)_{k=1}^\infty$

* в общем случае формулой в виде пропорциональности;

* в случае если $p_{t_k}(x)$ – плотность распределения $\mathcal{N}(a_k, \Sigma_k^2)$ и G_0 – неинформативное, а в вариационном семестве для $(\theta_k)_{k=1}^\infty$ рассматривается вырожденное распределение (т.е. нужно найти моду, см. сведение VI к EM).

Подсказка. Достаточно свести второй случай к уже решенной ранее задаче и выписать ответ.

□

Общий случай

Заметим, что θ_k содежится только в g_0 и p . Учитывая это, обновление в общем случае имеет вид:

$$q(\theta_k) \propto g_0(\theta_k) \prod_{i=1}^n p_{\theta_k}(x_i)^{\gamma_{ik}}$$

Частный случай.

В таком случае:

$$\begin{aligned}\log(q(\theta_k)) &\propto \sum_{i=1}^n \sum_{k=1}^{\infty} \gamma_{ik} \log(p_{t_k}(x_i)) \\ &= - \sum_{i=1}^n \sum_{k=1}^{\infty} \gamma_{ik} \left(\log(\det(\Sigma_k^2)) + \frac{1}{2}(x_i - a_k)^T (\Sigma_k^2)^{-1} (x_i - a_k) \right)\end{aligned}$$

Мы уже решали такую задачу, когда применяли ЕМ-алгоритм для гауссовской смеси, так что можно сразу выписать результат полученный на лекции:

$$\boxed{a_k = \frac{\sum_{i=1}^n \gamma_{ik} x_i}{\sum_{i=1}^n \gamma_{ik}} \quad \Sigma_k^2 = \frac{\sum_{i=1}^n \gamma_{ik} (x_i - a_k)(x_i - a_k)^T}{\sum_{i=1}^n \gamma_{ik}}}$$

■

№4

Распишите ELBO.

□

$$\begin{aligned}\mathcal{L}(q) &= \sum_{k=1}^{\infty} \mathbb{E}_{q(\theta_k)} [\log g_0(\theta_k)] + \sum_{k=1}^{\infty} \mathbb{E}_{q(v_k)} [\log \rho_{\alpha}(v_k)] \\ &\quad + \sum_{i=1}^n \sum_{k=1}^{\infty} \gamma_{ik} \left(\mathbb{E}_{q(v)} [\log v_k] + \sum_{j=1}^{k-1} \mathbb{E}_{q(v)} [\log(1 - v_j)] + \mathbb{E}_{q(\theta_k)} [\log p_{\theta_k}(x_i)] \right) \\ &\quad - \sum_{i=1}^n \sum_{k=1}^{\infty} \gamma_{ik} \log \gamma_{ik} - \sum_{k=1}^{\infty} \mathbb{E}_{q(v_k)} [\log q(v_k)] - \sum_{k=1}^{\infty} \mathbb{E}_{q(\theta_k)} [\log q(\theta_k)].\end{aligned}$$

■

№5

Вычислите все математические ожидания по вариационным распределениям $(V_k)_{k=1}^{\infty}, (Y_i)_{i=1}^n$.

□

$$\boxed{\mathbb{E}_{q(y)}(y_{ik}) = \gamma_{ik}}$$

Для нахождения производной по v , сначала заметим, что:

$$\frac{\partial B(a, b)}{\partial a} = \frac{\partial}{\partial a} \int_0^1 x^{a-1} (1-x)^{b-1} dx = \int_0^1 x^{a-1} (1-x)^{b-1} \log(x) dx = I(a, b)$$

То есть имеем

$$\frac{I(a, b)}{B(a, b)} = \frac{\partial \log B(a, b)}{\partial a}$$

А так как:

$$\frac{\partial \log B(a, b)}{\partial a} = \psi(a) - \psi(a + b)$$

То подставляя $a = a_k, b = b_k$, получаем:

$$\mathbb{E}_{q(v)}(\log(v_k)) = \psi(a_k) - \psi(a_k + b_k), \quad a_k = 1 + \sum_{i=1}^n \gamma_{ik}, \quad b_k = \alpha + \sum_{i=1}^n \sum_{s=k+1}^{\infty} \gamma_{is}$$

Аналогично можно получить, что:

$$\mathbb{E}_{q(v)}(\log(1 - v_k)) = \psi(b_k) - \psi(a_k + b_k), \quad a_k = 1 + \sum_{i=1}^n \gamma_{ik}, \quad b_k = \alpha + \sum_{i=1}^n \sum_{s=k+1}^{\infty} \gamma_{is}$$

$$\mathbb{E}_{q(v_k)} \log(q(v_k)) = (a_k - 1) \mathbb{E}_{q(v_k)}(\log(v_k)) + (b_k - 1) \mathbb{E}_{q(v)}(\log(1 - v_k)) - \log(B(a_k, b_k))$$

$$\mathbb{E}_{q(v_k)} \log \rho_{\alpha}(v_k) = (\alpha - 1) \mathbb{E}_{q(v_k)}[\log(1 - v_k)] - \log B(1, \alpha).$$

■