

Конспект находится в разработке, могут присутствовать опечатки и неточности

Математическая статистика, DS-поток

I Статистики, оценки и их свойства	4
I - 1 Метод Монте-Карло	4
I - 2 Повторение теории вероятностей	6
I - 2.1 Случайные величины и их свойства	6
I - 2.2 Сходимости	9
I - 3 Статистики и оценки	11
I - 3.1 Вероятностно-статистическая модель	11
I - 3.2 Свойства оценок	12
I - 3.3 Наследование свойств	14
I - 3.4 Доверительные интервалы	15
I - 4 Статистики и оценки. Семинар	17
I - 4.1 Оценки и сходимости	17
I - 4.2 Метод моментов	21
I - 5 Статистики и оценки. Доказательства теорем	22
I - 5.1 Линейная регрессия	22
I - 5.2 Наследование свойств. Продолжение	23
I - 5.3 Доверительные интервалы	26
I - 5.4 Метод центральной функции	26
I - 5.5 Точные доверительный интервалы в нормальной модели	27
I - 6 Доверительные интервалы. Семинар	30
I - 6.1 Доверительные интервалы и области	30
I - 6.2 Метод центральных функций	31
I - 6.3 Доверительный интервал Вильсона	31
I - 7 Метод максимального правдоподобия	33
I - 7.1 Метод максимального правдоподобия	33
I - 7.2 Задача про γ -котиков	36
I - 7.3 Выборочные квантили	37
I - 7.4 Достаточные статистики	38
I - 8 Метод максимального правдоподобия. Семинар	40
I - 8.1 Метод максимального правдоподобия	40
I - 8.2 Оценки для распределения Коши	43
I - 9 Сравнение оценок	44
I - 9.1 Экспоненциальное семейство распределений	44
I - 9.2 Сравнение оценок	47
I - 10 Сравнение оценок. Семинар	51
I - 10.1 Равномерный подход	52
I - 10.2 Байесовский подход	53

I - 10.3 Минимаксный подход	53
I - 10.4 Оценки в схеме Бернулли	54
I - 10.5 Асимптотический подход	55
I - 11 Робастные оценки	56
I - 11.1 Приближенный поиска ОМП. Метод Ньютона	56
I - 11.2 Робастность и симметричность	58
I - 11.3 Робастные оценки	58
I - 11.4 Эмпирическое распределение	61
I - 11.5 Метод подстановки	62
I - 12 Достаточные статистики и робастные оценки. Семинар	63
I - 12.1 Достаточные статистики	63
I - 12.2 Робастные оценки	64
I - 12.3 Приближенный поиск ОМП	65
I - 13 Бутстреп. Семинар	66
I - 13.1 Эмпирическое распределение. Напоминание	66
I - 13.2 Бутстреп	67
II Проверка статистических гипотез	69
II - 1 Гипотезы и критерии	69
II - 1.1 Гипотезы в непараметрическом и параметрическом случаях	69
II - 1.2 Проверка гипотез	69
II - 1.3 Альтернативная гипотеза	71
II - 1.4 Критерий Вальда	73
II - 2 Гипотезы и критерии. Семинар	75
II - 2.1 Критерий Вальда	76
II - 2.2 Критерий отношения правдоподобия	77
II - 3 Гипотезы и критерии. Повторение	81
II - 3.1 Гипотезы и критерии	81
II - 3.2 Доверительные интервалы	82
II - 4 Проверка гипотез. Семинар	82
II - 4.1 Оценка вероятности ошибки I рода	82
II - 4.2 Критерий χ -квадрат	84
II - 4.3 Обобщенный критерий χ -квадрат	86
II - 4.4 p-value, разбор ДЗ	87
II - 5 МПГ. Семинар	89
II - 5.1 Обобщенная ошибка первого рода	89
II - 5.2 Методы, контролирующие FWER	90
II - 6 Гауссовская линейная модель. Статистические свойства линейной регрессии .	92
II - 6.1 Свойства гауссовских случайных векторов	92
II - 6.2 Гауссовская линейная модель	93
II - 6.3 Доверительные интервалы и критерии для параметров GLM	93
II - 7 Гауссовская линейная модель. Семинар	96
II - 7.1 Гауссовская линейная модель	96
II - 7.2 Общий случай линейных гипотез	97
II - 8 Подсчет информации Фишера для частных случаев GLM	100
II - 8.1 Логистическая регрессия	100
II - 8.2 Пуассоновская регрессия	101
II - 8.3 Линейная регрессия	101
II - 9 Калибровка. Семинар	101

П - 9.1 Калибровка. Определение	102
П - 9.2 Калибровочная кривая	102
П - 9.3 Метрики калибровки	105
П - 9.4 Методы калибровки	106
П - 10 Информация Фишера	107
П - 11 Энтропия и дивергенция	109
П - 11.1 1. Дискретный случай	109
П - 11.2 2. Общий случай	110
П - 12 Натуральный градиент	111
П - 13 Свойства ОМП. Семинар	113
П - 14 Информация Фишера. Семинар	116
П - 14.1 Многомерная информация Фишера	116
П - 14.2 Информация Фишера для обобщенных линейных моделей	117
П - 15 Доказательства теорем	118
П - 15.1 Критерий χ^2	118
П - 15.2 Лемма Неймана-Пирсона	119

I Статистики, оценки и их свойства

I - 1 Метод Монте-Карло

Рассмотрим задачу минимизации функции с использованием градиентного спуска.

Задача:

$$\frac{1}{n} \sum_{i=1}^n f_i(x) \rightarrow \min_x$$

Задача очень важная, потому что именно это мы и делаем в ML, когда минимизируем ошибку:

- MSE: $\frac{1}{n} \sum_{i=1}^n (y_i - f(x_i))^2$
- LogLoss: $-\frac{1}{n} \sum_{i=1}^n y_i \ln(f(x_i)) + (1 - y_i) \ln(1 - f(x_i))$

Решается с помощью градиентного спуска:

$$\text{GD} : x_{t+1} = x_t - \lambda \cdot \frac{1}{n} \sum_{i=1}^n f'_i(x)$$

$$\text{SGD} : x_{t+1} = x_t - \frac{\lambda}{k} \cdot \frac{1}{n} \sum_{j=1}^k f'_{i_j}(x)$$

В SGD мы убрали подсчет большой суммы при помощи семплирования, в этом и заключается идея метода Монте-Карло

GD \rightarrow SGD - метод Монте-Карло

Рассмотрим теперь другую задачу

Задача:

Нужно оценить $\theta = \mathbb{E}f(X)$, $X \sim P$

$$\hat{\theta} = \frac{1}{k} \sum_{j=1}^k f(X_j)$$

Причем, по УЗБЧ есть сходимости почти наверное: $\hat{\theta} \xrightarrow[k \rightarrow \infty]{\text{п.н.}} \theta$

При помощи семплирования избавились от подсчета интеграла

Рассмотрим серию примеров:

Примеры:

1) $X \sim U\{1, \dots, n\}$

$$f(i) = f_i$$

$$\theta(x) = \mathbb{E}f(X)(x) = \frac{1}{n} \sum_{i=1}^n f_i(x)$$

$$\hat{\theta} = \frac{1}{k} \sum_{i=1}^k f_{i_j}(x), i_1, \dots, i_k \sim U\{1, \dots, n\}$$

2) $f(\theta) = \mathbb{E}g(X, \theta)$, где распределение X не зависит от θ

$$f(\theta) = \int_{\mathbb{R}} g(x, \theta) p(x) dx$$

$$f'(\theta) = \int_{\mathbb{R}} \frac{\partial g}{\partial \theta}(x, \theta) p(x) dx = \mathbb{E} \frac{\partial g}{\partial \theta}(x, \theta)$$

Замечание

Многие используемые в ML метрики имеют вид $\mathbb{E}g(x, \theta)$, где θ - параметр модели. Второй пример показывает, что можно взять производную и применить метод Монте-Карло

$$3) I = \int_a^b f(x) dx = (b-a) \int_a^b \frac{f(x)}{b-a} dx = (b-a) \int_{\mathbb{R}} f(x) p(x) dx = (b-a) \mathbb{E}f(X)$$

$$p(x) = \frac{1}{b-a} \mathbb{I}\{x \in [a, b]\}$$

X имеет распределение с плотностью $p(x)$, то есть $U[a, b]$

$$\hat{I} = \frac{b-a}{k} \sum_{j=1}^k f(x_j), X_1, \dots, X_k \sim U[a, b]$$

4) Скорость сходимости метода

$$\theta = \mathbb{E}f(X), X \sim P$$

$$\text{Оценка } \hat{\theta} = \frac{1}{k} \sum_{j=1}^k f(X_j), X_1, \dots, X_k \sim P$$

В силу ограниченности дисперсии можем по ЦПТ записать следующее

$$\sqrt{n} \frac{\hat{\theta} - \theta}{\sqrt{\mathbb{D}f(X)}} \xrightarrow{d} \mathcal{N}(0, 1)$$

$$P\left(\sqrt{n} \frac{|\hat{\theta} - \theta|}{\sqrt{\mathbb{D}f(X)}} < 3\right) \approx 0.99$$

То есть порядок сходимости(погрешности) в МК: $\frac{3\sqrt{\mathbb{D}f(X)}}{\sqrt{n}} \sim \frac{1}{\sqrt{n}}$

5) Оценка интеграла методом прямоугольников

$$I = \int_a^b f(x) dx$$

$$\hat{I} = \sum_{i=1}^n f\left(\frac{x_i + x_{i-1}}{2}\right) (x_i - x_{i-1})$$

$\{x_i\}$ - сетка точек

Теорема (о методе прямоугольников)

Если f - дважды дифференцируема, то равномерная сетка дает оценку:

$$|I - \hat{I}| \leq \frac{M(b-a)^3}{24n^2}, M = \max_{[a,b]} |f''(x)|$$

То есть у метода прямоугольников скорость сходимости $O(\frac{1}{n^2})$

Замечание

- 1) Что нужно каждому методу:
 - Для МК: $\mathbb{D}f(X) < \infty$
 - Для МП: $f''(x) < \infty$
- 2) Для одномерных задач лучше использовать метод прямоугольников, так как он сходится быстрее
- 3) У МП экспоненциально растет сетка при росте размерности, так что в многомерном случае он будет работать очень долго, при $d \geq 5$ лучше использовать МК
- 4) МК эффективно работает с матожиданием

I - 2 Повторение теории вероятностей

I - 2.1 Случайные величины и их свойства

Опр

(Ω, \mathcal{F}, P) - вероятностное пространство

- Ω - пространство элементарных исходов
- \mathcal{F} - σ -алгебра на Ω
- P - вероятностная мера

Опр

Функцией распределения $F(x)$ называется вероятность $P((-\infty, x])$

Свойства функции распределения:

- Неотрицательная, ограниченная
- Неубывающая
- Непрерывная справа
- $\lim_{x \rightarrow -\infty} F(x) = 0, \lim_{x \rightarrow \infty} F(x) = 1$

Первые 3 свойства очевидны, последнее следует из непрерывности меры

Опр

ξ (случайная величина) - измеримая функция $\Omega \rightarrow \mathbb{R}(\mathbb{R}^n)$

$F_\xi(x) = P(\xi \leq x)$ - функция распределения случайной величины

Задача(квантили экспоненциального распределения)

$$\xi \sim \text{Exp}(\theta)$$

Найдем функцию, обратную к функции распределения

$$F_{\xi}(x) = y = 1 - e^{-\theta x}$$

$$e^{-\theta x} = 1 - y \Rightarrow -\theta x = \ln(1 - y)$$

$$x = -\frac{\ln(1-y)}{\theta}$$

Ответ: $x = -\frac{\ln(1-y)}{\theta}$

Опр

Матожиданием случайной величины называется $\mathbb{E}\xi = \int_{\mathbb{R}} xp(x)dx$, если распределение абсолютно непрерывное и у него есть плотность

Дисперсия случайной величины: $\mathbb{D}\xi = \mathbb{E}\xi^2 - (\mathbb{E}\xi)^2$

Замечание

Конечно, в общем случае матожидание тоже можно определить, как

$$\mathbb{E}\xi = \int_{\mathbb{R}} xP_{\xi}(dx)$$

Задача(экспонента равномерного распределения)

Исследуем расоеделений $e^{\xi}, \xi \sim U[0, 1]$

$$F_{e^{\xi}}(x) = P(e^{\xi} \leq x) = P(\xi \leq \ln(x)) = F_{\xi} \circ \ln(x) \text{ при } x \in [1, e]$$

$$p_{e^{\xi}}(x) = F'_{e^{\xi}}(x) = \frac{1}{x} \mathbb{I}\{x \in [1, e]\}$$

$$\mathbb{E}e^{\xi} = \int_{\mathbb{R}} x \cdot \frac{1}{x} \mathbb{I}\{x \in [1, e]\} dx = \int_1^e dx = e - 1$$

Задача(распределение среднего)

$$X_1, \dots, X_n \sim P$$

$$\mathbb{E}X_i = a, \mathbb{D}X_i = \sigma^2$$

$$\mathbb{E}\bar{X} = \frac{n}{n} \mathbb{E}X_i = a$$

$$\mathbb{D}\bar{X} = \frac{1}{n^2} \mathbb{D}\left(\sum_{i=1}^n X_i\right) = \frac{n}{n^2} \mathbb{D}X_i = \frac{\sigma^2}{n}$$

$$\mathbb{E}(\bar{X})^2 = \frac{1}{n^2} \left(\overbrace{\mathbb{E}X_1^2}^{\sigma^2+a^2} + \dots + \mathbb{E}X_n^2 + 2 \overbrace{\mathbb{E}X_1 X_2 \dots}^{a^2} \right) = \frac{\sigma^2}{n} + a^2$$

Задача(моменты нормального распределения)

$$\xi \sim \mathcal{N}(0, \sigma^2)$$

$$\mathbb{E}|\xi|^n = \int_{\mathbb{R}} |x|^n e^{-\frac{x^2}{2\sigma^2}} \cdot \frac{1}{\sigma\sqrt{2\pi}} dx = \int_0^{+\infty} \frac{x^n \exp\left(-\frac{x^2}{2\sigma^2}\right)}{\sigma\sqrt{2\pi}}$$

Вспомним свойства Гамма-функции

$$\Gamma(x) = \int_0^{+\infty} e^{-t} t^{x-1} dt, \operatorname{Re}(x) > 0$$

$$\Gamma(x+1) = x\Gamma(x)$$

Теперь сделаем замену $u = \frac{x^2}{2\sigma^2}$. Тогда $x = \sigma\sqrt{2u}$, $dx = \frac{\sigma}{\sqrt{2u}}$

$$\begin{aligned} \mathbb{E}|\xi|^n &= 2 \int_0^{+\infty} \frac{e^{-u} (\sigma\sqrt{2u})^n}{\sqrt{2\pi}\sigma} \cdot \left(\frac{\sigma}{\sqrt{2u}}\right) du = \frac{(\sigma\sqrt{2})^n}{\sqrt{\pi}} \int_0^{+\infty} u^{\frac{n-1}{2}} e^{-u} du = \\ &= \frac{(\sigma\sqrt{2})^n}{\sqrt{\pi}} \Gamma\left(\frac{n+1}{2}\right) \end{aligned}$$

Ответ: $\mathbb{E}|\xi|^n = \frac{(\sigma\sqrt{2})^n}{\sqrt{\pi}} \Gamma\left(\frac{n+1}{2}\right)$

Если n – нечетное, то $\mathbb{E}|\xi|^n = \frac{\sigma^n}{\sqrt{\pi}}(n-1)!!$. Если четное, то $\sigma^n(n-1)!!$

Задача(поиск больных)

Нужно провести тест на поиск больных, действуем следующим образом

- 1) Делим людей на группы по k человек
- 2) В каждой группе берем кровь на анализы и смешиваем(вероятность заболеть у конкретного человека равна p)
 - Если в крови есть антитела, то проверяем каждого из группы
 - Если антител нет, то все из группы здоровы

Пусть T - общее число тестов, нужно найти такое k , что $\mathbb{E}T \rightarrow \min$

T_i - количество тестов в i -ой группе.

$$\mathbb{E}T = \sum_{i=1}^{\lfloor \frac{n}{k} \rfloor} \mathbb{E}T_i$$

$$\mathbb{E}T_i = (1-p)^k + (1 - (1-p)^k)(k+1)$$

$$\mathbb{E}T = \lfloor \frac{n}{k} \rfloor \left((1-p)^k + (1 - (1-p)^k)(k+1) \right) = (1-p)^k \left(\frac{n}{k} - \frac{n(k+1)}{k} \right) + \frac{(k+1)n}{k}$$

$$(1-p)^k \sim 1 - pk$$

$$\begin{aligned} \mathbb{E}T &\sim (1-pk) \left(\frac{n}{k} - \frac{(k+1)n}{k} \right) + \frac{(k+1)n}{k} = \frac{n}{k} - pn - \frac{(k+1)n}{k} + pn(k+1) + \frac{(k+1)n}{k} = \\ &= \frac{n}{k} + pnk \end{aligned}$$

$$\frac{n}{k} + pnk \rightarrow \min \Leftrightarrow \frac{1}{k} + pk \rightarrow \min$$

$$-\frac{1}{k^2} + p = 0 \Leftrightarrow k = \frac{1}{\sqrt{p}}$$

Ответ: $k = \frac{1}{\sqrt{p}}$

Опр

A_1, \dots, A_n независимы, если $\forall \{i_1, \dots, i_k\} \subset \{1, \dots, n\}$

$$P(A_{i_1} \cap \dots \cap A_{i_k}) = P(A_{i_1}) \cdot \dots \cdot P(A_{i_k})$$

Для случайных величин:

$$P(\xi_{i_1} \in A_{i_1}, \dots, \xi_{i_k} \in A_{i_k}) = \prod_{j=1}^k P(\xi_{i_j} \in A_{i_j})$$

Теорема (о наследовании независимости)

Если f, g - борелевские функции, а ξ и η независимы, то $f(\xi)$ и $g(\eta)$ тоже независимы



$$P(f(\xi) \in A, g(\eta) \in B) = P(\xi \in f^{-1}(A), \eta \in g^{-1}(B)) =$$

$$= P(f(\xi) \in A) \cdot P(g(\eta) \in B)$$



I - 2.2 Сходимости

1) Сходимость почти наверное

$$X_n \xrightarrow{\text{п.н.}} X \Leftrightarrow P(\{\omega \mid X_n(\omega) \nrightarrow X(\omega)\}) = 0$$

2) Сходимости по вероятности

$$X_n \xrightarrow{P} X \Leftrightarrow \forall \varepsilon > 0 \quad P(|X_n - X| > \varepsilon) \xrightarrow{n \rightarrow \infty} 0$$

3) Сходимость по распределению

$$X_n \xrightarrow{d} X, \text{ если } \forall f - \text{ограниченной непрерывной функции } \mathbb{E}f(X_n) \rightarrow \mathbb{E}f(X).$$

Или, равноценное условие, $\forall a$ - точка непрерывности F_X есть сходимость $F_{X_n}(a) \rightarrow F_X(a)$

$$\text{п.н.} \Rightarrow P \Rightarrow d$$

Свойства сходимостей:

- 1) $X_n \xrightarrow{d} X = C \Rightarrow X_n \xrightarrow{P} X$
- 2) $X_n \xrightarrow{P} X \Rightarrow \exists \{X_{n_k}\} : X_{n_k} \xrightarrow{\text{п.н.}} X$

Задача

X_n - независимые случайные величины

$$X_n \sim \mathcal{N}\left(0, \frac{1}{n}\right) \Rightarrow \sqrt{n}X_n \sim N(0, 1)$$

Нужно показать, что $X_n \xrightarrow{P} 0$

$$F_{X_n}(a) = P(X_n \leq a) = F_{\xi(\sqrt{n}a)}, \xi \sim \mathcal{N}(0, 1)$$

$$\lim_{n \rightarrow \infty} F_{X_n}(a) = \lim_{n \rightarrow \infty} F_{\xi}(a\sqrt{n}) = \begin{cases} 1, & a > 0 \\ \frac{1}{2}, & a = 0 \\ 0, & a < 0 \end{cases}$$

$$F_0(X) = P(0 < x) = \begin{cases} 1, & x > 0 \\ 0, & x \leq 0 \end{cases}$$

Теорема (УЗБЧ)

X_1, \dots, X_n - НОРСВ, $\mathbb{E}|X_i| < +\infty$

Тогда $\bar{X} \xrightarrow{\text{п.н.}} \mathbb{E}X_1$

Теорема (ЦПТ)

X_1, \dots, X_n - НОРСВ, $\mathbb{E}|X_i| < +\infty$, $\mathbb{E}X_i^2 < +\infty$

Тогда $\sqrt{n} \frac{\bar{X} - \mathbb{E}X_1}{\sqrt{\mathbb{D}X_1}} \xrightarrow{d} \mathcal{N}(0, 1)$

Неравенство Чебышева

$$P(|X - \mathbb{E}X| \geq a) \leq \frac{\mathbb{D}X}{a^2}$$

Задача(распределение Бернулли)

$$X_1, \dots, X_n \sim \text{Bern}\left(\frac{1}{2}\right)$$

С какого n будет выполнено $P(0.4 \leq \bar{X} \leq 0.6) \geq 0.7$?

$$P\left(\left|\frac{X_1 + \dots + X_n}{n} - 0.5\right| > 0.1\right) < \frac{\mathbb{D} \frac{X_1 + \dots + X_n}{n}}{0.01} = \frac{25}{n}$$

$$P\left(\left|\frac{X_1 + \dots + X_n}{n} - 0.5\right| \leq 0.1\right) > 1 - \frac{\mathbb{D} \frac{X_1 + \dots + X_n}{n}}{0.01} = 1 - \frac{25}{n}$$

Задача(распределение Пуассона)

$$\xi_1, \dots, \xi_{125} \sim \text{Pois}(5)$$

$$\mathbb{E}\xi_i = 5, \mathbb{D}\xi_i = 5$$

$$P(\bar{\xi} \leq 5.5) = ?$$

Воспользуемся ЦПТ:

$$\sqrt{125} \frac{\bar{\xi}-5}{\sqrt{5}} \xrightarrow{d} \mathcal{N}(0, 1) \Rightarrow \bar{\xi} - 5 \xrightarrow{d} \mathcal{N}(0, \frac{1}{25}) \Rightarrow \bar{\xi} - 5.5 \xrightarrow{d} \mathcal{N}(-\frac{1}{2}, \frac{1}{25})$$

Дальше нужно просто подставить 0 в функцию распределения $\mathcal{N}(-\frac{1}{2}, \frac{1}{25})$

I - 3 Статистики и оценки

I - 3.1 Вероятностно-статистическая модель

Опр

$(\mathcal{X}, \mathfrak{B}(\mathcal{X}), \mathcal{P})$ - вероятностно-статистическая модель

\mathcal{X} - выборочное пространство, $\mathfrak{B}(\mathcal{X})$ - σ -алгебра на нем

$\mathcal{P} = \{P_\theta \mid \theta \in \Theta\}$, Θ - множество параметров

Наша задача – оценить θ по данной выборке $X = (X_1, \dots, X_n)$ из $P \in \mathcal{P}$

Опр

Пусть (E, ε) - измеримое пространство. Тогда измеримая функция $S : \mathcal{X} \rightarrow E$ называется статистикой

Замечание

Смысл в том, что статистика - какая-то функция от выборки

Опр

Если $E = \Theta$, то такая статистика называется оценкой

Пример:

$$\tau \sim \text{Exp}(\lambda)$$

$$\tau(\theta) = \frac{1}{\theta}$$

Примеры статистик:

1) $\bar{X}, \overline{X^2}, \dots, \overline{X^k}$ - выборочный k -ый момент

$$g(X) = \frac{1}{n} \sum_{i=1}^n g(X_i)$$

2) $S^2 = \overline{X^2} - (\bar{X})^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$ - выборочная дисперсия

3) Порядковые статистики

$X_{(1)}, \dots, X_{(n)}$ - вариационный ряд

$X_{(k)}$ - k -ая порядковая статистика

I - 3.2 Свойства оценок

Замечание

Для распределения P_θ имеются следующие обозначения : $\mathbb{E}_\theta, \mathbb{D}_\theta, P_\theta$ п.н., d_θ

Перейдем к свойствам оценок

$X = (X_1, \dots, X_n)$ - выборка из распределения $P_\theta \in \mathcal{P}$

$\Theta \subseteq \mathbb{R}^d$

Опр

Оценка $\hat{\theta}(X)$ называется несмещенной оценкой параметра θ , если

$$\mathbb{E}_\theta \hat{\theta}(X) = \theta \quad \forall \theta \in \Theta$$

Несмещенной относительно $\tau(\theta)$, если $\mathbb{E}_\theta \hat{\theta}(X) = \tau(\theta) \quad \forall \theta \in \Theta$

Примеры:

- 1) $\hat{\theta}(X) = 1 : \mathbb{E}_\theta \hat{\theta}(X) = 1 \Rightarrow$ несмещенная при $\theta = 1$
- 2) $\hat{\theta}(X) = \bar{X} : \mathbb{E}_\theta \bar{X} = \mathbb{E}_\theta \frac{1}{n} \sum_{i=1}^n X_i = \frac{1}{n} \mathbb{E}_\theta X_1 = \tau(\theta)$
- 3) $\hat{\theta}(X) = X_1 : \mathbb{E}_\theta \hat{\theta}(X) = \mathbb{E}_\theta X_1 \Rightarrow$ несмещенная относительно $\tau(\theta) = \mathbb{E}_\theta X_1$

Замечание

Смысл несмещенности: при бесконечном повторении эксперимента в среднем будем получать $\theta(\tau(\theta))$

Асимптотические свойства:

Пусть $X = (X_1, \dots, X_n, \dots)$ - выборка неограниченного размера из распределения $P \in \mathcal{P} = \{P_\theta \mid \theta \in \Theta\}$

Опр

- 1) Оценка $\hat{\theta}(X)$ называется состоятельной оценкой параметра θ , если

$$\hat{\theta}(X) \xrightarrow[n \rightarrow \infty]{P_\theta} \theta \quad \forall \theta \in \Theta$$

- 2) Оценка $\hat{\theta}(X)$ называется сильно состоятельной оценкой параметра θ , если

$$\hat{\theta}(X) \xrightarrow[n \rightarrow \infty]{P_\theta \text{ п.н.}} \theta \quad \forall \theta \in \Theta$$

- 3) Оценка $\hat{\theta}(X)$ называется асимптотически нормальной оценкой параметра θ , если

$$\sqrt{n}(\hat{\theta}(X) - \theta) \xrightarrow[n \rightarrow \infty]{d_\theta} \mathcal{N}(0, \Sigma(\theta))$$

В таком случае $\Sigma(\theta)$ называется асимптотической матрицей ковариаций, в случае единичной размерности $\Sigma(\theta) = \sigma^2(\theta)$ - асимптотическая дисперсия

Замечание

$$\sqrt{n}(\hat{\theta}(X) - \theta) \xrightarrow{d_\theta} \mathcal{N}(0, \sigma^2(\theta)) \Rightarrow \hat{\theta}(X) \stackrel{d_\theta}{\sim} \frac{1}{\sqrt{n}} \mathcal{N}(0, \sigma^2(\theta)) + \theta \stackrel{d_\theta}{=} \mathcal{N}\left(\theta, \frac{\sigma^2(\theta)}{n}\right)$$

Смысл:

1) Состоятельность

При больших n оценка находится близко к θ , но нет численной характеристики, насколько




График 1: Иллюстрация состоятельной оценки

2) Асимптотическая нормальность




График 2: Иллюстрация асимптотически нормальной оценки

Здесь уже можем как-то оценить ширину, то есть численная характеристика есть

3) Сильная состоятельность

Имеет смысл для последовательно поступающих данных

Пример:

$X_1, \dots, X_n \sim \text{Laplace}$ со сдвигом θ

$$p_\theta(x) = \frac{1}{2}e^{-|x-\theta|}$$

$$\mathbb{E}_\theta X_1 = \theta, \mathbb{D}_\theta X_1 = 2$$

Исследуем $\hat{\theta} = \bar{X}$

1) $\mathbb{E}_\theta \bar{X} = \theta \Rightarrow$ оценка несмещенная

2) $\hat{\theta} = \bar{X} \xrightarrow[n \rightarrow \infty]{P_\theta} \theta = \mathbb{E}_\theta X_1 \Rightarrow$ оценка состоятельная(по УЗБЧ)

3) Сильная состоятельность также следует из УЗБЧ

$$4) \sqrt{n} \frac{\bar{X} - \mathbb{E}_\theta X_1}{\sqrt{\mathbb{D}_\theta X_1}} \xrightarrow{d_\theta} \mathcal{N}(0, 1) - \text{ЦПТ}$$

$$\sqrt{n}(\bar{X} - \theta) \xrightarrow{d_\theta} \mathcal{N}(0, \mathbb{D}_\theta X_1 = 2)$$

Значит оценка асимптотически нормальная с асимптотической дисперсией $\sigma^2(\theta) = 2$

5) Доверительный интервал

$$\bar{X} \overset{d_\theta}{\approx} \mathcal{N}\left(\theta, \frac{2}{n}\right)$$

По правилу 3σ :

$$P\left(\theta - 3\sqrt{\frac{2}{n}} < \bar{X} < \theta + 3\sqrt{\frac{2}{n}}\right) \approx 0.998$$

При $n = 200$ и $\bar{X} = 1$ с хорошей вероятностью $\theta \in (0.7, 1.3)$

УТВ

Из асимптотической нормальности следует состоятельность(из сильной состоятельности тоже следует состоятельность)

I - 3.3 Наследование свойств

В этом параграфе наша цель заключается в том, чтобы получить оценку $\tau(\theta)$, обладающую некоторыми свойствами, если есть оценка $\psi(\theta)$, обладающая этими свойствами

Пример:

$X_1, \dots, X_n \sim \text{Exp}(\theta)$

\bar{X} - асимптотически нормальная оценка $\frac{1}{\theta}$, а нам нужна оценка на θ

Теорема (о наследовании сходимостей)

Пусть $\{\xi_n\}, n \in \mathbb{N}$ - последовательность случайных величин, ξ - случайная величина размерности d .

- 1) $\xi_n \xrightarrow{P} \xi$ и $h : \mathbb{R}^d \rightarrow \mathbb{R}^m$ - непрерывная на множества B функция, причем $P(\xi \in B) = 1$, то $h(\xi_n) \xrightarrow{P} h(\xi)$
- 2) $\xi_n \xrightarrow{\text{п.н.}} \xi$ и $h : \mathbb{R}^d \rightarrow \mathbb{R}^m$ - непрерывная на множества B функция, причем $P(\xi \in B) = 1$, то $h(\xi_n) \rightarrow \text{п.н.} h(\xi)$
- 3) Если $\xi_n \xrightarrow{d} \xi$ и $h : \mathbb{R}^d \rightarrow \mathbb{R}^m$ - непрерывная, то $h(\xi_n) \xrightarrow{d} h(\xi)$

Следствие:

Если выполнены следующие условия:

- 1) $\hat{\theta}$ - (сильно) состоятельная оценка θ
- 2) Функция $\tau : \Theta \rightarrow \Theta$ непрерывна на Θ

Тогда $\tau(\hat{\theta})$ - (сильно) состоятельная оценка $\tau(\theta)$

Теорема (дельта-метод)

Пусть:

- 1) $\hat{\theta}$ - асимптотически нормальная оценка $\theta \in \Theta \subseteq \mathbb{R}^d$ с асимптотической матрицей ковариаций $\Sigma(\theta)$
- 2) $\tau : \mathbb{R}^d \rightarrow \mathbb{R}^m$ - непрерывно дифференцируема

Тогда $\tau(\hat{\theta})$ - асимптотически нормальная оценка $\tau(\theta)$ с асимптотической матрицей ковариаций $D(\theta)\Sigma(\theta)D^T(\theta)$, где $D(\theta) = \frac{\partial \tau}{\partial \theta}(\theta)$

Вернемся к пример с экспоненциальным распределением

По ЦПТ асимптотическая дисперсия оценки \bar{X} равна $\sigma^2(\theta) = \mathbb{D}_\theta X_1 = \frac{1}{\theta^2}$

Возьмем $\tau(x) = \frac{1}{x}$, тогда $\frac{\partial \tau}{\partial \theta}(x) = -\frac{1}{x^2}$

Подставим $\frac{1}{\bar{X}}$ в дельта-метод: $\sigma^{2'}(\theta) = \frac{\partial \tau}{\partial \theta}(\frac{1}{\bar{X}}) \cdot \frac{1}{\theta^2} \cdot \frac{\partial \tau}{\partial \theta}(\frac{1}{\bar{X}}) = \frac{1}{\theta^2} \cdot \theta^4 = \theta^2$

То есть по дельта-методу $\frac{1}{\bar{X}}$ - асимптотически нормальная оценка θ с асимптотической дисперсией θ^2

I - 3.4 Доверительные интервалы

Опр

Пусть $X = (X_1, \dots, X_n)$ - выборка из $P_\theta \in \mathcal{P} = \{P_\theta \mid \theta \in \Theta\}$

Если $\Theta \subseteq \mathbb{R}$, то пара статистик $(T_1(X), T_2(X))$ называется доверительным интервалом уровня доверия α , если $\forall \theta \in \Theta \ P_\theta(T_1(X) \leq \theta \leq T_2(X)) \geq \alpha$

Если выполняется равенство, то такой доверительный интервал называют точным.

Опр

Пусть $X = (X_1, \dots, X_n, \dots)$ - неограниченная выборка из $\mathcal{P} = \{P_\theta \mid \theta \in \Theta\}$

Последовательность статистик $(T_1^{(n)}(X), T_2^{(n)}(X))$ называется асимптотическим доверительным интервалом уровня доверия α , если

$$\liminf_{n \rightarrow \infty} P_\theta(T_1^{(n)}(X) \leq \theta \leq T_2^{(n)}(X)) \geq \alpha$$

Если выполняется равенство, то такой доверительный интервал называют точным.

Замечание

Смысл: $(T_1(X), T_2(X))$ накрывает θ с большой вероятностью ($\geq \alpha$)

Алгоритм построения доверительного интервала:

- 1) Пусть $\hat{\theta}$ - асимптотически нормальная оценка θ с асимптотической дисперсией $\sigma^2(\theta)$

$$\sqrt{n}(\hat{\theta} - \theta) \xrightarrow{d_\theta} \mathcal{N}(0, \sigma^2(\theta)) \Rightarrow \sqrt{n} \frac{\hat{\theta} - \theta}{\sigma(\theta)} \xrightarrow{d_\theta} \mathcal{N}(0, 1)$$

$$P\left(\sqrt{n} \frac{|\hat{\theta} - \theta|}{\sigma(\theta)} < Z_{\frac{1+\alpha}{2}}\right) \rightarrow \alpha$$

Z_α - это α квантиль стандартного нормального распределения

В питоне считается так:

```
z = sps.norm.ppf((1 + alpha) / 2)
```

- 2) $\sigma(\theta)$ может не дать выразить интервал

Пусть $\hat{\sigma}(\theta)$ - состоятельная оценка $\sigma(\theta)$

$$\sqrt{n} \frac{\hat{\theta} - \theta}{\hat{\sigma}} = \sqrt{n} \underbrace{\frac{\hat{\theta} - \theta}{\sigma(\theta)}}_{\xrightarrow{d_\theta} \mathcal{N}(0,1)} \cdot \underbrace{\frac{\sigma(\theta)}{\hat{\sigma}(\theta)}}_{\xrightarrow{P_\theta} 1} \xrightarrow{d_\theta} \mathcal{N}(0,1)$$

Последний переход совершен по лемме Слущкого

$\theta \in \left(\hat{\theta} - Z_{\frac{1+\alpha}{2}} \frac{\hat{\sigma}}{\sqrt{n}}, \hat{\theta} + Z_{\frac{1+\alpha}{2}} \frac{\hat{\sigma}}{\sqrt{n}} \right)$ - наш доверительный интервал

3) $\hat{\sigma}(\theta) = \sigma(\hat{\theta})$, если $\sigma(\theta)$ непрерывна (по теореме о наследовании сходимости)

$\hat{\theta}$ - а.н.о. $\Rightarrow \hat{\theta}$ - состоятельная $\Rightarrow \sigma(\hat{\theta})$ - состоятельная оценка $\sigma(\theta)$

Пример:

$X_1, \dots, X_n \sim \text{Pois}(\theta)$

$\mathbb{E}_\theta X_1 = \theta, \mathbb{D}_\theta X_1 = \theta$

$\hat{\theta} = \bar{X}$ - а.н.о. $\mathbb{E}_\theta X_1$ с а.д. $\mathbb{D}_\theta X_1$

По ЦПТ: $\sqrt{n}(\bar{X} - \theta) \xrightarrow{d_\theta} \mathcal{N}(0, \mathbb{D}_\theta X_1 = \theta)$

$\sqrt{n} \frac{\bar{X} - \theta}{\sqrt{\theta}} \xrightarrow{d_\theta} \mathcal{N}(0, 1) \Rightarrow P\left(\sqrt{n} \frac{|\bar{X} - \theta|}{\sqrt{\theta}} < Z_{\frac{1+\alpha}{2}}\right) \rightarrow \alpha$

$\sigma(\theta) = \sqrt{\theta}$ - непрерывная на \mathbb{R}_+ $\Rightarrow \sigma(\hat{\theta}) = \sqrt{\bar{X}}$ - состоятельная оценка $\sigma(\theta)$

$P\left(\sqrt{n} \frac{|\bar{X} - \theta|}{\sqrt{\bar{X}}} < Z_{\frac{1+\alpha}{2}}\right) \rightarrow \alpha$

Теперь выразим наш интервал:

$$-Z_{\frac{1+\alpha}{2}} < \sqrt{n} \bar{X} - \frac{\theta}{\sqrt{\bar{X}}} < Z_{\frac{1+\alpha}{2}}$$

$$\bar{X} - Z_{\frac{1+\alpha}{2}} \sqrt{\frac{\bar{X}}{n}} < \theta < \bar{X} + Z_{\frac{1+\alpha}{2}} \sqrt{\frac{\bar{X}}{n}}$$

I - 4 Статистики и оценки. Семинар

I - 4.1 Оценки и сходимости

В вероятностно-статистическом пространстве $(\mathcal{X}, \mathfrak{B}(\mathcal{X}), \mathcal{P})$ будем рассматривать $\mathcal{X} = \mathbb{R}, \mathfrak{B}(\mathcal{X}) = \mathfrak{B}(\mathbb{R})$

Пример: $\mathcal{P} = \{U[0, \theta] \mid \theta \geq 0\}, \Theta = [0, +\infty]$

Опр

Пусть (E, ε) - измеримое пространство. Тогда измеримая функция $S : \mathcal{X} \rightarrow E$ называется статистикой

Если $E = \Theta$, то такая статистика называется оценкой

Опр

Оценка называется несмещенной, если $\mathbb{E}_\theta \hat{\theta} = \theta \quad \forall \theta \in \mathbb{R}$

Пример:

$$X \sim U[0, \theta], \theta \in \mathbb{R}$$

$\hat{\theta} = 20$ – идеальна при $\theta = 20$, смещенная при любом $\theta \neq 20$

Задача

$$X_1, \dots, X_n \sim \text{Exp}(\theta), \theta > 0$$

\bar{X} - оценка $\frac{1}{\theta}$

Если посчитать матожидание $\frac{1}{X}$, то поймем, что $\frac{1}{\bar{X}}$ не является несмещенной оценкой θ

Задача

$$X_1, \dots, X_n \sim \text{Bern}(\theta), \theta \in (0, 1)$$

Нужно показать, что $\nexists \hat{\theta}(X)$ оценки для $\frac{1}{\theta}$, такой что $\hat{\theta}$ – несмещенная оценка

Докажем от противного, если такая оценка существует, то

$$\mathbb{E}_\theta \hat{\theta}(X) = \hat{\theta}(1)P_\theta(X_1 = 1) + \hat{\theta}(0)P_\theta(X_1 = 0) = c_1\theta + c_2(1 - \theta) \neq \frac{1}{\theta}$$

То есть несмещенной оценки нет

Опр

1) Оценка $\hat{\theta}(X)$ называется состоятельной оценкой параметра θ , если

$$\hat{\theta}(X) \xrightarrow[n \rightarrow \infty]{P_\theta} \theta \quad \forall \theta \in \Theta$$

2) Оценка $\hat{\theta}(X)$ называется сильно состоятельной оценкой параметра θ , если

$$\hat{\theta}(X) \xrightarrow[n \rightarrow \infty]{P_\theta \text{ п.н.}} \theta \quad \forall \theta \in \Theta$$

Задача

$$X_1, \dots, X_n \sim U[0, \theta]$$

$$\hat{\theta}_1 = (n + 1)X_{(1)}$$

$$\hat{\theta}_2 = X_{(n)}$$

Провери эти оценки на состоятельность и несмещенность

$$\mathbb{E}_\theta \hat{\theta}_1 = (n + 1)\mathbb{E}_\theta X_{(1)} = \theta \cdot \frac{n+1}{n+1} = \theta \Rightarrow \hat{\theta}_1 - \text{несмещенная оценка}$$

$\mathbb{E}_\theta \hat{\theta}_2 = \theta \cdot \frac{n}{n+1} \Rightarrow \hat{\theta}_2$ смещенная оценка

Проверим на состоятельность

$$\begin{aligned} P_\theta(|X_{(n)} - \theta| > \varepsilon) &= P_\theta(X_{(n)} < \theta - \varepsilon) = P_\theta(\forall i : X_i < \theta - \varepsilon) = \\ &= \prod_{i=1}^n P_\theta(X_i < \theta - \varepsilon) = \left(\frac{\theta - \varepsilon}{\theta}\right)^n = \left(1 - \frac{\varepsilon}{\theta}\right)^n \xrightarrow{n \rightarrow \infty} 0 \end{aligned}$$

Первый переход был сделан, так как $X_{(n)}$ всегда $< \theta$

Итого, $X_{(n)}$ – это состоятельная оценка

Исследуем $X_{(1)}$

$$\begin{aligned} P_\theta(X_{(1)} \geq t) &= \prod_{i=1}^n P(X_i \geq t) = \left(\frac{\theta - t}{\theta}\right)^n = \left(1 - \frac{t}{\theta}\right)^n \\ P_\theta(X_{(1)} < t) &= 1 - \left(1 - \frac{t}{\theta}\right)^n \\ P_\theta(|(n+1)X_{(1)} - \theta| > \varepsilon) &= P_\theta(X_{(1)} \leq \frac{\theta - \varepsilon}{n+1}) + P_\theta(X_{(1)} > \frac{\theta + \varepsilon}{n+1}) = \\ &= 1 - \left(1 - \frac{\theta - \varepsilon}{(n+1)\theta}\right)^n + \rho_+ \xrightarrow{n \rightarrow \infty} 1 - e^{-\frac{\varepsilon}{\theta}} = \rho_+ \nrightarrow 0 \end{aligned}$$

То есть вторая оценка не является состоятельной

Опр

Оценка $\hat{\theta}(X)$ называется асимптотически нормальной оценкой параметра θ , если

$$\sqrt{n}(\hat{\theta}(X) - \theta) \xrightarrow[n \rightarrow \infty]{d_\theta} \mathcal{N}(0, \Sigma(\theta))$$

В таком случае $\Sigma(\theta)$ называется асимптотической матрицей ковариаций, в случае единичной размерности $\Sigma(\theta) = \sigma^2(\theta)$ – асимптотическая дисперсия

При больших n имеем $\hat{\theta} \overset{d_\theta}{\approx} \mathcal{N}\left(\theta, \frac{\Sigma(\theta)}{n}\right)$

Задача

$$X_1, \dots, X_n \sim U[\theta - 1, \theta + 1]$$

$$\mathbb{E}_\theta X_1 = \theta, \mathbb{D}_\theta X_1 = \frac{1}{3}$$

По ЦПТ получаем следующую сходимость:

$$\sqrt{n} \frac{\bar{X} - \theta}{\sqrt{\mathbb{D}_\theta X_1}} \xrightarrow[n \rightarrow \infty]{d_\theta} \mathcal{N}(0, 1)$$

$= \sqrt{\frac{1}{3}}$

$$\sqrt{n}(\bar{X} - \theta) \xrightarrow[n \rightarrow \infty]{d_\theta} \mathcal{N}\left(0, \frac{1}{3}\right) \Rightarrow \bar{X} - \theta \xrightarrow[n \rightarrow \infty]{d_\theta} \mathcal{N}\left(0, \frac{1}{3n}\right)$$

$$\hat{\theta}(X) = \bar{X} - \text{а.н.о. } \theta \text{ с а.д. } \frac{1}{3}$$

Также можем записать следующую вероятность попадания θ в доверительный интервал:

$$P\left(\bar{X} - \sqrt{\frac{3}{n}} \leq \theta \leq \bar{X} + \sqrt{\frac{3}{n}}\right) = 0.997$$

Какие свойства оценок важны?

- Состоятельность – очень важно
- Асимптотическая нормальность – желательно, чтобы понимать предполагаемое распределение
- Несмещенность – не очень важно

Теорема (о наследовании состоятельности)

Если выполнены следующие условия:

- 1) $\hat{\theta}$ - (сильно) состоятельная оценка θ
- 2) Функция $\tau : \Theta \rightarrow \Theta$ непрерывна на Θ

Тогда $\tau(\hat{\theta})$ - (сильно) состоятельная оценка $\tau(\theta)$



Сразу следует из теоремы о наследовании сходимостей



Пример:

$$X_1, \dots, X_n \sim \text{Exp}(\theta)$$

\bar{X} – сильно состоятельная оценка $\frac{1}{\theta}$ (по УЗБЧ)

Тогда по теореме $\frac{1}{\bar{X}}$ – сильно состоятельная оценка θ

Теорема (дельта-метод)

Пусть:

- 1) $\hat{\theta}$ - асимптотически нормальная оценка $\theta \in \Theta \subseteq \mathbb{R}^d$ с асимптотической матрицей ковариаций $\Sigma(\theta)$
- 2) $\tau : \mathbb{R}^d \rightarrow \mathbb{R}^m$ - непрерывно дифференцируема

Тогда $\tau(\hat{\theta})$ - асимптотически нормальная оценка $\tau(\theta)$ с асимптотической матрицей ковариаций $D(\theta)\Sigma(\theta)D^T(\theta)$, где $D(\theta) = \frac{\partial \tau}{\partial \theta}(\theta)$

Задача

$$X_1, \dots, X_n \sim \text{Exp}(\theta)$$

Нужно доказать, что $\frac{1}{\bar{X}}$ – это а.н.о. θ с а.д. θ^2

Из ЦПТ получаем, что \bar{X} – а.н.о. $\frac{1}{\theta}$ с а.д. $\frac{1}{\theta^2}$

Возьмем функцию $\tau(x) = \frac{1}{x}$, $\frac{\partial \tau}{\partial \theta}(x) = -\frac{1}{x^2}$

Применим дельта-метод: $\sigma'^2(\theta) = \frac{\partial \tau}{\partial \theta}\left(\frac{1}{\theta}\right) \cdot \frac{1}{\theta^2} \cdot \frac{\partial \tau}{\partial \theta}\left(\frac{1}{\theta}\right) = \frac{1}{\theta^2} \cdot \theta^4 = \theta^2$

Задача

$X_1, \dots, X_n \sim \text{Exp}(\theta)$

Нужно доказать, что $\hat{\theta} = \frac{\bar{X}^2}{2(\bar{X})^3}$ – а.н.о и найти ее а.д.

Из ЦПТ знаем, что \bar{X} – а.н.о. $\frac{1}{\theta}$ с а.д. $\frac{1}{\theta^2}$

\bar{X}^2 – а.н.о. $\frac{2}{\theta^2}$

Опять же, из ЦПТ следует, что для случайных величин $Z_i = \begin{pmatrix} X_i \\ X_i^2 \end{pmatrix}$ величина $\bar{Z} = \begin{pmatrix} \bar{X} \\ \bar{X}^2 \end{pmatrix}$ является а.н.о.

Посчитаем для этой оценки матрицу ковариаций

$$\mathbb{D}Z_1 = \begin{pmatrix} \mathbb{D}X_1 & \text{cov}(X_1, X_1^2) \\ \text{cov}(X_1, X_1^2) & \mathbb{D}X_1^2 \end{pmatrix}$$

$$\mathbb{D}X_1 = \frac{1}{\theta^2}$$

$$\text{cov}(X_1, X_1^2) = \mathbb{E}X_1^3 - \mathbb{E}X_1 \cdot \mathbb{E}X_1^2 = \frac{6}{\theta^3} - \frac{2}{\theta^3} = \frac{4}{\theta^3}$$

$$\mathbb{D}X_1^2 = \mathbb{E}X_1^4 - (\mathbb{E}X_1^2)^2 = \frac{20}{\theta^4}$$

$$\text{То есть матрица ковариаций } \Sigma_Z(\theta) = \begin{pmatrix} \frac{1}{\theta^2} & \frac{4}{\theta^3} \\ \frac{4}{\theta^3} & \frac{20}{\theta^4} \end{pmatrix}$$

В качестве функции возьмем $\tau(x, y) = \frac{y}{2x^3}$

$$\frac{\partial \tau}{\partial x} = -\frac{3y}{2x^4}, \quad \frac{\partial \tau}{\partial y} = \frac{1}{2x^3}$$

$$\tau(\theta) = \tau\left(\frac{1}{\theta}, \frac{2}{\theta^2}\right) = \frac{\frac{2}{\theta^2}}{2 \cdot \frac{1}{\theta^3}} = \theta$$

То есть $\tau(\hat{\theta})$ – а.н.о. $\tau(\theta)$, где $\hat{\theta} = \frac{\bar{X}^2}{2(\bar{X})^3}$

$$\sigma^2(\theta) = D(\theta)\Sigma_Z(\theta)D(\theta)^T = \begin{pmatrix} \frac{\partial \tau}{\partial x} & \frac{\partial \tau}{\partial y} \end{pmatrix} \cdot \begin{pmatrix} \frac{1}{\theta^2} & \frac{4}{\theta^3} \\ \frac{4}{\theta^3} & \frac{20}{\theta^4} \end{pmatrix} \cdot \begin{pmatrix} \frac{\partial \tau}{\partial x} \\ \frac{\partial \tau}{\partial y} \end{pmatrix} = \frac{\theta^4}{4} - \frac{51}{8}\theta^2 + \frac{9}{20}$$

I - 4.2 Метод моментов

Пусть $X_1, \dots, X_n \sim P_\theta \in \{P_\theta \mid \theta \in \Theta \subseteq \mathbb{R}^d\}$

Рассмотрим набор борелевских функций g_1, \dots, g_d , таких что $\mathbb{E}_\theta |g_i(X_1)| < +\infty$

Составим систему:

$$\begin{cases} \mathbb{E}_{\theta} g_1(X) = \overline{g_1(X)} \\ \dots \\ \mathbb{E}_{\theta} g_d(X) = \overline{g_d(X)} \end{cases}$$

Тогда решение этой системы будет называться оценкой θ по обобщенному методу моментов

Задача:

$$X_1, \dots, X_n \sim \mathcal{N}(a, \sigma^2)$$

$$\mathbb{E}_{a, \sigma^2} X_1 = a$$

$$\mathbb{E}_{a, \sigma^2} X_1^2 = \sigma^2 + a^2$$

Замечание

Часто за g в методе моментов берут $g(x) = x$ или x^2, \dots, x^k

Возьмем $g_1(x) = x, g_2(x) = x^2$

$$\begin{cases} a = \overline{X} \\ \sigma^2 + a^2 = \overline{X^2} \end{cases} \Rightarrow \begin{cases} a = \overline{X} \\ \sigma^2 = \overline{X^2} - a^2 = \overline{X^2} - (\overline{X})^2 = S^2 \end{cases}$$

Тогда $\hat{\theta} = (\hat{a}, \hat{\sigma}^2) = (\overline{X}, S^2)$ - оценка метода моментов

$$\textbf{Ответ: } \hat{\theta} = (\hat{a}, \hat{\sigma}^2) = (\overline{X}, S^2)$$

I - 5 Статистики и оценки. Доказательства теорем

I - 5.1 Линейная регрессия

Рассмотрим задачу линейной регрессии

$$y(x) = x^T \theta, \theta \in \mathbb{R}^d$$

$$Y = \begin{pmatrix} y_1 \\ \dots \\ y_n \end{pmatrix} = x\theta + \varepsilon$$

$Y \in \mathbb{R}^n$ - отклики, они случайны; $\varepsilon \in \mathbb{R}^n$ - шум, тоже случаен; $x \in \mathbb{R}^{n \times d}, \theta \in \mathbb{R}^d$

Тогда оценкой параметра по МНК будет $\hat{\theta}_{\text{MSE}} = (x^T x)^{-1} x^T Y$

УТВ

1) Если $\mathbb{E}\varepsilon = 0$, то $\hat{\theta}_{\text{MSE}}$ - несмещенная оценка θ

$$\mathbb{E}(x^T x)^{-1} x^T Y = \mathbb{E}(x^T x)^{-1} x^T x \theta = \theta$$

2) Если $\mathbb{E}\varepsilon = 0, \mathbb{D}\varepsilon = \sigma^2 I_n$, то $\hat{\sigma}^2 = \frac{\|Y - x\hat{\theta}_{\text{MSE}}\|^2}{n-d}$ - несмещенная оценка σ^2

$$\mathbb{E}\hat{\sigma}^2 = (n-d)\mathbb{E} \sum_{i=1}^n (Y_i - x_i^T \hat{\theta}_{\text{MSE}})^2$$

Так как $\mathbb{E}Y_i = \mathbb{E}x_i^T \theta = \mathbb{E}x_i^T \hat{\theta}_{\text{MSE}}$, то

$$\mathbb{E}\hat{\sigma}^2 = \frac{1}{n-d} \sum_{i=1}^n \mathbb{D}(Y_i - x_i^T \hat{\theta}_{\text{MSE}}) = \frac{1}{n-d} \text{Tr}(\mathbb{D}(Y - x\hat{\theta}_{\text{MSE}}))$$

$$\begin{aligned} \mathbb{D}(Y - x\hat{\theta}_{\text{MSE}}) &= \mathbb{D}(Y - x(x^T x)^{-1} x^T Y) = \mathbb{D}\left(\left[I_n - \underbrace{x(x^T x)^{-1} x^T}_A\right] Y\right) = \\ &= \mathbb{D}[(I_n - A)Y] = (I_n - A)\mathbb{D}Y(I_n - A)^T = (I_n - A)\sigma^2 I_n (I_n - A)^T = \\ &= \left(I_n - 2A + \underbrace{A^T A}_A\right)\sigma^2 = (I_n - A)\sigma^2 \end{aligned}$$

$$\text{Tr}(I_n) = n, \text{Tr}(A) = d$$

Значит, подставляя это, получим:

$$\mathbb{E}\hat{\sigma}^2 = \frac{1}{n-d} \text{Tr}(\sigma^2(I_n - A)) = \sigma^2$$

I - 5.2 Наследование свойств. Продолжение

Теорема (о наследовании сходимостей)

Пусть $\{\xi_n\}, n \in \mathbb{N}$ - последовательность случайных величин, ξ - случайная величина размерности d .

- 1) $\xi_n \xrightarrow{P} \xi$ и $h: \mathbb{R}^d \rightarrow \mathbb{R}^m$ - непрерывная на множества B функция, причем $P(\xi \in B) = 1$, то $h(\xi_n) \xrightarrow{P} h(\xi)$
- 2) $\xi_n \xrightarrow{\text{п.н.}} \xi$ и $h: \mathbb{R}^d \rightarrow \mathbb{R}^m$ - непрерывная на множества B функция, причем $P(\xi \in B) = 1$, то $h(\xi_n) \rightarrow \text{п.н.} h(\xi)$
- 3) Если $\xi_n \xrightarrow{d} \xi$ и $h: \mathbb{R}^d \rightarrow \mathbb{R}^m$ - непрерывная, то $h(\xi_n) \xrightarrow{d} h(\xi)$



- 2) $\xi_n \xrightarrow{\text{п.н.}} \xi$

$$P(h(\xi_n) \rightarrow h(\xi)) \stackrel{?}{=} 1$$

$$P\left(\lim_{n \rightarrow \infty} h(\xi_n) = h(\xi)\right) \geq P\left(\lim_{n \rightarrow \infty} \xi_n = \xi, \xi \in B\right) = 1$$

То есть получили требуемое

- 1) $h(\xi_n) \xrightarrow{P} h(\xi) \Leftrightarrow \forall \varepsilon > 0 \ P(|h(\xi_n) - h(\xi)|) \rightarrow 0 \Leftrightarrow$
 $\Leftrightarrow \forall \varepsilon > 0 \ \forall \delta > 0 \ \exists N \in \mathbb{N} \ \forall n \geq N \ P(|h(\xi_n) - h(\xi)| > \varepsilon) < \delta$

Докажем от противного: $\exists \varepsilon, \delta > 0 \exists$ подпоследовательность $\{\xi_{n_k}\}_{k=1}^{\infty}$:
 $P(|h(\xi_{n_k}) - h(\xi)| > \varepsilon) > \delta$

Но по свойствам сходимости по вероятности найдется еще одна подпоследовательность $\{\xi_{n_{k_s}}\}_{s=1}^{\infty}$ такая, что на этой подпоследовательности есть сходимость почти наверное. Теперь существование $\{\xi_{n_k}\}$ противоречит пункту 2 и получено противоречие

3) Возьмем функцию $f : \mathbb{R}^d \rightarrow \mathbb{R}$ ограниченную и непрерывную.

Рассмотрим $f(h(x))$, так как $h(x)$ непрерывна, то и композиция будет непрерывна, а так как $f(x)$ ограничена, то и композиция будет ограничена. Тогда по определению сходимости по распределению имеем

$$\mathbb{E}f(h(\xi_n)) \rightarrow \mathbb{E}f(h(\xi)), \text{ так как } \xi_n \xrightarrow{d} \xi$$

$$\text{Значит, } h(\xi_n) \xrightarrow{d} h(\xi)$$



Теорема (лемма Slutsky)

Пусть $\{\xi_n\}, \{\eta_n\}, n \in \mathbb{N}$ - две последовательности случайных величин, причем есть сходимость $\xi_n \xrightarrow{d} \xi, \eta_n \xrightarrow{d} C$, тогда

$$\xi_n + \eta_n \xrightarrow{d} \xi + C, \xi_n \cdot \eta_n \rightarrow \xi \cdot C$$

Замечание

Неправильное доказательство: $(\xi_n, \eta_n) \rightarrow (\xi, \eta)$, возьмем $h(x, y) = x + y$, тогда $\xi_n + \eta_n \xrightarrow{d} \xi + \eta$.

Покомпонентная сходимость по распределению не дает сходимость вектора (хотя в случае сходимости по вероятности и почти наверное дает), поэтому нельзя применить теорему о наследовании сходимостей

Теорема (о производной)

Пусть $\{\xi_n\}, \xi_n \in \mathbb{R}^d, n \in \mathbb{N}$, - последовательность случайных величин. Выполнены 3 условия:

1) $\xi_n \xrightarrow{d} \xi$

2) $h : \mathbb{R}^d \rightarrow \mathbb{R}$ - непрерывно дифференцируема в точке $a \in \mathbb{R}^d$

3) $b_n > 0, b_n \rightarrow 0$ - числовая бесконечно малая последовательность

Тогда $\frac{h(a+\xi_n b_n) - h(a)}{b_n} \xrightarrow{d} \frac{\partial h}{\partial x} \Big|_a \cdot \xi$



Докажем для одномерного случая

Рассмотрим функцию

$$H(x) = \begin{cases} \frac{h(x+a) - h(a)}{x}, & x \neq 0 \\ h'(a), & \text{иначе} \end{cases}$$

Легко видеть, что $H(x)$ - непрерывная

По лемме Slutsky $\xi_n \cdot b_n \xrightarrow{d} 0 \Rightarrow \xi_n b_n \xrightarrow{P} 0$

Тогда по теореме о наследовании сходимостей $H(\xi_n \cdot b_n) \xrightarrow{P} H(0) = h'(a)$

И еще раз применив лемму Slutsky получаем

$$\xi_n \cdot H(\xi_n \cdot b_n) \xrightarrow{d} \xi \cdot h'(a)$$



Пример:

ξ_1, \dots, ξ_n - НОРСВ

$$\mathbb{E}\xi_k = a \neq 0, \mathbb{D}\xi_k = \sigma^2, S_n = \sum_{i=1}^n \xi_i$$

$$\sqrt{n} \left(\frac{n}{S_n} - \frac{1}{a} \right) \xrightarrow{d} ?$$

По ЦПТ имеем сходимость:

$$\underbrace{\sqrt{n} \left(\frac{S_n}{n} - a \right)}_{\zeta_n} \xrightarrow{d} \mathcal{N}(0, \sigma^2)$$

То есть $\zeta_n \xrightarrow{d} \zeta \sim \mathcal{N}(0, \sigma^2)$

Возьмем $h(x) = \frac{1}{x}$ и $b_n = \frac{1}{\sqrt{n}}$

$$\frac{h(a+b_n \zeta_n) - h(a)}{b_n} = \sqrt{n} \left(\frac{n}{S_n} - \frac{1}{a} \right) \xrightarrow{d} -\frac{1}{a^2} \cdot \zeta \sim \mathcal{N}\left(0, \frac{\sigma^2}{a^4}\right)$$

Теорема (дельта-метод)

Пусть:

- 1) $\hat{\theta}$ - асимптотически нормальная оценка $\theta \in \Theta \subseteq \mathbb{R}^d$ с асимптотической матрицей ковариаций $\Sigma(\theta)$

2) $\tau : \mathbb{R}^d \rightarrow \mathbb{R}^m$ - непрерывно дифференцируема

Тогда $\tau(\hat{\theta})$ - асимптотически нормальная оценка $\tau(\theta)$ с асимптотической матрицей ковариаций $D(\theta)\Sigma(\theta)D^T(\theta)$, где $D(\theta) = \frac{\partial \tau}{\partial \theta}(\theta)$



$\hat{\theta}$ - а.н.о. $\Leftrightarrow \sqrt{n}(\hat{\theta} - \theta) \xrightarrow{d_\theta} \mathcal{N}(0, \Sigma(\theta))$

Применим теорему о производной

$a = \theta, h(x) = \tau(x), \xi_n = \sqrt{n}(\hat{\theta} - \theta)$

$\xi \sim \mathcal{N}(0, \Sigma(\theta)), b_n = \frac{1}{\sqrt{n}}$

$\frac{h(a+\xi_n \cdot b_n) - h(a)}{b_n} = \sqrt{n}(\tau(\hat{\theta}) - \tau(\theta)) \xrightarrow{d_\theta} \frac{\partial h}{\partial x} \Big|_\theta \cdot \xi = D(\theta) \cdot \xi \sim$

$\sim \mathcal{N}(0, D(\theta)\Sigma(\theta)D^T(\theta))$



I - 5.3 Доверительные интервалы

Опр

1) Если $\Theta \subseteq \mathbb{R}$, то пара статистик $(T_1(X), T_2(X))$ называется доверительным интервалом уровня доверия α , если

$$P_\theta(T_1(X) \leq \theta \leq T_2(X)) \geq \alpha \quad \forall \theta \in \Theta$$

2) Если $\Theta \subseteq \mathbb{R}^d$, то статистика $S(X)$ называется доверительной областью уровня доверия α , если $P_\theta(\theta \in S(X)) \geq \alpha \quad \forall \theta \in \Theta$

Замечание

Обычно $\alpha = 0.95$

I - 5.4 Метод центральной функции

Пусть $G(X, \theta)$ - функция, распределение которой не зависит от θ

Опр

$p \in (0, 1)$, p - квантилем называется число $u_p = \min\{x : F(x) \geq p\}$

Возьмем $\alpha_1, \alpha_2 \in (0, 1) : \alpha_2 - \alpha_1 = \alpha$

g_j - квантиль α_j распределения $G(X, \theta)$

Введем $S(X) = \{\theta \in \Theta \mid g_1 \leq G(X, \theta) \leq g_2\}$

$P_\theta(\theta \in S(X)) = P_\theta(g_1 \leq G(X, \theta) \leq g_2) \geq \alpha_2 - \alpha_1 = \alpha$

Пример:

$X_1, \dots, X_n \sim \mathcal{N}(a, \sigma^2)$, где σ^2 – известна

Построим доверительный интервал уровня доверия α методом центральной функции

$$X_i - a \sim \mathcal{N}(0, \sigma^2)$$

$$\bar{X} - a \sim \mathcal{N}\left(0, \frac{\sigma^2}{n}\right)$$

$$\sqrt{n} \frac{\bar{X} - a}{\sigma} \sim \mathcal{N}(0, 1) \Rightarrow G(X, a) = \sqrt{n} \frac{\bar{X} - a}{\sigma} \sim \mathcal{N}(0, 1) - \text{центральная функция}$$

$$\text{Возьмем } \alpha_2 = \frac{1+\alpha}{2}, \alpha_1 = \frac{1-\alpha}{2} \Rightarrow \alpha_2 - \alpha_1 = \alpha$$

$$Z_{\alpha_1} = -Z_{\alpha_2}$$

$$P_{\theta}\left(Z_{\frac{1-\alpha}{2}} \leq \sqrt{n} \frac{\bar{X} - a}{\sigma} \leq Z_{\frac{1+\alpha}{2}}\right) = \alpha$$

Тогда доверительный интервал для a имеет вид

$$a \in \left(\bar{X} - Z_{\frac{1+\alpha}{2}} \cdot \frac{\sigma}{\sqrt{n}}, \bar{X} + Z_{\frac{1+\alpha}{2}} \cdot \frac{\sigma}{\sqrt{n}}\right)$$

I - 5.5 Точные доверительный интервалы в нормальной модели

В этом параграфе $X = (X_1, \dots, X_n)$, $X_i \sim \mathcal{N}(a, \sigma^2)$

1) Интервал для a , если σ известна

$$a \in \left(\bar{X} - Z_{\frac{1+\alpha}{2}} \cdot \frac{\sigma}{\sqrt{n}}, \bar{X} + Z_{\frac{1+\alpha}{2}} \cdot \frac{\sigma}{\sqrt{n}}\right)$$

2) Интервал для σ , если a известно

$$\xi_i = \frac{X_i - a}{\sigma} \sim \mathcal{N}(0, 1) \Rightarrow \sum_{i=1}^n \frac{(X_i - a)^2}{\sigma^2} \sim \chi_n^2$$

$$P\left(\chi_{n, \frac{1-\alpha}{2}}^2 \leq \sum_{i=1}^n \frac{(X_i - a)^2}{\sigma^2} \leq \chi_{n, \frac{1+\alpha}{2}}^2\right) = \alpha$$

$$\sum_{i=1}^n \xi_i^2 \sim \chi_n^2$$

$$\sigma \in \left(\sqrt{\frac{\sum_{i=1}^n (X_i - a)^2}{\chi_{n, \frac{1-\alpha}{2}}^2}}, \sqrt{\frac{\sum_{i=1}^n (X_i - a)^2}{\chi_{n, \frac{1+\alpha}{2}}^2}}\right)$$

Опр

$$\xi \sim \mathcal{N}(0, 1), \eta \sim \chi_k^2$$

$$\zeta = \frac{\xi}{\sqrt{\frac{\eta}{k}}} \sim T_k - \text{распределение Стьюдента}$$

3) Для a , если σ неизвестна

Теорема

$$X_1, \dots, X_n \sim \mathcal{N}(a, \sigma^2)$$

1) \bar{X} и S^2 независимы

$$2) \frac{nS^2}{\sigma^2} \sim \chi_{n-1}^2$$

$$3) \sqrt{n-1} \frac{\bar{X}-a}{S} \sim T_{n-1}$$



$$3) \frac{nS^2}{\sigma^2} \sim \chi_{n-1}^2, \sqrt{n} \frac{\bar{X}-a}{\sigma} \sim \mathcal{N}(0, 1)$$

Значит, по определению, $\frac{\sqrt{n} \frac{\bar{X}-a}{\sigma}}{\sqrt{\frac{nS^2}{\sigma^2(n-1)}}} = \sqrt{n-1} \frac{\bar{X}-a}{S} \sim T_{n-1}$



$$P\left(T_{n-1, \frac{1-\alpha}{2}} \leq \sqrt{n-1} \frac{\bar{X}-a}{S} \leq T_{n-1, \frac{1+\alpha}{2}}\right) = \alpha$$

Из симметрии распределения Стьюдента: $T_{n-1, \frac{1-\alpha}{2}} = -T_{n-1, \frac{1+\alpha}{2}}$

$$a \in \left(\bar{X} - \frac{T_{n-1, \frac{1+\alpha}{2}}}{\sqrt{n-1}} \cdot S, \bar{X} + \frac{T_{n-1, \frac{1+\alpha}{2}}}{\sqrt{n-1}} \cdot S\right)$$

Асимптотический доверительный интервал: $\left(\hat{\theta} - Z_{\frac{1+\alpha}{2}} \frac{\hat{\sigma}}{\sqrt{n}}, \hat{\theta} + Z_{\frac{1+\alpha}{2}} \frac{\hat{\sigma}}{\sqrt{n}}\right)$

4) Интервал для σ , если a неизвестно

$$\frac{nS^2}{\sigma^2} \sim \chi_{n-1}^2$$

$$P\left(\chi_{n-1, \frac{1-\alpha}{2}}^2 \leq \frac{nS^2}{\sigma^2} \leq \chi_{n-1, \frac{1+\alpha}{2}}^2\right) = \alpha$$

$$\sigma \in \left(\sqrt{\frac{nS^2}{\chi_{n-1, \frac{1+\alpha}{2}}^2}}, \sqrt{\frac{nS^2}{\chi_{n-1, \frac{1-\alpha}{2}}^2}}\right)$$

5) Доверительная область для двух параметров

В домашнем задании

Теорема (о разложении гауссовского вектора)

Пусть $\xi = (\xi_1, \dots, \xi_n) \sim \mathcal{N}(a, \sigma^2 I_n)$

Пусть $\mathbb{R}^n = \alpha_1 \oplus \dots \oplus \alpha_k$ – разложение в прямую сумму ортогональных подпространств

$$\eta_j = \text{proj}_{\alpha_j} \xi$$

Тогда

1) η_1, \dots, η_k – независимы в совокупности

$$2) \mathbb{E}\eta_j = \text{proj}_{\alpha_j}(a)$$

$$3) \frac{1}{\sigma^2} \|\eta_j - \mathbb{E}\eta_j\|^2 \sim \chi_{d_j}^2, d_j = \dim(\alpha_j)$$



Выберем ОНБ в \mathbb{R}^n (e_1, \dots, e_n)

Обозначим I_j – индексы базиса, соответствующие α_j

$$B = (e_1, \dots, e_n) \in \mathbb{R}^{n \times n}$$

$$\zeta_i = \langle \xi, e_i \rangle = e_i^T \xi$$

$$\zeta = \begin{pmatrix} \zeta_1 \\ \dots \\ \zeta_n \end{pmatrix} = \begin{pmatrix} e_1^T \xi \\ \dots \\ e_n^T \xi \end{pmatrix} = B^T \xi, \xi = B\zeta \text{ (в силу ортогональности матрицы)}$$

$$\mathbb{E}\zeta = \mathbb{E}B^T \xi = B^T \mathbb{E}\xi = B^T a$$

$$\mathbb{D}\zeta = \mathbb{D}B^T \xi = B\mathbb{D}\xi B^T = B\sigma^2 I_n B^T = \sigma^2 I_n$$

Значит, ζ – гауссовский вектор с независимыми компонентами

$\eta_j = \text{proj}_{\alpha_j}(\xi) = \sum_{i \in I_j} \langle \xi, e_i \rangle e_i = \sum_{i \in I_j} \zeta_i \cdot e_i \Rightarrow$ компоненты ζ в разных η не пересекаются, значит, η_1, \dots, η_k независимы в совокупности

$$\mathbb{E}\eta_j = \sum_{i \in I_j} \mathbb{E}\langle \xi, e_i \rangle e_i = \text{proj}_{\alpha_j}(a)$$

$$\frac{1}{\sigma^2} \|\eta_j - \mathbb{E}\eta_j\|^2 = \frac{1}{\sigma^2} \left\| \sum_{i \in I_j} \underbrace{\langle \xi - a, e_i \rangle}_{\zeta_i - \mathbb{E}\zeta_i} e_i \right\|^2 = \frac{1}{\sigma^2} \sum_{i \in I_j} (\zeta_i - \mathbb{E}\zeta_i)^2 \sim \chi_{d_j}^2$$



Теорема

$$X_1, \dots, X_n \sim \mathcal{N}(a, \sigma^2)$$

1) \bar{X} и S^2 независимы

$$2) \frac{nS^2}{\sigma^2} \sim \chi_{n-1}^2$$

$$3) \sqrt{n-1} \frac{\bar{X}-a}{S} \sim T_{n-1}$$



$$\mathbb{R}^n = \alpha \oplus \alpha^\perp, \alpha = \text{span} \begin{pmatrix} 1 \\ \dots \\ 1 \end{pmatrix}$$

$$\text{proj}_\alpha(X) : \arg \min_{c \in \mathbb{R}} \left\| X - \begin{pmatrix} c \\ \dots \\ c \end{pmatrix} \right\|^2 \Rightarrow c = \bar{X} = \text{proj}_\alpha(X) = \begin{pmatrix} \bar{X} \\ \dots \\ \bar{X} \end{pmatrix}$$

1. По предыдущей теореме $\begin{pmatrix} \bar{X} \\ \dots \\ \bar{X} \end{pmatrix}$ и $\begin{pmatrix} X_1 - \bar{X} \\ \dots \\ X_n - \bar{X} \end{pmatrix}$ независимы, значит и \bar{X} и S^2 независимы

$$2. \frac{1}{\sigma^2} \|\text{proj}_{\alpha^\perp} - \mathbb{E} \text{proj}_{\alpha^\perp} X\|^2 = \frac{1}{\sigma^2} \left\| \begin{pmatrix} X_1 - \bar{X} \\ \dots \\ X_n - \bar{X} \end{pmatrix} \right\|^2 = n \frac{S^2}{\sigma^2}$$

$$x = \text{proj}_\alpha(x) = \text{proj}_{\alpha^\perp}(x)$$



I - 6 Доверительные интервалы. Семинар

I - 6.1 Доверительные интервалы и области

Опр

Интервал из статистик $(T_1(X), T_2(X))$ называется доверительным интервалом уровня доверия α для параметра θ , если $P_\theta(\theta \in (T_1(X), T_2(X))) \geq \alpha$

Опр

Последовательность статистик $(T_1^{(n)}(X), T_2^{(n)}(X))$ называется асимптотическим доверительным интервалом уровня доверия α , если

$$\liminf_{n \rightarrow \infty} P_\theta(T_1^{(n)}(X) \leq \theta \leq T_2^{(n)}(X)) \geq \alpha$$

Если выполняется равенство, то такой доверительный интервал называют точным.

Задача

$$X_1, \dots, X_n \sim \text{Exp}^*(\theta)$$

$$p_\theta(x) = e^{-(x-\theta)} \mathbb{I}\{x > \theta\}$$

$$X_i - \theta \sim \text{Exp}(1)$$

$$P_\theta(\theta \in [X_{(1)} - c_\alpha, X_{(1)}]) \geq \alpha \Leftrightarrow P_\theta(X_{(1)} - c_\alpha \leq \theta \leq X_{(1)}) \geq \alpha$$

$$P_\theta(X_{(1)} \leq \theta + c_\alpha) \geq \alpha \Leftrightarrow P_\theta(X_{(1)} \geq \theta + c_\alpha) \leq 1 - \alpha$$

Распишем по независимости:

$$\prod_{i=1}^n P_\theta(X_i \geq \theta + c_\alpha) \leq 1 - \alpha \Leftrightarrow \prod_{i=1}^n (1 - P_\theta(X_{(i)} \leq \theta + c_\alpha)) \leq 1 - \alpha$$

Теперь перепишем последнее неравенство через функцию распределения

$$\prod_{i=1}^n (1 - (1 - e^{-c_\alpha})) \leq 1 - \alpha \Leftrightarrow \prod_{i=1}^n e^{-c_\alpha} \leq 1 - \alpha \Leftrightarrow c_\alpha \geq -\frac{\ln(1-\alpha)}{n}$$

Если же $c_\alpha = -\frac{\ln(1-\alpha)}{n}$, то доверительный интервал будет точным

$$\text{Ответ: } \theta \in \left[X_{(1)} - \frac{\ln(1-\alpha)}{n}, X_{(1)} \right]$$

I - 6.2 Метод центральных функций

Опр

Функция $G(X, \theta) : \mathcal{X} \times \Theta \rightarrow \mathbb{R}$ называется центральной, если ее распределение не зависит от θ

Рассмотрим $\alpha_2, \alpha_1 \in [0, 1], \alpha_2 > \alpha_1$

Пусть $g_{\alpha_1}, g_{\alpha_2}$ - квантили распределения $G(X, \theta)$ уровней α_1 и α_2

$D = \{ \theta : g_{\alpha_1} \leq G(X, \theta) \leq g_{\alpha_2} \}$ - доверительная область уровня α для θ

Мы хотим, чтобы $[g_{\alpha_1}, g_{\alpha_2}]$ был как можно уже, но $\alpha_2 - \alpha_1 = \alpha$

$$P_\theta(\theta \in D) = P_\theta(g_{\alpha_1} \leq G(X, \theta) \leq g_{\alpha_2}) = \alpha_2 - \alpha_1 = \alpha$$

Задача

$$X_1, \dots, X_n \sim \text{Exp}^*(\theta)$$

$$\xi_i = X_i - \theta \sim \text{Exp}(1)$$

$$\sum_{i=1}^n \xi_i = \sum_{i=1}^n X_i - n\theta \sim \Gamma(1, n)$$

$g_{\frac{1-\alpha}{2}}, g_{\frac{1+\alpha}{2}}$ - квантили $\Gamma(1, n)$

Тогда можно следующим образом записать доверительный интервал:

$$P_\theta\left(g_{\frac{1-\alpha}{2}} \leq n\bar{X} - n\theta \leq g_{\frac{1+\alpha}{2}}\right) = \alpha$$

$$\text{Ответ: } \theta \in \left[\bar{X} - \frac{g_{\frac{1+\alpha}{2}}}{n}, \bar{X} - \frac{g_{\frac{1-\alpha}{2}}}{n} \right]$$

Итого, мы рассмотрели два подхода построения интервалов:

$$\theta \in \left[\bar{X} - \frac{g_{\frac{1+\alpha}{2}}}{n}, \bar{X} - \frac{g_{\frac{1-\alpha}{2}}}{n} \right], \quad \theta \in \left[X_{(1)} - \frac{\ln(1-\alpha)}{n}, X_{(1)} \right]$$

I - 6.3 Доверительный интервал Вильсона

Рассматриваем распределение $\text{Bern}(\theta)$

- Что было в интервале Вальда:

$$\bar{X} \approx \mathcal{N}\left(\theta, \frac{\mathbb{D}X_i}{n}\right), \mathbb{D}X_i \sim \bar{X}(1 - \bar{X})$$

По ЦПТ имеем:

$$\sqrt{n} \frac{\bar{X} - \theta}{\sqrt{\mathbb{D}\bar{X}_i}} \xrightarrow{d} \mathcal{N}(0, 1)$$

$$P_{\theta} \left(-Z_{\frac{1+\alpha}{2}} \leq \sqrt{n} \frac{\bar{X} - \theta}{\sqrt{\mathbb{D}\bar{X}_i}} \leq Z_{\frac{1+\alpha}{2}} \right) = \alpha$$

В интервале Вальда мы заменяли дисперсию на ее состоятельную оценку,

$$\widehat{\mathbb{D}\bar{X}_i} = \bar{X}(1 - \bar{X})$$

$$\sqrt{n} \frac{\bar{X} - \theta}{\sqrt{\widehat{\mathbb{D}\bar{X}_i}}} = \sqrt{n} \frac{\bar{X} - \theta}{\sqrt{\mathbb{D}\bar{X}_i}} \cdot \frac{\sqrt{\mathbb{D}\bar{X}_i}}{\sqrt{\widehat{\mathbb{D}\bar{X}_i}}} \xrightarrow{d} \mathcal{N}(0, 1) \text{ (по лемме Slutsky)}$$

- Что будем делать сейчас?

Будем использовать честную дисперсию и уже из всего этого выражать θ и получать доверительный интервал

$$\bar{X} \approx \mathcal{N}\left(\theta, \frac{\mathbb{D}X_i}{n}\right)$$

$$\mathbb{D}X_i = \theta(1 - \theta)$$

По ЦПТ:

$$\sqrt{n} \frac{\bar{X} - \theta}{\sqrt{\theta(1 - \theta)}} \xrightarrow{d} \mathcal{N}(0, 1)$$

$$\left| \frac{\bar{X} - \theta}{\sqrt{\theta(1 - \theta)}} \right| \leq Z_{\frac{1+\alpha}{2}}$$

Решаем квадратное уравнение

$$n(\bar{X} - \theta)^2 \leq Z_{\frac{1+\alpha}{2}}^2 \theta(1 - \theta)$$

$$\text{Ответ: } \theta \in \left[\frac{2n\bar{X} + Z_{\frac{1+\alpha}{2}}^2}{2n + 2Z_{\frac{1+\alpha}{2}}^2} \pm \frac{1}{2n + 2Z_{\frac{1+\alpha}{2}}^2} \sqrt{Z_{\frac{1+\alpha}{2}}^4 + 4nZ_{\frac{1+\alpha}{2}}^2 \bar{X}(1 - \bar{X})} \right]$$

Замечание

В случае интервала Вальда замена дисперсии на ее оценку приводит к тому, что при малых n доверительный интервал широкий. В интервале Вильсона дисперсия считается честно и ошибка на малых n меньше, интервал уже

Главное отличие интервала Вильсона – не заменяем дисперсию на ее состоятельную оценку

I - 7 Метод максимального правдоподобия

I - 7.1 Метод максимального правдоподобия

$$X_1, \dots, X_n \sim \text{Exp}(\theta)$$

Посмотрим как мы раньше искали оценки

1) $\hat{\theta}_1 = \frac{1}{\bar{X}}$ - а.н.о. θ с а.д. $\sigma_1^2(\theta) = \theta^2$

2) Найдем оценку по методу моментов с $g(x) = \mathbb{I}\{x > 1\}$

$$\mathbb{E}_\theta \mathbb{I}\{X_1 > 1\} = \int_1^{+\infty} p_{\theta(x)} dx = e^{-\theta}$$

$$\text{По УЗБЧ: } \overline{\mathbb{I}\{X > 1\}} \xrightarrow{P_\theta \text{ п.н.}} e^{-\theta}$$

$$\text{По ЦПТ: } \sqrt{n}(\overline{\mathbb{I}\{X > 1\}} - e^{-\theta}) \xrightarrow{d_\theta} \mathcal{N}(0, \sigma_2^2(\theta))$$

$$\begin{aligned} \mathbb{D}_\theta \mathbb{I}\{X_1 > 1\} &= \mathbb{E}_\theta \mathbb{I}^2\{X_1 > 1\} - (\mathbb{E}_\theta \mathbb{I}\{X_1 > 1\})^2 = \mathbb{E}_\theta \mathbb{I}\{X_1 > 1\} - e^{-2\theta} = \\ &= e^{-\theta} - e^{-2\theta} \end{aligned}$$

Теперь применим дельта-метод с $\tau(x) = -\ln(x)$

$$-\ln(\overline{\mathbb{I}\{X > 1\}}) - \text{а.н.о. } \theta \text{ с а.д. } \sigma_2^2(\theta) = \left(\frac{\partial -\ln(x)}{\partial x} \Big|_{e^{-\theta}} \right)^2 \cdot (e^{-\theta} - e^{-2\theta}) = e^\theta - 1$$

$$\text{Итого, } \hat{\theta}_2 = -\ln(\overline{\mathbb{I}\{X > 1\}}) \text{ а.н.о. } \theta \text{ с а.д. } \sigma_2^2(\theta) = e^\theta - 1$$

Сравнивая дисперсии этих мы видим, что скорее всего $\hat{\theta}_1$ лучше $\hat{\theta}_2$. Но теперь возникает две задачи:

- 1) Нужно минимизировать дисперсию оценки
- 2) Нужно каким-то образом научиться сравнивать оценки

Предложим другой способ генерации оценки

Пусть $X = (X_1, \dots, X_n)$ – выборка из распределения P

$P \in \mathcal{P} = \{P_\theta \mid \theta \in \Theta\}$, где все P_θ либо дискретные, либо абсолютно непрерывные

Опр

Семейство распределений, в котором либо все распределения дискретные, либо все абсолютно непрерывные называется доминируемым семейством

Чтобы и в дискретном случае работали все выкладки с плотностью, определим ее следующим образом $p_\theta(x) = P_\theta(X_1 = x)$

Опр

$\mathcal{L}_X(\theta) = \prod_{i=1}^n p_\theta(X_i)$ - функция правдоподобия (функция от θ)

$$\ell_X(\theta) = \ln(\mathcal{L}_X(\theta)) = \sum_{i=1}^n \ln(p_\theta(X_i)) - \text{логарифм правдоподобия}$$




График 3: Иллюстрация метода правдоподобия

Идейно мы понимаем, что у “настоящей” плотности значения в точках где в окрестности много элементов выборки большие, то есть среди плотностей хочется выбрать ту, у которой значение в таких точках максимальное

Замечание

$\mathcal{L}_X(\theta)$ - степень правдоподобия θ для данной выборки X , значит, разумно брать ее максимум

Опр

$\hat{\theta}_{MLE}(X) = \arg \max_{\theta \in \Theta} \mathcal{L}_X(\theta) = \arg \max_{\theta \in \Theta} \ell_X(\theta)$ - оценка максимального правдоподобия (ОМП, MLE)

Утв:

ОМП не зависит от способа параметризации.

Пусть $\hat{\theta}$ - ОМП для θ , а функция $\tau : \Theta \rightarrow \Psi$ - биекция, тогда $\tau(\hat{\theta})$ - ОМП для $\tau(\theta)$

Пример:

$X_1, \dots, X_n \sim \text{Bern}(\theta)$. Нужно найти ОМП для θ и для $\ln\left(\frac{\theta}{1-\theta}\right)$

$$p_\theta(x) = \theta^x (1 - \theta)^{1-x}$$

$$\mathcal{L}_X(\theta) = \prod_{i=1}^n \theta^{X_i} (1 - \theta)^{1-X_i} = \theta^{\sum_{i=1}^n X_i} (1 - \theta)^{n - \sum_{i=1}^n X_i} \rightarrow \max_\theta$$

$$\ell_X(\theta) = \left(\sum_{i=1}^n X_i \right) \ln(\theta) - \left(n - \sum_{i=1}^n X_i \right) \ln(1 - \theta)$$

$$\ell'_X(\theta) = \frac{\sum_{i=1}^n X_i}{\theta} - \frac{n - \sum_{i=1}^n X_i}{1 - \theta} = 0 \Rightarrow \hat{\theta}_{MLE} = \bar{X}$$

Тогда по утверждению $\ln\left(\frac{\bar{X}}{1-\bar{X}}\right)$ - ОМП для $\ln\left(\frac{\theta}{1-\theta}\right)$

Теорема

Пусть $\forall n \forall X_1, \dots, X_n$ уравнение правдоподобия $\frac{\partial \ell_X}{\partial \theta} = 0$ имеет единственное решение

Тогда:

- 1) Если выполнены условия регулярности [L1-L5], то ОМП – состоятельная оценка θ
- 2) Если выполнены условия регулярности [L1-L9], то ОМП – асимптотически нормальная оценка θ с асимптотической матрицей ковариаций $i^{-1}(\theta)$, где $(i(\theta))_{jk} = \mathbb{E}_\theta \frac{\partial \ell_{X_1}}{\partial \theta_j} \cdot \frac{\partial \ell_{X_1}}{\partial \theta_k}$, здесь ℓ_{X_1} логарифм функции правдоподобия при $n = 1$

$i(\theta)$ называется информационной матрицей Фишера

Применим эту теорему для оценки для распределения Бернулли

$$\begin{aligned} i(\theta) &= \mathbb{E}_\theta \left(\frac{\partial \ell_{X_1}}{\partial \theta} \right)^2 = \mathbb{E}_\theta \left(\frac{X_1}{\theta} - \frac{1-X_1}{1-\theta} \right)^2 = \frac{1}{\theta^2(1-\theta)^2} \mathbb{E}_\theta (X_1 - \theta)^2 = \\ &= \frac{1}{\theta^2(1-\theta)^2} \mathbb{D}_\theta X_1 = \frac{1}{\theta(1-\theta)} \end{aligned}$$

И дисперсия оценки $\sigma^2(\theta) = i^{-1}(\theta) = \theta(1-\theta)$

Пример:

$$X_1, \dots, X_n \sim \text{Exp}(\theta)$$

Нужно найти ОМП и ее дисперсию

$$p_\theta(x) = \theta e^{-\theta x} \mathbb{I}\{x > 0\}$$

$$\mathcal{L}_X(\theta) = \prod_{i=1}^n p_\theta(X_i) = \theta^n e^{-\theta \sum_{i=1}^n X_i} \mathbb{I}\{X_{(1)} > 0\}$$

Теперь найдем логарифм правдоподобия

$$\ell_X(\theta) = n \ln(\theta) - \theta \sum_{i=1}^n X_i$$

$$\frac{\partial \ell_X}{\partial \theta} = \frac{n}{\theta} - \sum_{i=1}^n X_i = 0 \Leftrightarrow \theta = \frac{1}{\bar{X}}$$

$$\text{Тогда } \hat{\theta}_{\text{MLE}} = \frac{1}{\bar{X}}$$

Посчитаем дисперсию

$$i(\theta) = \mathbb{E}_\theta \left(\frac{1}{\theta} - X_1 \right)^2 = \mathbb{D}_\theta X_1 = \frac{1}{\theta^2}$$

$$i^{-1}(\theta) = \theta^2$$

I - 7.2 Задача про γ -котиков

На высоте 1 метр от точки θ находится источник γ -излучения, который излучает безмассовых γ -котиков, причем направления траекторий γ -котиков случайны, т.е. равномерно распределены по полуокружности.




График 4: Иллюстрация модели измерений

x – точка пересечения с осью, α_x – угол

Запишем функцию распределения случайной величины в точке x

$$F_{\theta}(x) = P_{\theta}(X \leq x) = \frac{\frac{\pi}{2} + \alpha_x}{\pi} \text{ – в предположении, что } \alpha_x > 0$$

$$F_{\theta}(x) = \frac{1}{2} + \frac{\alpha_x}{\pi} = \frac{1}{2} + \frac{1}{\pi} \arctan(x - \theta)$$

Это нечто иное, как распределение Коши со сдвигом θ

$$F'_{\theta}(x) = p_{\theta}(x) = \frac{1}{\pi(1+(x-\theta)^2)}$$

Что если мы хотим оценить θ ?

$$1) \hat{\theta} = \bar{X}$$

Но у распределения Коши нет математического ожидания и дисперсии, поэтому мы не можем пользоваться ЦПТ

Покажем, что в случае распределения Коши вообще нет смысла усреднять

$\varphi_X(t) = \mathbb{E}e^{itX}$ – характеристическая функция, для распределения Коши равна $e^{-|t|}$

$$\varphi_{\bar{X}}(t) = \mathbb{E}e^{it \frac{1}{n} \sum_{i=1}^n X_i} = \prod_{i=1}^n \mathbb{E}e^{it \frac{X_1}{n}} = \prod_{i=1}^n \varphi_X\left(\frac{t}{n}\right) = \left(e^{-\frac{|t|}{n}}\right)^n = e^{-|t|}$$

То есть $\overline{X} \stackrel{d}{=} X_1$ и усреднение не дает ничего хорошего

2) Попробуем найти ОМП

$$\mathcal{L}_X(\theta) = \prod_{i=1}^n \frac{1}{\pi(1+(X_i-\theta)^2)} = \frac{1}{\pi^n} \prod_{i=1}^n \frac{1}{1+(X_i-\theta)^2}$$

$$\ell_X(\theta) = -n \ln(\pi) - \sum_{i=1}^n \ln(1+(X_i-\theta)^2)$$

В общем случае после дифференцирования нельзя будет решить уравнение правдоподобия

3) Попробуем оценить θ медианой по выборке

I - 7.3 Выборочные квантили

Опр

Пусть P – распределение на $(\mathbb{R}, \mathfrak{B}(\mathbb{R}))$, $p \in (0, 1)$. Тогда p -квантилем называется $u_p = \min\{x \mid F(x) \geq p\}$




График 5: Иллюстрация квантилей

Опр

$\frac{1}{2}$ -квантиль называется медианой, $\frac{1}{4}$ -квантиль называется квартилем

$\widehat{u}_\alpha = X_{(\lceil n\alpha \rceil)}$ – выборочный α -квантиль

$$\widehat{\mu} = \begin{cases} X_{(k+1)}, & n=2k+1 \\ \frac{X_{(k)} + X_{(k+1)}}{2}, & n=2k \end{cases} \quad \text{– выборочная медиана}$$




График 6: Квантили нормального распределения

Теорема (о выборочном квантиле)

Пусть $(X_n, n \in \mathbb{N})$ - выборка неограниченного размера из распределения P с плотностью $p(x)$, число $\alpha \in (0, 1)$: $p(x)$ непрерывна в окрестности u_α и $p(u_\alpha) > 0$. тогда

- 1) $\sqrt{n}(\widehat{u}_\alpha - u_\alpha) \xrightarrow{d} \mathcal{N}\left(0, \frac{\alpha(1-\alpha)}{p^2(u_\alpha)}\right)$
- 2) $\sqrt{n}(\hat{\mu} - \mu) \xrightarrow{d} \mathcal{N}\left(0, \frac{1}{4p^2(\mu)}\right)$

Для распределения Коши:

$$\hat{\theta} = \hat{\mu} - \text{а.н.о. } \theta \text{ с а.д. } \sigma^2 = \frac{1}{4\left(\frac{1}{\pi}(1+0)^2\right)^2} = \frac{\pi^2}{4} \approx 2.47$$

Но если бы была ОМП, то ее дисперсия была бы $i(\theta) = \frac{1}{2} \Rightarrow \sigma^2(\theta) = 2$

I - 7.4 Достаточные статистики

Опр

Пусть $X = (X_1, \dots, X_n)$ - выборка из неизвестного распределения $P \in \mathcal{P} = \{P_\theta \mid \theta \in \Theta\}$

$S(X)$ - достаточная статистика для семейства \mathcal{P} , если условное распределение $P_\theta(X \in B \mid S(X))$ не зависит от $\theta \forall B \in \mathfrak{B}(\mathbb{R}^d)$

Замечание

Вся информация о θ , которая есть в выборке, хранится в достаточной статистике

Если данные поступают последовательно, то можно только пересчитывать $S(X)$

Пример:

$$X_1, \dots, X_n \sim \text{Bern}(\theta)$$

Какая вообще есть информация в выборке?

1) Количество единиц $S(X) = \sum_{i=1}^n X_i$

2) Порядок нулей и единиц

Покажем, что $S(X) = \sum_{i=1}^n X_i$ – достаточная статистика

$$P_\theta \left(X_1 = x_1, \dots, X_n = x_n \mid \sum_{i=1}^n X_i = S \right) = \frac{P_\theta(X_1=x_1, \dots, X_n=x_n)}{P_\theta \left(\sum_{i=1}^n X_i = S \right)} =$$

$$= \frac{\theta^{\sum_{i=1}^n x_i} (1-\theta)^{n - \sum_{i=1}^n x_i} \mathbb{I} \left\{ \sum_{i=1}^n X_i = S \right\}}{\binom{n}{S} \theta^S (1-\theta)^{n-S}} = \frac{1}{\binom{n}{S}} \mathbb{I} \left\{ \sum_{i=1}^n X_i = S \right\}$$

Значит, $S(X)$ – достаточная статистика

Теорема (критерий факторизации Неймана-Фишера)

Пусть $X = (X_1, \dots, X_n)$ – выборка из распределения $P \in \mathcal{P} = \{P_\theta \mid \theta \in \Theta\}$, \mathcal{P} – доминируемое распределение. Тогда

$S(X)$ – достаточная статистика $\Leftrightarrow p_\theta(x) = \Psi(S(x), \theta) h(x)$

h, Ψ – измеримые функции



Рассмотрим только дискретный случай



$S(X)$ – достаточная статистика

$\Rightarrow p_\theta(x) = P_\theta(X = x) =$

$$= P_\theta(X = x, S(X) = S(x)) = \underbrace{P_\theta(X = x \mid S(X) = S(x))}_{h(x)} \cdot \underbrace{P_\theta(S(X) = S(x))}_{\Psi(S(x), \theta)}$$



$P_\theta(X = x \mid S(X) = S(x))$ не зависит от θ

Если $S(X) \neq S(x)$, то вероятность равна 0

$$P_\theta(X = x \mid S(X) = S(x)) = \frac{P_\theta(X=x, S(X)=S(x))}{P_\theta(S(X)=S(x))} = \frac{P_\theta(X=x)}{\sum_{y: S(y)=S(x)} P_\theta(X=y)} =$$

$$= \frac{h(x) \Psi(S(x), \theta)}{\sum_{y: S(y)=S(x)} \Psi(S(y)=S(x), \theta) h(y)} = \frac{h(x)}{\sum_{y: S(y)=S(x)} h(y)}$$

Итоговое выражение не зависит от θ , значит, $S(X)$ – достаточная

Пример:

$$X_1, \dots, X_n \sim \Gamma(\alpha, \beta), \theta = (\alpha, \beta)$$

$$p_\theta(x) = \frac{\alpha^\beta}{\Gamma(\beta)} x^{\beta-1} e^{-\alpha x}$$

$$p_\theta(x_1, \dots, x_n) = \frac{\alpha^{n\beta}}{\Gamma^n(\beta)} \left(\prod_{i=1}^n x_i \right)^{\beta-1} e^{-\alpha \sum_{i=1}^n x_i}$$

Тогда по критерию факторизации Неймана-Фишера $\left(\prod_{i=1}^n X_i, \sum_{i=1}^n X_i \right)$ – достаточная статистика

I - 8 Метод максимального правдоподобия. Семинар

I - 8.1 Метод максимального правдоподобия

Опр

Семейство распределений, в котором либо все распределения дискретные, либо все абсолютно непрерывные называется доминируемым семейством

Чтобы и в дискретном случае работали все выкладки с плотностью, определим ее следующим образом $p_\theta(x) = P_\theta(X_1 = x)$

Опр

$\mathcal{L}_X(\theta) = \prod_{i=1}^n p_\theta(X_i)$ - функция правдоподобия (функция от θ)

$\ell_X(\theta) = \ln(\mathcal{L}_X(\theta)) = \sum_{i=1}^n \ln(p_\theta(X_i))$ - логарифм правдоподобия

Пример:

Оригинальные часы отстают на $\mathcal{N}(0, 1)$ мс, а поддельные – на $\mathcal{N}(0, 100^2)$. Мы померили и получили, что замедление равно 2 мс. Настоящие ли часы?

$$P_{\mathcal{N}(0,1)}(|X| > 2) \leq 0.05$$

Значит, видимо, часы поддельные

Посчитаем правдоподобие

$$\mathcal{L}_{\mathcal{N}(0,1),X}(2) = 0.054$$

$$\mathcal{L}_{\mathcal{N}(0,100^2),X}(2) = 0.004$$

Но функция правдоподобия у настоящих при таком отклонении больше в 13.5 раз. Тут никаких проблем нет, просто в данном случае отклонение 2 более маловероятно для $\mathcal{N}(0, 100^2)$, чем для $\mathcal{N}(0, 1)$

Задача

$$X_1, \dots, X_n \sim \mathcal{N}(a, \sigma^2)$$

Нужно найти ОМП для:

a. $\theta = (a, \sigma^2)$

b. $\theta = a$, если σ^2 – известна

c. $\theta = \sigma^2$, если a – известно

a. $\mathcal{L}_X(\theta) = \prod_{i=1}^n p_\theta(X_i) = \frac{1}{(2\pi\sigma^2)^{\frac{n}{2}}} \exp\left(-\frac{1}{2\sigma^2} \sum_{i=1}^n (X_i - a)^2\right)$

$$\ell_X(\theta) = -\frac{n}{2} \ln(2\pi) - n \ln(\sigma^2) - \frac{\sum_{i=1}^n (X_i - a)^2}{2\sigma^2}$$

$$\frac{\partial \ell_X}{\partial a} = \frac{1}{\sigma^2} \sum_{i=1}^n (X_i - a) = 0 \Rightarrow \hat{a} = \bar{X}$$

$$\frac{\partial \ell_X}{\partial \sigma} = -\frac{n}{\sigma} + \frac{1}{\sigma^3} \sum_{i=1}^n (X_i - a)^2 \Rightarrow \hat{\sigma} = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$$

b.

$$\frac{\partial \ell_X}{\partial a} = \frac{1}{\sigma^2} \sum_{i=1}^n (X_i - a) = 0 \Rightarrow \hat{a} = \bar{X}$$

c.

$$\frac{\partial \ell_X}{\partial \sigma} = -\frac{n}{\sigma} + \frac{1}{\sigma^3} \sum_{i=1}^n (X_i - a)^2 \Rightarrow \hat{\sigma} = \frac{1}{n} \sum_{i=1}^n (X_i - a)^2$$

Задача

$$X_1, \dots, X_n \sim \text{Geom}(\theta)$$

$$p_\theta(x) = (1 - \theta)^{x-1} \theta, x \in \mathbb{N}$$

Посчитаем функцию правдоподобия

$$\mathcal{L}_X(\theta) = \prod_{i=1}^n (1 - \theta)^{X_i-1} \theta = \theta^n (1 - \theta)^{\sum_{i=1}^n X_i - n}$$

$$\ell_X(\theta) = n \ln(\theta) + \left(\sum_{i=1}^n X_i - n \right) \ln(1 - \theta)$$

Решим уравнение правдоподобия

$$\frac{\partial \ell_X}{\partial \theta} = \frac{n}{\theta} - \frac{\sum_{i=1}^n X_i - n}{1 - \theta} = \frac{n - n\theta - \theta \cdot \sum_{i=1}^n X_i + n\theta}{\theta(1 - \theta)} = 0 \Rightarrow \hat{\theta} = \frac{1}{\bar{X}}$$

$$\text{Ответ: } \hat{\theta}_{\text{MLE}} = \frac{1}{X}$$

Задача

$$X_1, \dots, X_n \sim U[0, \theta]$$

$$p_\theta(x) = \frac{1}{\theta} \mathbb{I}\{0 \leq x \leq \theta\}$$

Найдем функцию правдоподобия

$$\mathcal{L}_X(\theta) = \prod_{i=1}^n \frac{1}{\theta} \mathbb{I}\{0 \leq X_i \leq \theta\} = \frac{1}{\theta^n} \mathbb{I}\{0 \leq X_{(1)}\} \cdot \mathbb{I}\{X_{(n)} \leq \theta\}$$

Здесь уже искать логарифм правдоподобия нет особого смысла. Мы хотим максимизировать функцию правдоподобия, $\frac{1}{\theta^n}$ убывает по θ . Значит нам нужно наименьшее θ , при котором произведение индикаторов не равно нулю

$$\text{То есть } \hat{\theta} = X_{(n)}$$

$$\text{Ответ: } \hat{\theta} = X_{(n)}$$

Основные свойства ОМП:

- 1) Если $\hat{\theta}$ – ОМП для θ , а функция $\tau : \Theta \rightarrow \Psi$ – биекция, то $\tau(\hat{\theta})$ – ОМП для $\tau(\theta)$
- 2) Если выполнены условия регулярности L1-L5, то единственность решения уравнения правдоподобия делает это решение ОМП с вероятностью $\rightarrow 1$
- 3) Если выполнены условия регулярности L1-L5, то ОМП – состоятельная оценка
- 4) Если выполнены условия регулярности L1-L9, то ОМП асимптотически нормальная оценка θ с асимптотической дисперсией

асимптотической матрицей ковариаций $i^{-1}(\theta)$, где $(i(\theta))_{jk} = \mathbb{E}_\theta \frac{\partial \ell_{X_1}}{\partial \theta_j} \cdot \frac{\partial \ell_{X_1}}{\partial \theta_k}$.

Причем у этой оценки наименьшая дисперсия

Пример:

$$X_1, \dots, X_n \sim \mathcal{N}(0, 1)$$

\bar{X} – ОМП для θ , тогда при $\tau(x) = e^x$ имеем, что $\tau(\bar{X})$ – ОМП e^θ

Задача

$$X_1, \dots, X_n \sim U[a, b]$$

$$\theta = (a, b)$$

Нужно найти ОМП для $\mathbb{E}_\theta X_1 = \frac{a+b}{2}$

$$p_\theta(x) = 1(b-a) \mathbb{I}\{a \leq x \leq b\}$$

$$\mathcal{L}_X(\theta) = \frac{1}{(b-a)^n} \mathbb{I}\{a \leq X_{(1)}\} \cdot \mathbb{I}\{X_{(n)} \leq b\}$$

$$\hat{a} = X_{(1)}, \hat{b} = X_{(n)}$$

Тогда теперь легко получить ответ

Задача

Нужно найти асимптотическую дисперсию для следующих оценок

$$1) X_1, \dots, X_n \sim \text{Geom}(\theta), \hat{\theta} = \frac{1}{\bar{X}}$$

$$\begin{aligned} i(\theta) &= \mathbb{E}_\theta \left(\frac{\partial \ell_{X_1}}{\partial \theta} \right)^2 = \mathbb{E}_\theta \left(\frac{1}{\theta} - \frac{X_1 - 1}{1 - \theta} \right)^2 = \mathbb{E}_\theta \frac{(\theta X_1 - 1)^2}{\theta^2 (1 - \theta)^2} = \frac{1}{\theta^2 (1 - \theta)^2} \mathbb{E}_\theta (\theta X_1 - 1)^2 = \\ &= \frac{1}{(1 - \theta)^2} \mathbb{E}_\theta \left(X_1 - \frac{1}{\theta} \right)^2 = \frac{1}{(1 - \theta)^2} \mathbb{D}_\theta X_1 = \frac{1}{(1 - \theta)^2} \cdot \frac{1 - \theta}{\theta} = \frac{1}{(1 - \theta)\theta} \end{aligned}$$

$$\text{Ответ: } i^{-1}(\theta) = \theta(1 - \theta)$$

$$2) X_1, \dots, X_n \sim \mathcal{N}(\theta, \sigma^2), \sigma^2 - \text{известна}$$

$$i(\theta) = \mathbb{E}_\theta \left(\frac{\partial \ell_{X_1}(\theta)}{\partial \theta} \right)^2 = \mathbb{E}_\theta \left(\frac{(X_1 - \theta)^2}{\sigma^2} \right) = \frac{1}{\sigma^4} \mathbb{E}_\theta (X_1 - \theta)^2 = \frac{1}{\sigma^4} \mathbb{D} X_1 = \frac{\sigma^2}{\sigma^4} = \frac{1}{\sigma^2}$$

$$\text{Ответ: } i^{-1}(\theta) = \sigma^2$$

I - 8.2 Оценки для распределения Коши

Пусть $X_1, \dots, X_n \sim \text{Cauchy}(\theta)$

Из лекции $\hat{\mu}$ - а.н.о. с а.д. $\frac{\pi^2}{4}$

Теорема (о выборочном квантиле)

Пусть $(X_n, n \in \mathbb{N})$ - выборка неограниченного размера из распределения P с плотностью $p(x)$, число $\alpha \in (0, 1)$: $p(x)$ непрерывна в окрестности u_α и $p(u_\alpha) > 0$. тогда

$$1) \sqrt{n}(\hat{u}_\alpha - u_\alpha) \xrightarrow{d} \mathcal{N}\left(0, \frac{\alpha(1-\alpha)}{p^2(u_\alpha)}\right)$$

$$2) \sqrt{n}(\hat{\mu} - \mu) \xrightarrow{d} \mathcal{N}\left(0, \frac{1}{4p^2(\mu)}\right)$$

Пусть $X_1, \dots, X_n \sim \text{Cauchy}(\theta)$

Причем θ не сдвиг, а масштаб

$$p_\theta(x) = \frac{1}{\pi\theta\left(1 + \left(\frac{x}{\theta}\right)^2\right)}$$

Найдем оценку для θ

$$F_\theta(x) = \frac{1}{2} + \frac{1}{\pi} \arctan\left(\frac{x}{\theta}\right)$$




График 7: График функции распределения Cauchy(θ)

Рассмотрим выборку $|X_1|, \dots, |X_n|$ и найдем ее медиану

$$F_{|X|, \theta}(x) = \frac{2}{\pi} \arctan\left(\frac{x}{\theta}\right)$$

Для медианы $F_{|X|, \theta}(\mu) = \frac{1}{2}$

Тогда решаем уравнения $\frac{2}{\pi} \arctan\left(\frac{\mu}{\theta}\right) = \frac{1}{2}$

$$\frac{\mu}{\theta} = 1 \Rightarrow \mu = \theta$$

Свели задачу к задаче из лекции

В качестве оценки возьмем $\hat{\mu}(|X_1|, \dots, |X_n|)$

I - 9 Сравнение оценок

I - 9.1 Экспоненциальное семейство распределений

Опр

Семейство распределений $\mathcal{P} = \{P_\theta \mid \theta \in \Theta\}$ принадлежит экспоненциальному классу распределений, если

$$p_\theta(x) = \frac{g(x)}{h(\theta)} \cdot e^{(a(\theta))^T u(x)}$$

Где g, u – борелевские функции, а $h(\theta) = \int_{\mathcal{X}} g(x) e^{(a(\theta))^T u(x)} dx$ – нормировочная компонента

Если $a(\theta) = \theta$, то параметризация называется естественной

Пример:

$$\mathcal{P} = \{\mathcal{N}(a, \sigma^2) \mid a \in \mathbb{R}, \sigma > 0\}, \theta = (a, \sigma)$$

$$\begin{aligned} p_\theta(x) &= \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{(x-a)^2}{2\sigma^2}} = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{1}{2\sigma^2}x^2 + \frac{xa}{\sigma^2} - \frac{a^2}{2\sigma^2}\right) = \\ &= \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{a^2}{2\sigma^2}\right) \cdot e^{(a(\theta))^T u(x)} \end{aligned}$$

$$a(\theta) = \begin{pmatrix} \frac{1}{2\sigma^2} \\ \frac{a}{\sigma^2} \end{pmatrix}, u(x) = \begin{pmatrix} -x^2 \\ x \end{pmatrix}$$

Перейдем к естественной параметризации

$$\theta_1 = \frac{1}{2\sigma^2}, \theta_2 = \frac{a}{\sigma^2} \Rightarrow \sigma^2 = \frac{1}{\theta_1}, a = \frac{\theta_2}{2\theta_1}$$

$$p_\theta(x) = \overbrace{\sqrt{\frac{\theta_1}{\pi}} \exp\left(-\frac{\theta_2^2}{2\theta_1}\right)}^{h^{-1}(\theta)} e^{\theta^T u(x)}$$

Найдем достаточную статистику для распределения из экспоненциального класса

$$\begin{aligned} X_1, \dots, X_n : p_\theta(x_1, \dots, x_n) &= \prod_{i=1}^n \frac{g(x_i)}{h(\theta)} e^{(a(\theta))^T u(x_i)} = \\ &= h^{-n}(\theta) \left(\prod_{i=1}^n g(x_i) \right) \exp\left((a(\theta))^T \sum_{i=1}^n u(x_i)\right) \end{aligned}$$

$$S(X) = \sum_{i=1}^n u(X_i) - \text{достаточная статистика по критерию Неймана-Фишера}$$

Замечание

Как мы видим, достаточная статистика имеет фиксированную размерность

Теорема

$\mathcal{P} = \{P_\theta \mid \theta \in \Theta\}$ – семейство распределений, такое что $p_\theta(x)$ непрерывно дифференцируема и носитель не зависит от θ . Пусть $S(X)$ – достаточная статистика с фиксированной размерностью.

Тогда \mathcal{P} принадлежит экспоненциальному классу.

Следствие

Если плотность “хорошая”, то только экспоненциальный класс распределений допускает сжатие с помощью достаточной статистики

Пример:

- 1) Распределение Коши с $p_\theta(x) = \frac{1}{\pi} \frac{1}{1+(x-\theta)^2}$ не лежит в экспоненциальном классе, значит у него нет достаточной статистики
- 2) $U[0, \theta], S(X) = X_{(n)}$. Но здесь не выполнено условие на плотность, поэтому теорема не работает

Далее потребуем следующие условия

- 1) $a(\theta) = \theta$, то есть работаем с естественной параметризацией
- 2) $g(x), u(x)$ – непрерывные

3) Выполнено условие равномерной сходимости интеграла

$$\forall S \forall j \leq k \exists \varphi(x) : \forall \theta \in \Theta \left| g(x) u_s^j(x) e^{\theta^T u(x)} \right| \leq \varphi(x)$$

Следствие

- 1) $h(\theta)$ – непрерывно дифференцируема k раз
- 2) $p_\theta(x)$ непрерывно дифференцируема по θ k раз
- 3) Можно менять местами $\frac{\partial}{\partial \theta}$ и \int

Теорема

$$1) \mathbb{E}_\theta u(X_1) = \nabla \ln(h(\theta))$$

$$2) \mathbb{D}_\theta u(X_1) = \left(\frac{\partial^2 \ln(h(\theta))}{\partial \theta_j \partial \theta_k} \right)_{jk}$$



$$\begin{aligned} 1) \quad \frac{\partial h(\theta)}{\partial \theta_j} &= \frac{\partial}{\partial \theta_j} \int_{\mathcal{X}} g(x) \exp(\theta^T u(x)) dx = \int_{\mathcal{X}} g(x) u_j(x) e^{\theta^T u(x)} dx = \\ &= \int_{\mathcal{X}} g(x) u_j(x) e^{\theta^T u(x)} dx = h(\theta) \int_{\mathcal{X}} u_j(x) \underbrace{\frac{g(x)}{h(\theta)} e^{\theta^T u(x)}}_{p_\theta(x)} dx = \\ &= h(\theta) \int_{\mathcal{X}} u_j(x) p_{\theta(x)} dx = h(\theta) \mathbb{E}_\theta u_j(X_1) \\ \frac{1}{h(\theta)} \frac{\partial}{\partial \theta_j} h(\theta) &= \mathbb{E}_\theta u(X_1) \Rightarrow \frac{\partial \ln(h(\theta))}{\partial \theta_j} = \mathbb{E}_\theta u(X_1) \end{aligned}$$



Теорема

Если Θ выпуклое, то ОМП существует и единственна



$$\begin{aligned} \mathcal{L}_X(\theta) &= h^{-n}(\theta) \left(\prod_{i=1}^n g(X_i) \right) e^{\theta^T \sum_{i=1}^n u(X_i)} \\ \ell_X(\theta) &= -n \ln h(\theta) + \sum_{i=1}^n \ln(g(X_i)) + \theta^T \left(\underbrace{\sum_{i=1}^n u(X_i)}_{\text{линейная функция}} \right) \end{aligned}$$

$\nabla^2 \ln(h(\theta)) = \mathbb{D}_\theta u(X_1) \geq 0 \Rightarrow$ по вогнутости получаем существование и единственность



Теорема

Если Θ – выпуклое открытое множество, то условия L1-L9 выполняются



L1-L7 выполняются из следствий и определений

L8:

$$(i(\theta))_{ij} = \mathbb{E}_{\theta} \frac{\partial \ell_{X_1}(\theta)}{\partial \theta_i \partial \theta_j}$$

$$\ell_{X_1}(\theta) = -\frac{\partial}{\partial \theta_j} \ln(h(\theta)) + u(X_1)$$

$$i(\theta) = \mathbb{E}_{\theta} \left(u(X_1) - \frac{1}{h(\theta)} \frac{\partial h(\theta)}{\partial \theta} \right)^2$$

L9:

$$\frac{\partial^3 \ln(p_{\theta}(x))}{\partial \theta^3} = - \underbrace{\frac{\partial^2}{\partial \theta^2} \frac{\frac{\partial h}{\partial \theta}}{h(\theta)}}_{\text{не зависит от } X}$$



I - 9.2 Сравнение оценок

Опр

Функция $L : \mathbb{R}^d \times \mathbb{R}^d \rightarrow \mathbb{R}_+$, которая характеризует степень отличия оценки $\hat{\theta}$ от $\tau(\theta)$ называется функцией потерь (Loss function)

Примеры:

$$d = 1$$

$$1) L(x, y) = |x - y|$$

$$2) L(x, y) = (x - y)^2$$

$$3) L(x, y) = \ln(1 + |x - y|)$$

$$d > 1$$

$$L(x, y) = (x - y)^T A (x - y)$$

Причем, если $A = I_d$, то $L(x, y) = \sum_{i=1}^n (x_i - y_i)^2$, то есть простое MSE

$L(\hat{\theta}, \tau(\theta))$ – штраф при оценивании $\tau(\theta)$ оценкой $\hat{\theta}$

Замечание

Оценка строится по выборке, штраф считается по оценке. То есть получается, что функция штрафа будет выдавать случайные значения

Опр

Функцией риска оценки $\hat{\theta}$ величины $\tau(\theta)$ называется $R_{\hat{\theta},\tau} = \mathbb{E}_{\theta} L(\hat{\theta}, \tau(\theta))$

Если $\tau(\theta) = \theta$, то будем обозначать $R_{\hat{\theta}}$

Примеры:

1) $L(x, y) = (x - y)^2$

$$L(\hat{\theta}, \tau(\theta)) = (\hat{\theta} - \tau(\theta))^2 \Rightarrow R_{\hat{\theta},\tau} = \mathbb{E}_{\theta} (\hat{\theta} - \tau(\theta))^2 = \text{MSE}_{\hat{\theta},\tau}(\theta)$$

2) $L(x, y) = |x - y|$

$$\text{MAE}_{\hat{\theta},\tau}(\theta) = \mathbb{E}_{\theta} |\hat{\theta} - \tau(\theta)|$$

Пример:

Посчитаем MSE для двух разных оценок

$$\tau(\theta) = \mathbb{E}_{\theta} X_1, \hat{\theta}_1 = X_1, \hat{\theta}_2 = \bar{X}$$

$$R_{\hat{\theta}_1} = \mathbb{E}_{\theta} (\hat{\theta}_1 - \mathbb{E}_{\theta} X_1)^2 = \mathbb{D}_{\theta} X_1$$

$$R_{\hat{\theta}_2} = \mathbb{E}_{\theta} (\hat{\theta}_2 - \mathbb{E}_{\theta} X_1)^2 = \mathbb{D}_{\theta} \bar{X} = \frac{\mathbb{D}_{\theta} X_1}{n}$$

Усреднение уменьшает риск в n раз

Рассмотрим разные подходы к сравнению оценок

1. Равномерный подход

Опр

1) $\hat{\theta}_1$ не хуже $\hat{\theta}_2$, если $\forall \theta \in \Theta : R_{\hat{\theta}_1,\tau}(\theta) \leq R_{\hat{\theta}_2,\tau}(\theta)$

2) $\hat{\theta}_1$ лучше $\hat{\theta}_2$, если кроме того $\exists \theta \in \Theta : R_{\hat{\theta}_1,\tau}(\theta) < R_{\hat{\theta}_2,\tau}(\theta)$

Опр

Пусть K - класс оценок. $\hat{\theta}$ называется наилучшей в классе K , если она лучше всех в K

Если функция потерь – это $L(x, y) = (x - y)^2$, то такой подход называется среднеквадратичным




График 8: Иллюстрация среднеквадратичного подхода

По изображенным на графике функциям риска мы можем видеть, что $\hat{\theta}_1$ лучше $\hat{\theta}_2$, а также $\hat{\theta}_1$ лучше $\hat{\theta}_3$. Но вот уже $\hat{\theta}_2$ и $\hat{\theta}_3$ сравнить нельзя

УТВ

Наилучшей оценки может не существовать

$$\Theta = \mathbb{R}, K = \{\hat{\theta}_1 = 1, \hat{\theta}_2 = 2\}, \tau(\theta) = \theta$$

$$\text{MSE}_{\hat{\theta}_1}(\theta) = (1 - \theta)^2$$

$$\text{MSE}_{\hat{\theta}_2}(\theta) = (2 - \theta)^2$$

Графики этих функций риска – это две параболы, они пересекаются и сравнить их нельзя

Теорема

Справедливо bias-variance разложение

$$\text{MSE}_{\hat{\theta}, \tau} = \overbrace{\mathbb{D}_{\theta} \hat{\theta}}^{\text{variance}} + \overbrace{(\mathbb{E}_{\theta} \hat{\theta} - \tau(\theta))^2}^{\text{bias}^2}$$



$$\begin{aligned} \text{MSE}_{\hat{\theta}, \tau} &= \mathbb{E}_{\theta} (\hat{\theta} - \tau(\theta))^2 = \mathbb{E}_{\theta} ((\hat{\theta} - \mathbb{E}_{\theta} \hat{\theta}) + (\mathbb{E}_{\theta} \hat{\theta} - \tau(\theta)))^2 = \\ &= \mathbb{E}_{\theta} \left[(\hat{\theta} - \mathbb{E}_{\theta} \hat{\theta})^2 + 2(\hat{\theta} - \mathbb{E}_{\theta} \hat{\theta})(\mathbb{E}_{\theta} \hat{\theta} - \tau(\theta)) + (\mathbb{E}_{\theta} \hat{\theta} - \tau(\theta))^2 \right] = \\ &= \mathbb{D}_{\theta} \hat{\theta} + (\mathbb{E}_{\theta} \hat{\theta} - \tau(\theta))^2 \end{aligned}$$

Среднее слагаемое равно нулю, так как вторая скобка – константа, а математическое ожидание $\mathbb{E}_{\theta} (\hat{\theta} - \mathbb{E}_{\theta} \hat{\theta}) = 0$



Следствие

В классе несмещенных оценок самая лучшая оценка – оценка с наименьшей дисперсией

2. Байесовский подход

Опр

Пусть Q распределение на Θ

$\hat{\theta}_1$ не хуже $\hat{\theta}_2$, если $\mathbb{E}_Q R_{\hat{\theta}_1, \tau} \leq \mathbb{E}_Q R_{\hat{\theta}_2, \tau}$.

Если неравенство строгое, то оценка $\hat{\theta}_1$ лучше

Замечание

Основная идея в том, что мы уже что-то знаем о θ , это знание и отражает распределение Q




График 9: Иллюстрация байесовского подхода

Пусть $Q = U[-2, 2]$. В равномерном подходе мы бы не смогли сравнить такие оценки, но тут явно видим, что площадь под функцией риска $\hat{\theta}_2$ больше, значит $\hat{\theta}_1$ не хуже $\hat{\theta}_2$

3. Минимаксный подход

Опр

$\hat{\theta}_1$ не хуже $\hat{\theta}_2$, если $\sup_{\theta \in \Theta} R_{\hat{\theta}_1, \tau} \leq \sup_{\theta \in \Theta} R_{\hat{\theta}_2, \tau}$.

Если неравенство строгое, то оценка $\hat{\theta}_1$ лучше

В предыдущем примере в таком подходе уже оценка $\hat{\theta}_2$ лучшая, ведь супремум ее риска меньше

4. Асимптотический подход

Опр

$\hat{\theta}_1, \hat{\theta}_2$ - а.н.о. θ с а.д. $\sigma_1^2(\theta), \sigma_2^2(\theta)$

- 1) $\hat{\theta}_1$ не хуже $\hat{\theta}_2$, если $\forall \theta \in \Theta : \sigma_1^2(\theta) \leq \sigma_2^2(\theta)$.
- 2) Если существует θ , в котором неравенство строгое, то оценка $\hat{\theta}_1$ лучше $\hat{\theta}_2$
- 3) $ARE_{\hat{\theta}_1, \hat{\theta}_2} = \frac{\sigma_2^2(\theta)}{\sigma_1^2(\theta)}$ – относительная асимптотическая эффективность

Опр

Оценка $\hat{\theta}$ – асимптотически эффективная оценка $\tau(\theta)$, если у нее наименьшая а.д. среди всех а.н.о. с $\tau(\theta)$ с непрерывной дисперсией

Утв

Если L1-L9 выполнено, то ОМП – асимптотически эффективная оценка

Пример:

$$X_1, \dots, X_n \sim \mathcal{N}(\theta, 1)$$

$$\hat{\theta}_1 = \bar{X} - \text{а.н.о. } \theta \text{ с а.д. } \sigma_1^2(\theta) = 1$$

$$\hat{\theta}_2 = \hat{\mu} - \text{а.н.о. } \theta \text{ с а.д. } \sigma_2^2(\theta) = \frac{\pi}{2} \text{ (по теореме о выборочном квантиле)}$$

$$ARE_{\hat{\theta}_1, \hat{\theta}_2} \approx 1.57$$

То есть выборочная медиана оказалась хуже, так как оценка средним – ОМП

I - 10 Сравнение оценок. Семинар

$$X_1, \dots, X_n \sim P \in \{P_\theta \mid \theta \in \Theta\}$$

Задача – оценить параметр θ

Общий принцип решения:

- 1) Построить мат модель
- 2) Выбрать множество оценок K
- 3) Задать численный критерий качества
- 4) Выбрать наилучшую по критерию оценку из K

Опр

$L : \mathbb{R}^d \times \mathbb{R}^d \rightarrow \mathbb{R}_+$ - функция потерь

$L(\hat{\theta}, \tau(\theta))$ – штраф при оценке $\tau(\theta)$ с помощью $\hat{\theta}$

$R_{\hat{\theta}, \tau}(\theta) = \mathbb{E}_{\theta} L(\hat{\theta}, \tau(\theta))$ – функция риска

$$\text{MSE}_{\hat{\theta}, \tau}(\theta) = \mathbb{E}_{\theta} (\hat{\theta} - \tau(\theta))^2$$

$$\text{MAE}_{\hat{\theta}, \tau}(\theta) = \mathbb{E}_{\theta} |\hat{\theta} - \tau(\theta)|$$

Пример:

$$X_1, \dots, X_n \sim \text{Bern}(\theta), \hat{\theta} = \bar{X}$$

$$\text{MSE}_{\hat{\theta}}(\theta) = \mathbb{E}_{\theta} (\bar{X} - \theta)^2 = \mathbb{D}_{\theta} \bar{X} = \frac{\theta(1-\theta)}{n}$$

Мы видим, что если реальное θ близко к концам отрезка $[0, 1]$, то функция риска меньше, чем при θ , близких к $\frac{1}{2}$

I - 10.1 Равномерный подход

Опр

- 1) $\hat{\theta}_1$ не хуже $\hat{\theta}_2$, если $\forall \theta \in \Theta : R_{\hat{\theta}_1, \tau}(\theta) \leq R_{\hat{\theta}_2, \tau}(\theta)$
- 2) $\hat{\theta}_1$ лучше $\hat{\theta}_2$, если кроме того $\exists \theta \in \Theta : R_{\hat{\theta}_1, \tau}(\theta) < R_{\hat{\theta}_2, \tau}(\theta)$

Задача

$$X_1, \dots, X_n \sim U[0, \theta], \theta > 0$$

$$K = \{cX_{(n)} \mid c \in \mathbb{R}\}$$

$$\mathbb{E}_{\theta} X_{(n)} = \frac{n}{n+1} \theta$$

$$\mathbb{E}_{\theta} X_{(n)}^2 = \int_0^{\theta} x^2 \frac{nx^{n-1}}{\theta^n} dx = \int_0^{\theta} \frac{nx^{n+1}}{\theta^n} dx = \frac{n}{n+2} \frac{x^{n+2}}{\theta^n} \Big|_0^{\theta} = \frac{n}{n+2} \theta^2$$

Теперь можем выразить MSE:

$$\begin{aligned} \text{MSE}_{cX_{(n)}}(\theta) &= \mathbb{E}_{\theta} (cX_{(n)} - \theta)^2 = c^2 \mathbb{E}_{\theta} X_{(n)}^2 - 2c\theta \mathbb{E}_{\theta} X_{(n)} + \theta^2 = \\ &= c^2 \frac{n}{n+2} \theta^2 - 2c\theta^2 \frac{n}{n+1} + \theta^2 = \theta^2 \left(\frac{n}{n+2} c^2 - \frac{2n}{n+1} c + 1 \right) \rightarrow \min_c \end{aligned}$$

Просто найдем минимум как у квадратичной функции, получим:

$$c_{\min} = \frac{2n}{(n+1)n} \cdot \frac{n+2}{2} = \frac{n+2}{n+1}$$

Лучшая оценка в равномерном подходе по MSE: $\frac{n+2}{n+1} X_{(n)}$

Причем, как мы знаем, $\frac{n}{n+1} X_{(n)}$ – единственная несмещенная оценка такого вида, а $X_{(n)}$ – ОМП

Запишем еще bias-variance разложение

$$\text{MSE}_{\hat{\theta}}(\theta) = \mathbb{D}_{\theta} \hat{\theta} + (\mathbb{E}_{\theta} \hat{\theta} - \theta)^2$$

$$\text{bias}^2 = \left(c\mathbb{E}_\theta X_{(n)} - \theta \right)^2 = \theta^2 \left(c\frac{n}{n+1} - 1 \right)^2$$

$$\text{variance} = \mathbb{D}_\theta cX_{(n)} = c^2 \frac{\theta^2 n}{(n+1)^2(n+2)}$$

Замечание

Регулируя смещение мы можем получить меньшее или большее отклонение

Задача

$$X_1, \dots, X_n \sim \mathcal{N}(0, \sigma^2)$$

$$K = \left\{ \frac{1}{c} \sum_{i=1}^n (X_i - \bar{X})^2 \mid c \in \mathbb{R}, c \neq 0 \right\}$$

Нужно найти наилучшую оценку в с/к подходе:

$$1) \frac{nS^2}{\sigma^2} \sim \chi_{n-1}^2 \Rightarrow \frac{\mathbb{D}_\sigma nS^2}{\sigma^2} = 2(n-1)$$

$$2) \mathbb{E}_\sigma \sum_{i=1}^n (X_i - \bar{X})^2 = (n-1)\sigma^2$$

$$3) \mathbb{D}_\sigma \sum_{i=1}^n (X_i - \bar{X})^2 = (n-1)\sigma^4$$

$$\text{bias}^2 = \left[\mathbb{E}_\sigma \left(\frac{1}{c} \sum_{i=1}^n (X_i - \bar{X})^2 - \sigma^2 \right) \right]^2 = \left(\frac{n-1}{c} - 1 \right)^2 \sigma^4$$

$$\text{variance} = \mathbb{D}_\sigma \frac{1}{c} \sum_{i=1}^n (X_i - \bar{X})^2 = \frac{2(n-1)}{c^2} \sigma^4$$

$$\text{MSE}_{\hat{\sigma}}(\sigma) = \sigma^4 f(c), f(c) = \left(\frac{n-1}{c} - 1 \right)^2 + \frac{2(n-1)}{c^2}$$

$$f'(c) = 2 \left(\frac{n-1}{c} - 1 \right) \cdot \left(-\frac{n-1}{c^2} \right) - \frac{4(n-1)}{c^3}$$

Тогда $c_{\min} = n + 1$

Итого, $c = n + 1$ – лучшая оценка в с/к подходе, $c = n$ – ОМП, $c = n - 1$ – несмещенная

I - 10.2 Байесовский подход

Опр

Пусть Q распределение на Θ

$\hat{\theta}_1$ не хуже $\hat{\theta}_2$, если $\mathbb{E}_Q R_{\hat{\theta}_1, \tau} \leq \mathbb{E}_Q R_{\hat{\theta}_2, \tau}$.

Если неравенство строгое, то оценка $\hat{\theta}_1$ лучше

Если Q – равномерное распределение, то просто сравниваем площадь под графиками риска

I - 10.3 Минимаксный подход

Опр

$\hat{\theta}_1$ не хуже $\hat{\theta}_2$, если $\sup_{\theta \in \Theta} R_{\hat{\theta}_1, \tau} \leq \sup_{\theta \in \Theta} R_{\hat{\theta}_2, \tau}$.

Если неравенство строгое, то оценка $\hat{\theta}_1$ лучше

I - 10.4 Оценки в схеме Бернулли

$X_1, \dots, X_n \sim \text{Bern}(\theta)$

Будем сравнивать разные оценки

1) $K = \{\text{все несмещенные оценки}\}$

\bar{X} – лучшая в с/к подходе и во всех других подходах

2) $K = \{\text{все оценки}\}$

В с/к подходе наилучших нет

3) Минимаксный подход

$\tilde{\theta} = \bar{X} + \frac{1}{1+\sqrt{n}} \left(\frac{1}{2} - \bar{X} \right)$ – оценка Ходжеса-Лемана

$\tilde{\theta} = \arg \min_{\hat{\theta}} \max_{\theta \in \Theta} \mathbb{E}_{\theta} (\hat{\theta} - \theta)^2$

Рассмотрим $n = 9$:

Доля $\theta \in [0, 1]$, при которых $\tilde{\theta}$ лучше \bar{X} равна ≈ 0.66 , то есть, если θ выбирается равномерно из $[0, 1]$, то в 66% случаев $\tilde{\theta}$ будет лучше

Рассмотрим функцию $p(\theta) = P_{\theta} \left(\frac{\theta - d_n}{1 - 2d_n} \leq \bar{X} \leq \frac{1}{2} \right)$, $d_n = \frac{1}{4(\sqrt{1+\sqrt{n}})}$, $\theta \leq \frac{1}{2}$

Во-первых, функция симметрична относительно $\theta = \frac{1}{2}$, во-вторых,

$p(\theta) = P_{\theta} (|\tilde{\theta} - \theta| < |\bar{X} - \theta|)$

То есть по ней мы можем понять, когда оценка Ходжеса Лемана скорее всего лучше, чем оценка средним




График 10: График $p(\theta)$

Если график ниже $\frac{1}{2}$, то настоящее значение ближе к \bar{X} , если выше — наоборот.

Замечание

$X_1, \dots, X_n \sim \mathcal{N}(\theta, \sigma^2)$, σ — известна

Тогда \bar{X} — наилучшая в с/к подходе и минимаксном подходе (при MSE). Но тем не менее $\exists \tilde{\theta} \forall \theta \in \mathbb{R} P_{\theta}(|\tilde{\theta} - \theta| < |\bar{X} - \theta|) > \frac{1}{2}$

$$\tilde{\theta} = \bar{X} - \frac{\sigma}{2\sqrt{n}} \cdot \text{sign}(\bar{X}) \min\left(\sqrt{n} \frac{|\bar{X}|}{\sigma}, \Phi_{\mathcal{N}(0,1)}\left(-\sqrt{n} \frac{|\bar{X}|}{\sigma}\right)\right)$$

I - 10.5 Асимптотический подход

Опр

$\hat{\theta}_1, \hat{\theta}_2$ — а.н.о. θ с а.д. $\sigma_1^2(\theta), \sigma_2^2(\theta)$

- 1) $\hat{\theta}_1$ не хуже $\hat{\theta}_2$, если $\forall \theta \in \Theta : \sigma_1(\theta) \leq \sigma_2(\theta)$.
- 2) Если существует θ , в котором неравенство строгое, то оценка $\hat{\theta}_1$ лучше $\hat{\theta}_2$
- 3) $\text{ARE}_{\hat{\theta}_1, \hat{\theta}_2} = \frac{\sigma_2^2(\theta)}{\sigma_1^2(\theta)}$ — относительная асимптотическая эффективность

Замечание

Если $\text{ARE}_{\hat{\theta}_1, \hat{\theta}_2} > 1$, то $\hat{\theta}_1$ лучше

Пример:

$X_1, \dots, X_n \sim \mathcal{N}(\theta, \sigma^2)$, σ – известна

Сравним среднее и медиану в асимптотическом подходе

\bar{X} – а.н.о. с а.д. $\sigma_1^2 = \mathbb{D}_\theta X_1 = \sigma^2$

По теореме о выборочном квантиле $\hat{\mu}$ – а.н.о. θ с а.д. $\sigma_2^2 = \frac{\pi\sigma^2}{2}$

$\text{ARE}_{\bar{X}, \hat{\mu}} = \frac{\pi}{2} > 1 \Rightarrow \bar{X}$ лучше $\hat{\mu}$

Пример:

Сравним еще среднее и медиану для распределения Лапласа

$X_1, \dots, X_n \sim \text{Laplace}(\theta)$

$p_\theta(x) = \frac{1}{2}e^{-|x-\theta|}$

\bar{X} – а.н.о. θ с а.д. $\sigma_1^2 = 2$

$\hat{\mu}$ – а.н.о. θ с а.д. $\sigma_2^2 = 1$

В данном случае медиана оказалось лучше

I - 11 Робастные оценки

I - 11.1 Приближенный поиска ОМП. Метод Ньютона

Пусть дана функция $f(x) : \mathbb{R} \rightarrow \mathbb{R}$ и надо решить уравнение $f(x) = 0$

Идея: приближение касательной

$y(x) = f(x_0) + f'(x_0)(x - x_0) = 0$

$x = x_0 - \frac{f(x_0)}{f'(x_0)}$

Исходя из этого запишем итерацию метода Ньютона

$x^{(k+1)} = x^{(k)} - \frac{f(x^{(k)})}{f'(x^{(k)})}$

Применим теперь метод Ньютона для поиска ОМП:

Нам нужно получить $\ell_X(\theta) \rightarrow \max_\theta$

То есть найти экстремум, а это мы можем сделать, найдя ноль производной

$\frac{\partial \ell_X(\theta)}{\partial \theta} = 0 : \theta^{(k+1)} = \theta^{(k)} - (\nabla^2 \ell_X(\theta^{(k)}))^{-1} \cdot (\nabla \ell_X(\theta^{(k)}))$

Замечание

Пока неизвестно, какую брать начальную точку и насколько быстрая сходимость, то есть сколько итераций надо сделать

Теорема

В условиях L1-L9 если $\hat{\theta}^{(0)}$ - а.н.о. θ , то

- 1) $\hat{\theta}^{(1)}$ - а.н.о. θ с а.д. $i^{-1}(\theta)$
- 2) $\hat{\theta}^{(1)}$ - асимптотически эквивалента ОМП, то есть

$$\sqrt{n}(\hat{\theta}^{(1)} - \theta^*) \xrightarrow{P_\theta} 0, n \rightarrow \infty, \text{ где } \theta^* - \text{ОМП}$$



Без доказательства примем, что $\hat{\theta}^{(1)} - \theta^* = (\hat{\theta}^{(0)} - \theta^*)\varepsilon_n(\theta), \varepsilon_n(\theta) \xrightarrow{P_\theta} 0$

$$2) \sqrt{n}(\hat{\theta}^{(1)} - \theta^*) = \sqrt{n}(\hat{\theta}^{(0)} - \theta)\varepsilon_n(\theta) + \sqrt{n}(\theta - \theta^*)\varepsilon_n(\theta) \rightarrow 0$$

По лемме Слуцкого и асимптотической нормальности каждое слагаемое сходится к нулю по распределению, а значит сходится к нулю и по вероятности

$$1) \sqrt{n}(\hat{\theta}^{(1)} - \theta) = \overbrace{\sqrt{n}(\hat{\theta}^{(1)} - \theta)}^{\xrightarrow{P_\theta} 0} + \overbrace{\sqrt{n}(\theta^* - \theta)}^{\xrightarrow{d_\theta} \mathcal{N}(0, i^{-1}(\theta))} \xrightarrow{d_\theta} \mathcal{N}(0, i^{-1}(\theta))$$



Утв

Утверждение теоремы не изменится, если заменить $\nabla^2 \ell_X(\theta)$ на

$$\mathbb{E}_\theta \nabla^2 \ell_X(\theta) = -ni(\theta)$$

$$\hat{\theta}^{(1)} = \hat{\theta}^{(0)} + i^{-1}(\theta) \nabla \ell_X(\theta) \cdot \frac{1}{n}$$

Пример:

Применим нашу теорему к распределению Коши и выборочной медиане

$$\hat{\theta}^{(0)} = \hat{\mu} - \text{выборочная медиана}$$

$$\hat{\mu} - \text{а.н.о. } \theta \text{ с а.д. } \sigma^2 = \frac{\pi^2}{4} \approx 2.47, \text{ а у ОМП дисперсия была бы равна } 2$$

Теперь выпишем одношаговую оценку

$$\hat{\theta}^{(1)} = \hat{\mu} + \frac{\sum_{i=1}^n \frac{X_i - \hat{\mu}}{1 + (X_i - \hat{\mu})^2}}{\sum_{i=1}^n \frac{1 - (X_i - \hat{\mu})^2}{(1 + (X_i - \hat{\mu})^2)^2}}$$

Замечание

- 1) Если не выполнены L1-L9, то нужно сделать несколько итераций метода Ньютона

2) Если $\ell_X(\theta)$ не выпуклая, то можно запустить метод несколько раз, а результаты усреднить

I - 11.2 Робастность и симметричность

Пусть нам дана выборка $X = (X_1, \dots, X_n) \sim \mathcal{N}(\theta, 1)$

$\hat{\theta} = \bar{X}$ – как мы знаем это хорошая оценка, асимптотически нормальная, ОМП и т.д. Но что если в данных будут выбросы – оценка испортится, хорошие свойства потеряются

Замечание

В реальных данных где-то 10% выбросов

Поэтому нужны методы детекции выбросов и оценки, которые умеют работать с этими выбросами.

Начнем с детекции выбросов. Рассмотрим график boxplot или “ящик с усами”




График 11: Иллюстрация boxplot

$\hat{\mu}$ – выборочная медиана, $\hat{u}_{\frac{1}{4}}, \hat{u}_{\frac{3}{4}}$ – соответствующие выборочные квантили, $I = \hat{u}_{\frac{3}{4}} - \hat{u}_{\frac{1}{4}}$

Выбросами в таком случае принято считать точки, которые не попадают в отрезок $\left[\hat{u}_{\frac{1}{4}} - \frac{3}{2}I, \hat{u}_{\frac{3}{4}} + \frac{3}{2}I \right]$

Теперь перейдем к робастным оценкам

I - 11.3 Робастные оценки

Пусть исследуемое семейство распределений – это $\mathcal{P} = \{P_\theta \mid \theta \in \Theta\}$. Причем P_0 имеет плотность $p_0(x)$, симметричную относительно 0, непрерывную, с носителем $(-c, c)$, $c > 0$ и удовлетворяющую равенству $p_\theta(x) = p_0(x - \theta)$, то есть θ – это сдвиг

Мы хотим получить оценку, которая будет хорошо приближать θ , но также будет устойчивой к выбросам

1. Усеченное среднее

Опр

$$\alpha \in (0, \frac{1}{2}), k = \lceil \alpha n \rceil$$

$$\bar{X}_\alpha = \frac{1}{n-2k} \sum_{i=k+1}^{n-k} X_{(i)}$$

Опр

Пусть $\hat{\theta} = f(X_{(1)}, \dots, X_{(n)})$. Определим K_n^* как наименьшее k , такое что:

1) Если $X_1, \dots, X_{k+1} \rightarrow -\infty$, а X_{k+2}, \dots, X_n – фиксированные, то

$$f(X_1, \dots, X_n) \rightarrow -\infty$$

2) Если $X_{n-k}, \dots, X_n \rightarrow -\infty$, а X_1, \dots, X_{n-k-1} – фиксированные, то

$$f(X_1, \dots, X_n) \rightarrow -\infty$$

Тогда величина $\tau_{\hat{\theta}} = \lim_{n \rightarrow \infty} \frac{K_n^*}{n}$ называется асимптотической толерантностью оценки $\hat{\theta}$

Замечание

$\tau_{\hat{\theta}}$ – это наибольшая доля выбросов, которую выдержит оценка

Теорема (об усеченном среднем)

$$\alpha \in (0, \frac{1}{2}), k = \lceil \alpha n \rceil$$

$X_1, \dots, X_n \sim P \in \mathcal{P}$ – для распределения выполнены условия выше

Тогда $\sqrt{n}(\bar{X}_\alpha - \theta) \xrightarrow{d_\theta} \mathcal{N}(0, \sigma_\alpha^2)$

$$\sigma_\alpha^2 = \frac{2}{(1-2\alpha)^2} \left[\int_0^{u_{1-\alpha}} x^2 p_0(x) dx + \alpha u_{1-\alpha}^2 \right]$$

$u_{1-\alpha}$ – это $1 - \alpha$ квантиль распределения P_0


Пример:

График 12: Графики дисперсий усеченного среднего

Также в качестве примера приведем сравнения среднего и усеченного среднего для $\mathcal{N}(\theta, 1)$

α	0	$\frac{1}{20}$	$\frac{1}{8}$	$\frac{1}{4}$	$\frac{3}{8}$	$\frac{1}{2}$
$\text{ARE}_{\bar{X}_\alpha, \bar{X}}$	1	0.99	0.94	0.84	0.74	0.64

Замечание

$\alpha = \frac{1}{8}$ защищает от 12.5% выбросов

Теорема

Если $\mathbb{D}_\theta X_1 < \infty$, то $\text{ARE}_{\bar{X}_\alpha, \bar{X}} \geq (1 - 2\alpha)^2$



\bar{X}_α – а.н.о. θ с а.д. σ_α^2

\bar{X} – а.н.о. θ с а.д. $\sigma^2 = \mathbb{D}_\theta X_1$

$$\frac{1}{2} \mathbb{D}_\theta X_1 = \frac{1}{2} \int_{\mathbb{R}} x^2 p_0(x) dx = \int_0^{+\infty} x^2 p_0(x) dx =$$

$$= \int_0^{u_{1-\alpha}} x^2 p_0(x) dx + \int_{u_{1-\alpha}}^{+\infty} x^2 p_0(x) dx \geq \int_0^{u_{1-\alpha}} x^2 p_0(x) dx + \alpha u_{1-\alpha}^2 = \frac{\sigma_\alpha^2 (1-2\alpha)^2}{2}$$

Тогда $\text{ARE}_{\bar{X}_\alpha, \bar{X}} \geq (1 - 2\alpha)^2$



2. Медиана средних Уолша

Опр

$Y_{ij} = \frac{X_i + X_j}{2}$ – среднее Уолша

$W = \text{median}(\{Y_{ij}, 1 \leq i \leq j \leq n\})$

Пусть X_1, \dots, X_n – выборка из $P_\theta \in \mathcal{P}$ (в условиях выше). Тогда $\sqrt{n}(W - \theta) \xrightarrow{d_\theta} \mathcal{N}(0, \sigma^2)$

$$\text{Где } \sigma^2 = \frac{1}{12} \left[\frac{1}{\int_{\mathbb{R}} p_0^2(x) dx} \right]^2$$

Утв

$$\tau_W \approx 0.293$$

То есть медиана Уолша может выдержать до 29.3% выбросов

$\text{ARE}_{W, \bar{X}} \approx 0.955$ для $\mathcal{N}(\theta, 1)$

Замечание

Для общего случая есть теорема, которая доказывает, что $\text{ARE}_{W, \bar{X}} \geq \frac{108}{125} = 0.864$

То есть в худшем случае теряем 14% эффективности, причем плотность для этого худшего случая выглядит вот так: $p_0(x) = \frac{3\sqrt{5}}{100}(5 - x^2)\mathbb{I}\{|x| \leq \sqrt{5}\}$

I - 11.4 Эмпирическое распределение

Пусть $X = (X_1, \dots, X_n)$ – выборка из распределения P , причем \mathcal{P} – это все распределения на \mathcal{X} , то есть семейство распределений мы никак не ограничиваем

Опр

Эмпирическим распределением по X называется вероятностная мера, определяемая по правилу $\forall B \in \mathfrak{B}(\mathcal{X}) : \hat{P}_n(B) = \frac{1}{n} \sum_{i=1}^n \mathbb{I}\{X_i \in B\}$

Свойства:

- 1) $\hat{P}_n(B)$ – случайная величина (доля элементов, попавших в B)
- 2) $\hat{P}_n(B)$ – дискретная вероятностная мера
- 3) $n \cdot \hat{P}_n(B) \sim \text{Binom}(n, P(B))$
- 4) Из УЗБЧ следует, что $\hat{P}_n(B) \xrightarrow{\text{п.н.}} P(B)$

Теперь перейдем в $(\mathbb{R}, \mathfrak{B}(\mathbb{R}))$ и будем рассматривать случайные величины только там. Тогда справедливы следующие результаты

$\hat{P}_n(B)$ имеет эмпирическую функцию распределения

$$\hat{F}_n(x) = \hat{P}_n((-\infty, x]) = \frac{1}{n} \sum_{i=1}^n \mathbb{I}\{X_i \leq x\}$$

И эта функция распределения тоже почти наверное сходится к настоящей, свойства этой сходимости устанавливают следующие теоремы

Теорема (Гливенко-Кантелли)

$$D_n = \sup_{x \in \mathbb{R}} |\hat{F}_n(x) - F(x)| \xrightarrow{\text{п.н.}} 0$$

Заметим, что $D_n = \sup_{B \in \mathcal{A}} |\hat{P}_n(B) - P(B)| \xrightarrow{\text{п.н.}} 0$, $\mathcal{A} = \{(-\infty, x]\}$

Теорема (Вапника-Червоненкиса)

$D_n = \sup_{B \in \mathcal{A}} |\hat{P}_n(B) - P(B)| \xrightarrow{\text{п.н.}} 0 \Leftrightarrow$ конечна VC размерность при разбиении \mathbb{R}^d множествами из \mathcal{A}

Причем, как видно, \mathcal{A} набор множеств из \mathbb{R}^d , а не обязательно из \mathbb{R}

Замечание

VC-размерность не часть курса, но на всякий случай приведено определение из дискретного анализа

(X, R) – ранжированное пространство, $R \subseteq 2^X$.

$VC(X, R) = \max\{m \mid \exists S \subset X : |S| = m, S \text{ дробится } m\}$

$S \subset X$ дробится R , если $\{S \cap r \mid r \in R\} = 2^S$

Теорема (Колмогорова-Смирнова)

$\sqrt{n}D_n \xrightarrow{d} \xi$ – распределение Колмогорова

$$F_\xi(x) = \sum_{k=-\infty}^{\infty} (-1)^k \exp(-2k^2 x^2) \mathbb{I}\{x \geq 0\}$$

I - 11.5 Метод подстановки

Пусть $X = (X_1, \dots, X_n)$ – выборка из произвольного распределения P с функцией распределения F

$\theta = G(P)$ – это то, что нам нужно оценить

$$\theta = \int_{\mathbb{R}} x dF(x)$$

Чтобы получить оценку методом подстановки нужно просто исходное распределение заменить на эмпирическое $\hat{\theta} = G(\hat{P}_n)$

Пример:

$$1) \theta = G(P) = \int_{\mathbb{R}} f(x) dF(x) \Rightarrow \hat{\theta} = \int_{\mathbb{R}} f(x) d\hat{F}_n(x) = \frac{1}{n} \sum_{i=1}^n f(X_i) = \overline{f(X)}$$

$$2) \theta = G(P) = \mathbb{D}_\theta X_1 = \int_{\mathbb{R}} x^2 dF(x) - \left(\int_{\mathbb{R}} x dF(x) \right)^2$$
$$\hat{\theta} = \overline{X^2} - (\overline{X})^2 = S^2$$

$$3) \theta = \min\{x \mid F(x) \geq \alpha\}$$
$$\hat{\theta} = \min\{x \mid \hat{F}_n(x) \geq \alpha\} = X_{(\lceil n\alpha \rceil)}$$

I - 12 Достаточные статистики и робастные оценки.

Семинар

I - 12.1 Достаточные статистики

Опр

$X_1, \dots, X_n \sim P \in \mathcal{P} = \{P_\theta \mid \theta \in \Theta\}$. Тогда статистика $S(X)$ называется достаточной, если $\forall \theta \in \Theta \forall B \in \mathfrak{B}(\mathbb{R}^d) P_\theta(X \in B \mid S(X))$ не зависит от θ

Пример:

$X_1, \dots, X_n \sim \text{Bern}(\theta) \Rightarrow S(X) = \bar{X}$ или $S(X) = \sum_{i=1}^n X_i$ – достаточные статистики

Теорема (критерий факторизации Неймана-Фишера)

Пусть $X = (X_1, \dots, X_n)$ – выборка из распределения $P \in \mathcal{P} = \{P_\theta \mid \theta \in \Theta\}$, \mathcal{P} – доминируемое распределение. Тогда

$S(X)$ – достаточная статистика $\Leftrightarrow \mathcal{L}_X(\theta) = \Psi(S(X), \theta)h(X)$

h, Ψ – измеримые функции

Замечание

Совместную плотность можно записать через правдоподобие, как и было сделано, идейно от этого ничего не поменяется

Пример:

$X_1, \dots, X_n \sim \mathcal{N}(a, \sigma^2), \theta = (a, \sigma^2)$

Нужно найти достаточную статистику

$$\begin{aligned}\mathcal{L}_X(\theta) &= (2\pi\sigma^2)^{-\frac{n}{2}} \exp\left(-\frac{1}{2\sigma^2} \sum_{i=1}^n (X_i - a)^2\right) = \\ &= (2\pi\sigma^2)^{-\frac{n}{2}} \exp\left[-\frac{\sum_{i=1}^n X_i^2}{\sigma^2} + \frac{a}{\sigma^2} \sum_{i=1}^n X_i - \frac{na^2}{2\sigma^2}\right]\end{aligned}$$

Тогда по критерию факторизации Неймана-Фишера

$S(X) = \left(\sum_{i=1}^n X_i^2, \sum_{i=1}^n X_i\right)$ – достаточная статистика

$$h(x) = 1, \Psi(S(x), \theta) = (2\pi\theta_2)^{-\frac{n}{2}} \exp\left(\frac{1}{2\theta_2} S_1 + \frac{\theta_1}{\theta_2^2} S_2 + \frac{n\theta_1^2}{2\theta_2}\right)$$

Если данные к нам приходят последовательно и в реальном времени, то легко записать формулу пересчета для порядковой статистики

$$S_{n+1}(X) = (S_{n,1}(X_1, \dots, X_n) + X_{n+1}^2, S_{n,2}(X_1, \dots, X_n) + X_{n+1})$$

Пример:

$X_1, \dots, X_n \sim \text{Exp}^*(\theta)$ (экспоненциальное распределение со сдвигом θ)

Снова нужно найти достаточную статистику

$$p_\theta(x) = e^{-(x-\theta)} I\{x \geq \theta\}$$

$$\begin{aligned} \mathcal{L}_X(\theta) &= \mathbb{I}\{X_{(1)} \geq \theta\} \exp\left(-\sum_{i=1}^n X_i + n\theta\right) = \\ &= \underbrace{\mathbb{I}\{X_{(1)} \geq \theta\}}_{\Psi(S(X), \theta)} \cdot \underbrace{\exp\left(-\sum_{i=1}^n X_i\right)}_{h(X)} \end{aligned}$$

$S(X) = X_{(1)}$ – достаточная статистика

Формула пересчета:

$$S_{n+1}(X) = \min(S_n(X_1, \dots, X_n), X_{n+1})$$

I - 12.2 Робастные оценки

Опр

Пусть $\hat{\theta} = f(X_{(1)}, \dots, X_{(n)})$. Определим K_n^* как наименьшее k , такое что:

1) Если $X_1, \dots, X_{k+1} \rightarrow -\infty$, а X_{k+2}, \dots, X_n – фиксированные, то

$$f(X_1, \dots, X_n) \rightarrow -\infty$$

2) Если $X_{n-k}, \dots, X_n \rightarrow -\infty$, а X_1, \dots, X_{n-k-1} – фиксированные, то

$$f(X_1, \dots, X_n) \rightarrow -\infty$$

Тогда величина $\tau_{\hat{\theta}} = \lim_{n \rightarrow \infty} \frac{K_n^*}{n}$ называется асимптотической толерантностью оценки $\hat{\theta}$

Пример:

$$\hat{\theta} = \sum_{i=\lfloor \ln(n) \rfloor}^{\lfloor n - \ln(n) \rfloor} X_{(i)} \Rightarrow K_n^* = 2 \ln(n). \text{ Тогда } \tau_{\hat{\theta}} = \lim_{n \rightarrow \infty} \frac{K_n^*}{n} = 0$$

Опр

Усеченным средним степени $\alpha \in (0, \frac{1}{2})$ называется оценка

$$\bar{X}_\alpha = \frac{1}{n-2k} \sum_{i=k+1}^{n-k} X_{(i)}, k = \lceil n\alpha \rceil$$

Опр

Медиана средних Уолша – это оценка

$$W = \text{median}\left(\left\{\frac{X_i + X_j}{2}, 1 \leq i \leq j \leq n\right\}\right)$$

Замечание

Как уже отмечалось, $\tau_W \approx 0.293$

Теорема

Пусть P_0 – симметричное распределение с непрерывной плотностью $p_0(x)$, а P_θ – его сдвиг на θ . Тогда

- 1) \bar{X}_α – а.н.о. θ с а.д. $\frac{2}{(1-2\alpha)^2} \left[\int_0^{u_{1-\alpha}} x^2 p_0(x) dx + \alpha u_{1-\alpha}^2 \right]$
- 2) W – а.н.о. θ с а.д. $\frac{1}{12} \left[\left(\int_{\mathbb{R}} p_0^2(x) dx \right) \right]^{-2}$

Пример:

$$X_1, \dots, X_n \sim U[\theta - 1, \theta + 1]$$

Нужно посчитать а.д. для \bar{X}_α и W

$$P_0 = U[-1, 1], p_0(x) = \frac{1}{2} I\{-1 \leq x \leq 1\}$$

$$P_\theta = U[\theta - 1, \theta + 1], p_\theta(x) = \frac{1}{2} I\{\theta - 1 \leq x \leq \theta + 1\}$$

То есть условия теоремы выше выполняются

$$u_{1-\alpha} = 1 - 2\alpha$$

$$\sigma_{\bar{X}_\alpha}^2 = \frac{2}{(1-2\alpha)^2} \left[\int_0^{1-2\alpha} \frac{x^2}{2} dx + \alpha(1-2\alpha)^2 \right] = \frac{4\alpha+1}{3}$$

$$\sigma_W^2 = \frac{1}{12} \left[\left(\int_{\mathbb{R}} \left(\frac{1}{2} I\{x \in [-1, 1]\} \right)^2 dx \right) \right]^{-2} = \frac{1}{12} \left(\int_{[-1, 1]} \frac{1}{4} dx \right)^{-2} = \frac{1}{3}$$

Также, как мы знаем, $\sigma_\mu^2 = 1$

Можно сделать вывод, что часто мы жертвуем дисперсией оценки, чтобы получить устойчивость к выбросам

I - 12.3 Приближенный поиск ОМП

Как уже обсуждалось на лекции, будем искать ноль производной логарифма правдоподобия по методу Ньютона

$$\hat{\theta}^{(k+1)} = \hat{\theta}^{(k)} - \left(\nabla^2 \ell_X(\hat{\theta}^{(k)}) \right)^{-1} \cdot \left(\nabla \ell_X(\hat{\theta}^{(k)}) \right)$$

Пример:

$$X_1, \dots, X_n \sim \text{Exp}(\theta)$$

$$p_\theta(x) = \theta^{-\theta x} \mathbb{I}\{x \geq 0\}$$

$$\mathcal{L}_X(\theta) = \theta^n \mathbb{I}\{X_{(1)} \geq 0\} \exp\left(-\theta \sum_{i=1}^n X_i\right)$$

$$\ell_X(\theta) = n \ln(n) - \theta \sum_{i=1}^n X_i$$

$$\nabla \ell_X(\theta) = \frac{n}{\theta} - \sum_{i=1}^n X_i$$

$$\nabla^2 \ell_X(\theta) = -\frac{n}{\theta^2}$$

Теперь у нас есть все, чтобы записать итерацию метода Ньютона

$$\hat{\theta}^{(k+1)} = \hat{\theta}^{(k)} - \frac{\frac{n}{\hat{\theta}^{(k)}} - \sum_{i=1}^n X_i}{-\frac{n}{(\hat{\theta}^{(k)})^2}} = \hat{\theta}^{(k)} + \hat{\theta}^{(k)} \left(1 - \hat{\theta}^{(k)} \overline{X}\right)$$

И на вопросы о начальной точке и скорости сходимости отвечает теорема

Теорема

В условиях L1-L9 если $\hat{\theta}^{(0)}$ - а.н.о. θ , то $\hat{\theta}^{(1)}$ - а.н.о. θ с а.д. $i^{-1}(\theta)$ (то есть с минимальной дисперсией)

I - 13 Бутстреп. Семинар

Лекция по бутстрепу была полностью по презентации, поэтому в конспект не вошла

I - 13.1 Эмпирическое распределение. Напоминание

Опр

$\hat{P}_n(B) = \frac{1}{n} \sum_{i=1}^n \mathbb{I}\{X_i \in B\}$ – эмпирическое распределение

$\hat{F}_n(x) = \frac{1}{n} \sum_{i=1}^n \mathbb{I}\{X_i \leq x\}$ – эмпирическая функция распределения




График 13: График эмпирической функции распределения

I - 13.2 Бутстреп

Дана выборка $X_1, \dots, X_n \sim P$, нужно оценить $T(X)$, а также $G(T(X))$

Алгоритм:

- 1) Генерируем индексы $i_1, \dots, i_n \sim U\{1, \dots, n\}$. Теперь наша новая выборка – это $X^* = (X_{i_1}, \dots, X_{i_n})$
- 2) Считаем статистику $T(X_{i_1}, \dots, X_{i_n}) = T(X^*)$
- 3) Повторяем шаги 1 и 2 B раз, получим B значений статистики
- 4) Считаем $G(T(X_j^*))$ методом Монте-Карло (используем посчитанные на бутстрепных выборках значения)

X_j^* – j -ая бутстрепная статистика из B итераций

Какая точность у такого алгоритма? У метода Монте-Карло точность $O\left(\frac{1}{\sqrt{B}}\right)$, у метода подстановки, как мы знаем из лекции, $O\left(\frac{1}{\sqrt{n}}\right)$. Тогда нужно брать $B \geq n$, чтобы не уменьшить точность.

Пример:

Пусть дана выборка 3, 5, 7, 1, 9. Нам нужно оценить дисперсию.

Мы сгенерируем как минимум 5 бутстрепных выборок. Пусть средние по этим выборкам равны: 4, 3.6, 3.8, 4.2, 5.

Тогда дисперсию мы будем считать по формуле:

$$\frac{1}{B} \sum_{b=1}^B (T_b^*)^2 - \left(\frac{1}{B} \sum_{b=1}^B T_b^* \right)^2.$$

Где T_b^* – значение среднего по соответствующей бутстрепной выборке

Замечание

Таже можем строить доверительные интервалы при помощи бутстрепа, например, квантильный.

$t = (T_1, \dots, T_B)$ – бутстрепные статистики

$\left(t_{\frac{1-\alpha}{2}}, t_{\frac{1+\alpha}{2}} \right)$ – квантильный доверительный интервал

Обсудим плюсы и минусы бутстрепа:

Плюсы:

- Прост в реализации
- Можно не использовать дельта-метод и другие сложные способы получения оценок

Минусы:

- Имеет более низкую точность, чем теоретические методы
- Может очень долго считаться. Например, при размере выборке 10^4 нужно сгенерировать 10^8 элементов.

II Проверка статистических гипотез

II - 1 Гипотезы и критерии

Пусть \mathcal{X} - выборочное пространство, \mathcal{P} - семейство распределений и $X = (X_1, \dots, X_n)$

II - 1.1 Гипотезы в непараметрическом и параметрическом случаях

Опр

Рассмотрим высказывание такого вида: $H_0 : P \in \mathcal{P}_0$, где $\mathcal{P}_0 \subseteq \mathcal{P}$. Тогда H_0 - (основная) гипотеза

Опр

Пусть $\mathcal{P} = \{P_\theta \mid \theta \in \Theta\}$ - параметрическое семейство распределений. Тогда $H_0 : \theta \in \Theta_0 \subseteq \Theta$ - гипотеза

Примеры:

- 1) \mathcal{P} - семейство всех абсолютно непрерывных распределений

$$H_0 : P \in \{\mathcal{N}(a, \sigma^2) \mid a \in \mathbb{R}, \sigma \in \mathbb{R}_+\}$$

- 2) $\mathcal{P} = \{\mathcal{N}(a, \sigma^2) \mid a \in \mathbb{R}, \sigma \in \mathbb{R}_+\}$ - семейство нормальных распределений

$$H_0 : a = 0 (\theta = (a, \sigma^2) \in \{(0, \sigma^2) \mid \sigma \in \mathbb{R}_+\})$$

II - 1.2 Проверка гипотез

Опр

Критерий для проверки гипотезы H_0 - такое множество $S \subseteq \mathcal{X}$ (подмножество реализаций выборки), для которого выполнено, что H_0 отвергается $\Leftrightarrow X \in S$

Замечание

Обычно критерий S можно представить в виде $S = \{x \in \mathcal{X} \mid T(x) > c\}$. c - какая-то константа, критическое значение критерия; $T(x)$ - статистика критерия

Результаты проверки гипотез

- 1) $X \in S \Rightarrow H_0$ отвергается и результат называется статистически значимым
2) $X \notin S \Rightarrow H_0$ не отвергается и результат не статистически значим

Смысл:

Мы можем утверждать с какой-то ошибкой, что H_0 не верна, но не можем утверждать, что H_0 верна. То есть можем отвечать только “нет” и “не знаю”.

Важно, что не можем говорить, что H_0 принимается.

Пример: Как проверить нормальность? Через моменты!

$$\mathbb{E}(X_1 - \mu_1)^3 = 0, \mathbb{E}(X_1 - \mu_1)^4 = 3\sigma^4$$

Увидим, что какой-то выборочный центральный момент не близок к теоретическому моменту нормального распределения \Rightarrow можем с большой вероятностью сказать, что распределение не нормальное, но доказать нормальность не можем

Вывод: семейство распределений бесконечно, а выборка конечна. Можем увидеть различия в типичности выборки для данного распределения, но не можем утверждать, что выборка точно из этого семейства.

Аналогия с презумпцией невиновности: обвиняемый считается невиновным, пока его вина не доказана

Обвиняемый $\longleftrightarrow P$ - распределение

Невиновность $\longleftrightarrow H_0 : P \in \mathcal{P}_0$

Виновность $\longleftrightarrow P \notin \mathcal{P}_0$

Факты/улики $\longleftrightarrow T(X)$

Вердикт $\longleftrightarrow \begin{cases} H_0 \text{ отвергается} & (X \in S) \\ H_0 \text{ не отвергается} & (X \notin S) \end{cases}$

Верность Отвергаем H_0	H_0 верна	H_0 не верна
H_0 не отвергается	☺☺	Ошибка II рода
H_0 отвергается	Ошибка I рода	☹☹

Опаснее ошибка первого рода

Опр

Вероятность ошибки I рода: $P(I_S) = \sup_{P \in \mathcal{P}_0} P(X \in S)$

Вероятность ошибки II рода: $P(II_S) = P(X \notin S)$ для $P \notin \mathcal{P}_0$

Замечание

- 1) Можно встретить определение вероятности ошибки II рода по аналогии.
- 2) На практике в вероятности ошибки I рода \sup часто опускают.

Задача на оптимизации на ошибки I, II рода

$$\begin{cases} P(I_S) \leq \alpha - \text{ограничиваем опасную ошибку} \\ P(II_S) \rightarrow \min_{P \notin \mathcal{P}_0} - \text{минимизируем по остаточному признаку} \end{cases}$$

Опр

Число $\alpha \in (0, 1)$ - уровень значимости критерия S, если $P(I_S) \leq \alpha$

Замечание

На практике обычно $\alpha = 0.05$, то есть допускаем $\leq 5\%$ ошибок I рода

Вывод:

По уровню значимости отбираем допустимые критерии ($S : P(I_S) \leq \alpha$) по \min ошибке II рода берем наилучший

Опр

Мощность критерия $\mathfrak{P}_S(p) = 1 - P(II_S) = P(X \in S)$ для $P \notin \mathcal{P}_0$

II - 1.3 Альтернативная гипотеза

Рассмотрим другую постановку задачи

$$H_0 : P \in \mathcal{P}_0 \text{ vs } H_1 : P \in \mathcal{P}_1, \text{ где } \mathcal{P}_0, \mathcal{P}_1 \subseteq \mathcal{P}, \mathcal{P}_0 \cap \mathcal{P}_1 = \emptyset$$

Опр

H_1 - альтернативная гипотеза

Рассмотрим задачу

$$\begin{cases} P(I_S) \leq \alpha \\ P(II_S) \rightarrow \min_{P \in \mathcal{P}_1} \end{cases}$$

Замечание

Альтернативная H_1 помогает выбрать лучший критерий отвержения H_0 в пользу H_1 среди допустимых. Мы не можем отвергать или принимать H_1

Если $\mathcal{P} = \{P_\theta \mid \theta \in \Theta\}$ и $H_0 : \theta = \theta_0$, то рассматриваем следующие альтернативы:

- 1) $H_1 : \theta \neq \theta_0$ - двусторонняя

2) $H_1 : \theta > \theta_0$ - правосторонняя гипотеза

3) $H_1 : \theta < \theta_0$ - левосторонняя гипотеза

Задача 1

$X \sim \text{Exp}(\theta)$, θ - интенсивность

$H_0 : \theta = \theta_0$ - изменений нет vs $H_1 : \theta > \theta_0$

$\{x > c\} \quad \{x \in (c_1, c_2)\}$

$\{x < c\} \quad \{x \leq c_1\} \cup \{x \geq c_2\}$




График 14: График плотности $\text{Exp}(\theta)$

Соображение:

Интенсивность больше \Rightarrow величина уменьшилась \Rightarrow выгоднее взять $\{x \leq c_\alpha\}$

$$P(I_S) = \sup_{\theta=\theta_0} P(X \in S) = P_{\theta_0}(x < c_\alpha) = F_{\theta_0}(c_\alpha) = 1 - e^{-c_\alpha \theta_0} \leq \alpha$$

$$e^{-c_\alpha \theta_0} \geq 1 - \alpha \Rightarrow -c_\alpha \theta_0 \geq \ln(1 - \alpha) \Rightarrow c_\alpha \leq -\frac{1}{\theta_0} \ln(1 - \alpha)$$

Выбираем c_α по max мощности:

$$\mathfrak{P}_S(\theta) = P_\theta(x < c_\alpha) = 1 - e^{-c_\alpha \theta} - \text{возрастает по } c_\alpha$$

$$\text{Тогда } c_\alpha = -\frac{1}{\theta_0} \ln(1 - \alpha)$$




График 15: График мощности $\mathfrak{P}_S = 1 - e^{-c_\alpha \theta}$

Итого получаем критерий $S = \left\{ x \in \mathcal{X} \mid x < -\frac{1}{\theta_0} \ln(1 - \alpha) \right\}$

Его мощность: $\mathfrak{P}_S(\theta) = 1 - e^{-\frac{\theta}{\theta_0} \ln(1-\alpha)} = 1 - (1 - \alpha)$

Пусть $\alpha = 0.05$, $\theta_0 = 1$ авт/час

$c \approx 0.051$ час $\Rightarrow c \approx 3$ мин

Замечание

c_α получился α -квантилем экспоненциального распределения

II - 1.4 Критерий Вальда

Опр

Критерий S - асимптотический критерий с уровнем значимости α , если

$$\lim_{n \rightarrow \infty} \sup P(I_S) = \overline{\lim}_{n \rightarrow \infty} P(I_S) \leq \alpha$$

Замечание

При каком-то конечном размере выборки $P(I_S)$ может быть больше α , но в пределе сойдется к величине $\leq \alpha$

Пусть $\mathcal{P} = \{P_\theta \mid \theta \in \Theta\}$, $\Theta \subseteq \mathbb{R}$. Пусть также $H_a : \theta = \theta_0$ - простая гипотеза. А $\hat{\theta}$ - асимптотически нормальная оценка θ с асимптотической дисперсией $\sigma^2(\theta)$

Тогда $\theta = \theta_0$, $W(X) = \sqrt{n} \frac{\hat{\theta} - \theta_0}{\hat{\sigma}} \xrightarrow{d_{\theta_0}} \mathcal{N}(0, 1)$




График 16: График квантилей нормального распределения

1) $H_1 : \theta \neq \theta_0$

$$S_1 = \{x \in \mathcal{X} \mid |W(X)| \geq Z_{1-\frac{\alpha}{2}}\}$$

2) $H'_1 : \theta > \theta_0$

$$S_2 = \{x \in \mathcal{X} \mid W(X) \geq Z_{1-\alpha}\}$$

3) $H''_1 : \theta < \theta_0$

$$S_3 = \{x \in \mathcal{X} \mid W(X) \leq Z_{\alpha}\}$$

Покажем, что S_1 контролирует асимптотическую ошибку I рода:

$$P_{\theta_0}(|W(X)| \geq Z_{1-\frac{\alpha}{2}}) = P_{\theta_0}(W(X) \leq Z_{\frac{\alpha}{2}}) + P_{\theta_0}(W(X) \geq Z_{1-\frac{\alpha}{2}}) \xrightarrow{n \rightarrow \infty} \frac{\alpha}{2} + (1 - (1 - \frac{\alpha}{2})) = \alpha$$




График 17: График мощностей для критериев S_1, S_2, S_3

Эквивалентный доверительный интервал

Возьмем $H_1 : \theta \neq \theta_0$

Для него $P(I_S) = P_{\theta_0}(|W(X)| \geq Z_{1-\frac{\alpha}{2}}) \xrightarrow{n \rightarrow \infty} \alpha$

$P_{\theta_0}(|W(X)| < Z_{1-\frac{\alpha}{2}}) \xrightarrow{n \rightarrow \infty} 1 - \alpha$

Тогда интервал Вальда $C = \left(\hat{\theta} - \frac{\hat{\sigma} Z_{1-\frac{\alpha}{2}}}{\sqrt{n}}, \hat{\theta} + \frac{\hat{\sigma} Z_{1-\frac{\alpha}{2}}}{\sqrt{n}} \right)$ уровня доверия $1 - \alpha$

Но отвергаем $\Leftrightarrow \theta_0 \notin C \Leftrightarrow X \in S$

Замечание

В случаях (2) и (3) в H_0 можем поставить $\theta \leq \theta_0$ и $\theta \geq \theta_0$ соответственно (так как супремум достигается в θ_0)

Задача 2

$X_1, \dots, X_n \sim \text{Cauchy}(\theta)$, θ - сдвиг

$H_0 : \theta = \theta_0$ vs $H_1 : \theta \neq \theta_0$

$\hat{\mu}$ - асимптотически нормальная оценка с асимптотической дисперсией $\frac{\pi^2}{4}$

$W(X) = \sqrt{n} \frac{\hat{\mu} - \theta_0}{\frac{\pi}{2}}$ - статистика критерия

$S = \{X \in \mathcal{X} \mid |W(X)| \geq Z_{1-\frac{\alpha}{2}}\}$

II - 2 Гипотезы и критерии. Семинар

Опр

X_1, \dots, X_n - выборка из распределения $P \in \mathcal{P} = \{P_\theta \mid \theta \in \Theta\}$. Есть множества $\Theta_1, \Theta_0 \subseteq \Theta$, такие что $\Theta_0 \cap \Theta_1 = \emptyset$ Тогда:

- $H_0 : \theta \in \Theta_0$ - основная гипотеза
- $H_1 : \theta \in \Theta_1$ - альтернативная гипотеза

Опр

Подмножество $S \subseteq \mathcal{X}$ - критерий для проверки H_0 , если выполнено $X \in S \Leftrightarrow H_0$ отвергается

Опр

Вероятность ошибки I рода: $P(I_S) = \sup_{P \in \mathcal{P}_0} P(X \in S)$

Вероятность ошибки II рода: $P(II_S) = P(X \notin S)$ для $P \notin \mathcal{P}_0$

Мы хотим минимизировать ошибки, но не можем сделать это одновременно

Решение:

$$\begin{cases} P(I_S) \leq \alpha \\ P(II_S) \rightarrow \min_S \end{cases}$$

α - уровень значимости / доверия, обычно $\alpha = 0.05$

Опр

$$\mathfrak{P}_S(P) = P(X \in S) = 1 - P(\Pi_S), P \notin \mathcal{P}_0$$

II - 2.1 Критерий Вальда

$X = (X_1, \dots, X_n)$ - выборка из распределения $P \in \mathcal{P} = \{P_\theta \mid \theta \in \Theta\}$

$\hat{\theta}$ - асимптотически нормальная оценка с асимптотической дисперсией σ^2

$\hat{\sigma}$ - состоятельная оценка σ

$$W = \sqrt{n} \frac{\hat{\theta} - \theta_0}{\hat{\sigma}}$$

$$H_0 : \theta = \theta_0$$

$$H_1 : \theta > \theta_0 \text{ - правосторонняя}$$

$$H_1 : \theta < \theta_0 \text{ - левосторонняя}$$

$$H_1 : \theta \neq \theta_0 \text{ - двусторонняя}$$

$$W \xrightarrow{d_{\theta_0}} \mathcal{N}(0, 1) \text{ (по лемме Служцкого и ЦПТ)}$$

$\theta > \theta_0$	$S_1 = \{W \geq Z_{1-\alpha}\}$	
$\theta < \theta_0$	$S_2 = \{W \leq Z_\alpha\}$	
$\theta_0 \neq \theta$	$S_3 = \{ W \geq Z_{1-\frac{\alpha}{2}}\}$	

Задача

$$X_1, \dots, X_n \sim \text{Pois}(\theta)$$

Нужно построить асимптотический критерий Вальда уровня доверия α для $H_0 : \theta = \theta_0, H_1 : \theta > \theta_0$

$\hat{\theta} = \bar{X}$ - асимптотически нормальная оценка с асимптотической дисперсией θ
 $\hat{\sigma}^2 = \bar{X}$

Теперь выразим статистику W

$$W = \sqrt{n} \frac{\bar{X} - \theta_0}{\sqrt{\bar{X}}} \xrightarrow{d_{\theta_0}} \mathcal{N}(0, 1)$$

$$S_1 = \left\{ \sqrt{n} \frac{\bar{X} - \theta_0}{\sqrt{\bar{X}}} \geq Z_{1-\alpha} \right\}$$

Для остальных критериев все аналогично

II - 2.2 Критерий отношения правдоподобия

Опр

$\mathcal{P} = \{P_\theta \mid \theta \in \Theta\}$ - семейство распределений с плотностью p_θ

$\mathcal{L}_X(\theta)$ - функция правдоподобия

$\Lambda_{\theta_1, \theta_2}(X) = \frac{\mathcal{L}_X(\theta_1)}{\mathcal{L}_X(\theta_2)}$ - статистика отношения правдоподобия.

Замечание

Смысл: насколько θ_1 вероятнее, чем θ_2

1. $H_0 : \theta = \theta_0$ vs $H_1 : \theta = \theta_1$ (*). Причем $\theta_0 \neq \theta_1$

Теорема Неймана-Пирсона

В случае (*), если $\exists c_\alpha : P_{\theta_0}(\Lambda_{\theta_1, \theta_0} > c_\alpha) = \alpha$, то критерий

$S = \{\Lambda_{\theta_1, \theta_0} > c_\alpha\}$ имеет максимальную мощность среди критериев с уровнем доверия α

Задача 1 Часы отстают по времени на X - выборка из одного элемента, нужно поверить часы на оригинальность.

Оригинальные отстают на $X \sim \mathcal{N}(0, 1)$, а поддельные - на $X \sim \mathcal{N}(0, 100)$

Рассмотрим распределение $\mathcal{N}(0, \theta)$. То есть рассматриваемый параметр - дисперсия

$$H_0 : \theta = 1$$

$$H_1 : \theta = 100$$

Посчитаем статистику отношения правдоподобия

$$\Lambda_{\theta_1, \theta_0} = \frac{p_{\theta_1}(X_1)}{p_{\theta_0}(X_1)} = \frac{\frac{1}{\sqrt{2\pi \cdot 100}} e^{-x^2 \frac{1}{2 \cdot 100}}}{\frac{1}{\sqrt{2\pi \cdot 1}} e^{-x^2 \frac{1}{2 \cdot 1}}} = \frac{e^{-x^2 \frac{1}{200 - \frac{1}{2}}}}{10}$$

$\Lambda_{\theta_1, \theta_0}(x)$ возрастает по $|x|$

$$P_{\theta_0} \left(\frac{e^{-x^2 \left(\frac{1}{200} - \frac{1}{2} \right)}}{10} > c_\alpha \right) = \alpha$$

Учитывая монотонность, заменим выражение под знаком вероятности




График 18: График $\Lambda_{\theta_1, \theta_0}(|X|)$

$$\exists \tilde{c}_\alpha \quad P_{\theta_0} \left(\frac{e^{-x^2 \left(\frac{1}{200} - \frac{1}{2} \right)}}{10} > c_\alpha \right) = \alpha = P_{\theta_0}(|X| > \tilde{c}_\alpha)$$

$$P_{\theta_0}(|X| > \tilde{c}_\alpha) = \alpha$$




График 19: График квантилей нормального распределения

Новый критерий эквивалентен начальному (биекция между $|x|$ и $\Lambda(x)$)

Ответ:

$$S = \left\{ |X| > Z_{1-\frac{\alpha}{2}} \right\}$$

$$S = \left\{ \Lambda_{\theta_1, \theta_0}(x) > \Lambda_{\theta_1, \theta_0}(\tilde{c}_\alpha), c_\alpha = Z_{1-\frac{\alpha}{2}} \right\}$$

2.

$$H_0 : \theta = \theta_0$$

$$H_1 : \theta > \theta_0 (\clubsuit)$$

Опр

Критерий S - равномерно наиболее мощный критерий (РНМК) уровня значимости α для проверки гипотез вида (\clubsuit) , если $\forall \mathcal{R} \subseteq \mathcal{X}$ и $\forall \theta > \theta_0$ выполнено: $\mathfrak{P}_S(\theta) \geq \mathfrak{P}_{\mathcal{R}}(\theta)$

Теорема (о монотонном отношении правдоподобия)

Пусть $\theta_1 > \theta_0$

$$\Lambda_{\theta_1, \theta_0}(X) = \frac{\mathcal{L}_X(\theta_1)}{\mathcal{L}_X(\theta_0)} = f_{\theta_1, \theta_0} \left(\underbrace{T(X)}_{\text{статистика}} \right), \text{ причем } f \text{ возрастает по аргументу}$$

Тогда $S = \{T(X) > c_\alpha\}$ - равномерно наиболее мощный критерий уровня значимости α для проверки (\clubsuit) , где $c_\alpha : P(T(X) > c_\alpha) = \alpha$

Свойства:

1) В дискретном случае вместо α рассматриваем:

$$\alpha_0 : \alpha_0 \leq \alpha, P_{\theta_0}(T(X) \geq c_{\alpha}) = \alpha_0, \alpha_0 - \text{максимальное}$$




График 20: График дискретного распределения

2) Можно рассматривать $H_0 : \theta \leq \theta_0$

3) Если рассматривать случай $H_0 : \theta = \theta_0$ vs $H_1 : \theta < \theta_0$, то $S = \{T(X) < c_\alpha\}$

4) Если f_{θ_1, θ_0} из теоремы не возрастает, а убывает, то $S = \{T(X) < c_\alpha\}$

Пример:

$f_{\theta_1, \theta_0}(T(X))$ убывает по $T(X)$ и $H_0 : \theta \geq \theta_0, H_1 : \theta < \theta_0$

Тогда $S = \{T(X) > c_\alpha\}$

Задача 2

$$X_1, \dots, X_n \sim \text{Exp}(\theta)$$

Нужно построить РНМК уровня значимости α для проверки

$$H_0 : \theta \leq \theta_0$$

$$H_1 : \theta > \theta_0$$

$$\theta_1 > \theta_0$$

$$\Lambda_{\theta_1, \theta_0}(X) = \frac{(\theta_1)^n}{(\theta_0)^n} \cdot \frac{\exp\left(-\theta_1 \sum_{i=1}^n X_i\right)}{\exp\left(-\theta_0 \sum_{i=1}^n X_i\right)} = \left(\frac{\theta_1}{\theta_0}\right)^n \exp\left((\theta_0 - \theta_1) \sum_{i=1}^n X_i\right)$$

$$T(X) = \sum_{i=1}^n X_i$$

$\Lambda_{\theta_1, \theta_0}$ убывает по $T(X)$

$$S = \left\{ \sum_{i=1}^n X_i < c_\alpha \right\}$$

$$c_\alpha : P_{\theta_0}(T(X) < c_\alpha) = \alpha$$

И, так как $\sum_{i=1}^n X_i = T(X) \sim \Gamma(\theta_0, n)$

$$c_\alpha = \gamma_\alpha - \alpha\text{-квантиль } \Gamma(\theta_0, n)$$




График 21: График квантилей $\Gamma(\theta_0, n)$

$$\text{Ответ: } S = \left\{ \sum_{i=1}^n X_i < \gamma_\alpha \right\} - \text{РНМК}$$

В питоне:

```
c_alpha = sps.gamma.ppf(alpha, a = n, scale = 1 / theta_0)
```

Задача 3

$$X_1, \dots, X_n \sim \text{Bern}(\theta)$$

Построить РНМК уровня значимости α для проверки

$$H_0 : \theta \geq \theta_0$$

$$H_1 : \theta < \theta_0$$

$$\theta_1 > \theta_2$$

$$\Lambda_{\theta_1, \theta_2}(X) = \frac{\theta_1^K (1-\theta_1)^{n-K}}{\theta_2^K (1-\theta_2)^{n-K}}, K = \sum_{i=1}^n X_i$$

$$\Lambda_{\theta_1, \theta_2}(X) = \left(\frac{1-\theta_1}{1-\theta_2} \right)^n \left(\frac{\theta_1(1-\theta_2)}{\theta_2(1-\theta_1)} \right)^K$$

$$\text{Критерий будет иметь вид } S = \left\{ \sum_{i=1}^n X_i \stackrel{?}{<} c_\alpha \right\}$$

$$c_\alpha : P_{\theta_2}(T(X) < c_\alpha) = \alpha$$

$$T(X) = \sum_{i=1}^n X_i \sim \text{Binom}(n, \theta_0)$$

Заменяем α на α_0 , для которого выполняется условие $P_{\theta_2}(T(X) < c_{\alpha_0}) = \alpha_0$ и α_0 - максимальное $\alpha_0 < \alpha$

$$c_{\alpha_0} = \begin{cases} u_\alpha, & \text{если } P_{\theta_0}\left(\sum_{i=1}^n X_i \leq u_\alpha\right) = \alpha \\ u_\alpha - 1, & \text{иначе} \end{cases}$$

Как найти c_{α_0} в питоне:

```
c_alpha0 = sps.binom(n = n, p = theta_0).ppf(alpha)
if sps.binom(n = n, p = theta_0).cdf(c_alpha0) > alpha:
    c_alpha0 -= 1
```

II - 3 Гипотезы и критерии. Повторение

II - 3.1 Гипотезы и критерии

Опр

Гипотеза:

$$H_0 : P \in \mathcal{P}_0 \subseteq \mathcal{P}$$

$$H_0 : \theta \in \Theta_0 \subseteq \Theta, \text{ а } P = P_\theta$$

Критерий:

$$S : \{x \in \mathcal{X} \mid x \in S \Leftrightarrow H_0 \text{ отвергается}\}$$

Верность Отвергаем H_0	H_0 верна	H_0 не верна
H_0 отвергается	Ошибка I рода	☹️
H_0 не отвергается	☹️	Ошибка II рода

Опр

$$P(I_S) = \sup_{P \in \mathcal{P}_0} P(X \in S), \quad P(I_S) \leq \alpha$$

$P(\Pi_S) = P(X \notin S)$ для $P \notin \mathcal{P}_0$, в случае использования альтернативной гипотезы $P \in \mathcal{P}_1$

Хотим ограничить опасную ошибку первого рода:

$$\begin{cases} P(I_S) \leq \alpha \\ P(\Pi_S) \rightarrow \min_S \end{cases}$$
$$H_0 : \theta = \theta_0 \text{ vs } \begin{cases} H_1 : \theta \neq \theta_0 \text{ двусторонняя} \\ H'_1 : \theta > \theta_0 \text{ правосторонняя} \\ H''_1 : \theta < \theta_0 \text{ левосторонняя} \end{cases}$$

$$S_1 = \{|W(X)| > Z_{1-\frac{\alpha}{2}}\}$$

$$S_2 = \{W(X) > Z_{1-\alpha}\}$$

$$S_3 = \{W(X) < Z_{\alpha}\}$$




График 22: График мощностей для критериев S_1, S_2, S_3

Опр

Мощность критерия $\mathfrak{P}_S(p) = 1 - P(\Pi_S) = P(X \in S)$ для $P \notin \mathcal{P}_0$

II - 3.2 Доверительные интервалы

$$W(X) = \sqrt{n} \frac{\hat{\theta} - \theta}{\hat{\sigma}} \xrightarrow{d} \mathcal{N}(0, 1)$$

$$\theta_0 \notin (\hat{\theta}_1, \hat{\theta}_2) \Leftrightarrow H_0 \text{ отвергается}$$

II - 4 Проверка гипотез. Семинар

II - 4.1 Оценка вероятности ошибки I рода

Опр

$$P(I_S) = \sup_{\theta \in \Theta_0} P_{\theta}(X \in S), \quad X = (X_1, \dots, X_n)$$

Проблема:

Не всегда $\alpha = P(I_S)$, например:

- Критерий может быть асимптотическим
- На практике может не выполняться какое-то условие для применения критерия

Вывод:

Хотим оценивать $P(I_S)$

Пример:

$$X_1, \dots, X_n \sim \text{Pois}(\theta)$$

$$H_0 : \theta = \theta_0 \text{ vs } H_1 : \theta \neq \theta_0$$

Запишем критерий Вальда:

$$S = \left\{ \sqrt{n} \frac{|\bar{X} - \theta_0|}{\sqrt{\bar{X}}} > Z_{1-\frac{\alpha}{2}} \right\}$$

$$P(I_S) = P_{\theta_0} \left(\sqrt{n} \frac{|\bar{X} - \theta_0|}{\sqrt{\bar{X}}} > Z_{1-\frac{\alpha}{2}} \right)$$

Оценим вероятность ошибки I рода методом Монте-Карло:

- 1) Генерируем выборки $X^{(j)} = (X_1^{(j)}, \dots, X_n^{(j)}) \sim \text{Pois}(\theta_0)$
- 2) Проверяем критерий $I_j = \mathbb{I}\{X^{(j)} \in S\}$. Повторяем для $j = 1, \dots, M$
 $I_j \sim \text{Bern}(P_{I_S})$
- 3) \bar{I} = оценка $\mathbb{E}_{\theta_0} \mathbb{I}\{X \in S\} = P_{\theta_0}(X \in S)$

Замечание

В реальных задача важно понимать, насколько $P(I_S)$ близка к α .

Возникает вопрос: “Сколько итераций Монте-Карло нужно сделать?”

Ответим на него с использованием ЦПТ

$$\gamma = P(I_S) \Rightarrow I_1, \dots, I_M \sim \text{Bern}(\gamma)$$

Применим ЦПТ:

$$\sqrt{M} \frac{\bar{I} - \gamma}{\sqrt{\gamma(1-\gamma)}} \xrightarrow{d} \mathcal{N}(0, 1)$$

С вероятностью 95% γ лежит в интервале Вальда:

$$\left(\bar{I} - Z_{0.975} \cdot \sqrt{\frac{\bar{I}(1-\bar{I})}{M}}, \bar{I} + Z_{0.975} \cdot \sqrt{\frac{\bar{I}(1-\bar{I})}{M}} \right)$$

Посмотрим, что у нас получилось:

- $Z_{0.975} \leq 2$
- $\bar{I}(1 - \bar{I}) \leq \frac{1}{4}$

Значит, $Z_{0.975} \sqrt{\bar{I}(1 - \bar{I})} \leq 1 \Rightarrow$ при $M \geq 10^6$ имеем, что $Z_{0.975} \frac{\sqrt{\bar{I}(1 - \bar{I})}}{\sqrt{M}} < 10^{-3}$

Замечание

Если γ не близка к $\alpha = 0.05$, то мы сможем это увидеть за $M \geq 10^6$ итераций.

Но если близка, то надо сделать сильно меньше итераций

Пример:

$\gamma \approx 0.05$, $M = 2 \cdot 10^5$. $\hat{\gamma} = \bar{I}$ будет лежать в интервале $(0.049, 0.051)$ с вероятностью 0.95

Замечание

Если $\gamma = 0.1$, то при $M = 2 \cdot 10^5$ оценка $\hat{\gamma}$ с вероятностью 0.95 будет лежать в интервале $(0.086, 0.114)$

Замечание

Если H_0 не точечная ($H_0 : \theta \in \Theta_0$), то можно взять несколько $\theta'_1, \dots, \theta'_r \in \Theta_0$ и оценить P_{I_S} для них

Замечание

Аналогично можно оценивать мощность: берем $\theta \in \Theta_1$ и оцениваем вероятность отвергнуть критерий

II - 4.2 Критерий χ -квадрат

$X = (X_1, \dots, X_n) \sim P$ с носителем \mathcal{X}

Рассмотрим разделение \mathcal{X} на бины:

$$\mathcal{X} = \bigsqcup_{i=1}^k B_j$$

$$\mu_j = \#\{i \mid X_i \in B_j\}$$

$$p_j^0 = P_0(X_1 \in B)$$

Рассмотрим гипотезы:

$$H_0 : P = P_0 \text{ vs } H_1 : P \neq P_0$$

Статистика: $\chi(x) = \sum_{j=1}^n \frac{(\mu_j - n \cdot p_j^0)^2}{n \cdot p_j^0} \xrightarrow{d_0} \chi_{k-1}^2$




График 23: График плотности χ^2_{k-1}

Возьмем $\alpha = 0.05$

$$S = \{\chi(X) > \chi^2_{k-1, 1-\alpha}\}$$

Задача

Есть генератор случайных чисел, нужно проверить, насколько он хороший.
Числа генерируются из $\{1, 2, 3, 4\}$

$$H_0 : P = U\{1, 2, 3, 4\} \text{ vs } H_1 : P \neq U\{1, 2, 3, 4\}$$

$$\mathcal{X} = \bigsqcup_{i=1}^4 \{i\}$$

$$B_j = \{j\}$$

$$\#1 = 249, \#2 = 254, \#3 = 246, \#4 = 251$$

$$p_j^0 = \frac{1}{4}, \mu_j = \#j$$

$$\chi(x) = \sum_{i=1}^4 \frac{(\mu_j - n \cdot p_j^0)^2}{n \cdot p_j^0} = 0.136$$

$$\chi(X) \xrightarrow{d_0} \chi^2_3$$

Ответ: $S = \{\chi(X) > \chi^2_{3, 1-\alpha}\}$

В питоне считается так:

```
sps.chi2(df = 3).ppf(1 - alpha)
```

p-value:

$$p(x) = P_{\chi^2_3}(\chi(X) > \xi) = \text{sps.chi2}(df = 3).sf(\xi) = 0.987$$

$\xi = \chi(X)$ - статистика по реализации выборки

То есть мы не отвергаем нашу гипотезу

Замечание

Вообще, в таком случае наш генератор можно считать слишком хорошим и нам может захотеться отвергать такие случаи.

В таком случае нужно брать квантили с другой стороны, важно чтобы вероятность попасть в такие области в сумме была не больше α

II - 4.3 Обобщенный критерий χ -квадрат

$X = (X_1, \dots, X_n)$ из распределения P с носителем \mathcal{X}


$$H_0 : P \in \mathcal{P}_0 \text{ vs } H_1 : P \notin \mathcal{P}_0$$

$$\mathcal{P}_0 = \{P_\theta \mid \theta \in \Theta_0\}$$

$$\hat{\chi} = \sum_{i=1}^k \frac{(\mu_j - n \cdot p_j^0(\hat{\theta}))^2}{n \cdot p_j^0}$$

Задача

Есть районы 0, 1, 2, 3, 4, 5, 6, 7, 8, 9

Кол-во семян , попавших в районы 229, 211, 93, 35, 7, 0, 0, 1, 0

$$H_0 : \overbrace{(X_1, \dots, X_n)}^X \sim \text{Pois}(\theta)$$

$$B_0 = \{0\}, B_1 = \{1\}, B_2 = \{2\}, B_3 = \{3\}, B_4 = \mathbb{N} \setminus \{0, 1, 2, 3\}$$

$$1) p_0^0(\theta) = \theta^0 e^{-\theta}$$

$$p_1^0(\theta) = \theta e^{-\theta}$$

$$p_2^0(\theta) = \frac{\theta^2}{2} e^{-\theta}$$

$$p_3^0(\theta) = \frac{\theta^3}{6} e^{-\theta}$$

$$p_4^0(\theta) = 1 - e^{-\theta} \left(1 + \theta + \frac{\theta^2}{2} + \frac{\theta^3}{6}\right)$$

$$\mu_j = \#j$$

$$2) \hat{\theta} = ?$$

$$\sum_{i=1}^4 \mu_j \ln(p_j^0(\theta)) \rightarrow \max$$

$$\hat{\theta} = 0.93$$

$$3) \chi(X) = \sum_{j=0}^4 \frac{(\mu_j - n \cdot p_j^0(\hat{\theta}))^2}{n \cdot p_j^0(\hat{\theta})} = 1.17$$

p-value: 0.759 \Rightarrow гипотеза не отвергается

II - 4.4 p-value, разбор ДЗ

Пусть $H_0 : \theta \in \Theta_0$ - основная гипотеза

S - критерий, $T(X)$ - статистика критерия

x_1, \dots, x_n - реализация выборки

$t = T(x_1, \dots, x_n)$ - реализация статистики при данной реализации выборки

Опр

p-value - вероятность при верности H_0 получить такое же значение статистики или более экстремальное




График 24: График нормального распределения и статистики W

$$\theta > \theta_0$$

$$P_{\theta_0}(T(X) \geq c_\alpha)$$

УТВ:

H_0 отвергается \Leftrightarrow p-value $\leq \alpha$

Задача 7(Автор решения: Хузин Э. Р.)

$$T(X) = \bar{X}$$

$$S = \{T(X) \leq c_\alpha\}$$

$$P\left(\sqrt{n}(\bar{X} - \theta_0) \leq \sqrt{n}(c_\alpha - \theta_0)\right) = F_{\mathcal{N}(0,1)}(\sqrt{n}(c_\alpha - \theta_0)) = \alpha$$

$$c_\alpha = \theta_0 + \frac{Z_\alpha}{\sqrt{n}}$$

$$P_\theta(X \in S) = P_\theta\left(\bar{X} \leq \theta_0 + \frac{Z_\alpha}{\sqrt{n}}\right) + P_\theta\left(\sqrt{n}(\bar{X} - \theta) \leq \sqrt{n}(\theta_0 - \theta) + Z_\alpha\right)$$

Задача 7(Решение семинариста)

$$T(X) = \sum_{i=1}^n X_i$$

$$S = \{T(X) < c_\alpha\}$$

$$c_\alpha - \alpha \text{-квантиль } \mathcal{N}(\theta_0 \cdot n, n)$$

Посчитаем p-value:

x_1, \dots, x_n - реализация выборки

$t = \sum_{i=1}^n x_i$ - реализация статистики

$$p(t) = P\left(\sum_{i=1}^n X_i \leq t\right)$$

В питоне:

```
sps.norm(a = theta_0 * n, scale = np.sqrt(n).cdf(sample.limits(sum))())
```

Задача 8

$$X_i \sim \Gamma(\theta, \beta)$$

$$\mathcal{L}_X(\theta) = \theta^{n\beta} \prod_{i=1}^n X_i^{\beta-1} e^{-\theta \sum_{i=1}^n X_i}$$

$$\sum_{i=1}^n X_i \sim \Gamma(\theta, n\beta)$$

$$\theta_2 > \theta_1$$

$$T(X) = \sum_{i=1}^n X_i$$

$$\Lambda_{\theta_2, \theta_1} = \left(\frac{\theta_2}{\theta_1}\right)^{n\beta} \exp\left(-\sum_{i=1}^n X_i(\theta_2 - \theta_1)\right) - \text{убывает по } T(X)$$

$$H_0 : \theta \geq \theta_0 \text{ vs } H_1 : \theta < \theta_0$$

$$S = \{T(X) > c_\alpha\} - \text{PHMK}$$

c_α - это $1 - \alpha$ квантиль $\Gamma(\theta_0, n\beta)$

x_1, \dots, x_n - реализация выборки

$$t = \sum_{i=1}^n x_i$$

$$p(t) = P_{\theta_0}\left(\sum_{i=1}^n x_i \geq t\right) =$$

$$= \text{sps.gamma}(a=n*b, \text{scale} = 1/\theta_0).sf(\text{sample.limits}(\text{sum}))()$$

Задача

$$H_0 : \text{часы оригинальные } P = \mathcal{N}(0, 1) \text{ vs } H_1 : \text{поддельные } P = \mathcal{N}(0, 100)$$

$$T(X) = |X|$$

$$S(X) = \{|X| > Z_{1-\frac{\alpha}{2}}\}$$

$$p(x) = P_{\theta_0}(|X| \geq 2) = P_{\mathcal{N}(0,1)}(|X| > 2) = 0.0453$$

$x = 2$ - реализация

II - 5 МПГ. Семинар

Есть m выборок $(X_{1,1}, \dots, X_{1,n_1}), \dots, (X_{m,1}, \dots, X_{m,n_m})$

Есть m пар гипотез H_1 vs H'_1, \dots, H_m vs H'_m

И есть m критериев S_1, \dots, S_m

II - 5.1 Обобщенная ошибка первого рода

Опр

- 1) $V_{P,S}(X)$ – количество верных основных гипотез, которые были отвергнуты
- 2) $R_S(X)$ – количество отвергнутых основных гипотез

Опр

Групповая ошибка I рода $\text{FWER} = P(V_{P,S}(X) > 0)$

Ожидаемая доля ложных отклонений $\text{FDR} = \mathbb{E} \frac{V_{P,S}(X)}{\max(1, R_S(X))}$

Теорема

$\text{FDR} \leq \text{FWER}$



$$\text{FDR} = \mathbb{E} \frac{V_{P,S}(X)}{\max(1, R_S(X))} = \underbrace{\mathbb{E} \frac{V_{P,S}(X)}{\max(1, R_S(X))}}_{\leq 1} \cdot \mathbb{I}\{V_{P,S}(X) > 0\} \leq$$

$$\leq \mathbb{E} 1 \cdot \mathbb{I}\{V_{P,S}(X) > 0\} = P(V_{P,S}(X) > 0) = \text{FWER}$$



Задача

Пусть $X_j = (X_{j,1}, \dots, X_{j,n_j}), j \in \{1, 2\}$

S_j – критерий для проверки гипотез H_j vs H'_j

Пусть мы знаем, что $P_j(I_{S,j}) = \alpha$

- Какие значения может принимать FWER (нужно привести примеры для крайних случаев)?
- Какое значение будет иметь FWER, если выборки являются независимыми?

1) $\text{FWER} \geq \alpha$

$$\begin{aligned}\text{FWER} &= P(V_{P,S}(X) > 0) = \\ &= P(\text{в 1 случае ошибка I рода} \vee \text{во 2 случае ошибка I рода}) \geq \\ &\geq P(\text{ошибка I рода в 1 случае}) = \alpha\end{aligned}$$

2) $\text{FWER} = 2\alpha$

$$\begin{aligned}X_1 &= X_2, H_1 = H_2, S_1 = S_2 \\ \text{FWER} &\leq P(\text{в 1 случае ошибка I рода}) + \\ &+ P(\text{во 2 случае ошибка I рода}) = 2\alpha\end{aligned}$$

Если $X_1 = X_2, H_1 = H_2, S_1 \cap S_2 = \emptyset$, то $\text{FWER} = 2\alpha$

3) Выборки независимы

$$\begin{aligned}\text{FWER} &= P_1(I_{S_1}) + P_2(I_{S_2}) - \\ &- P(\text{в 1 случае ошибка I рода} \wedge \text{во 2 случае ошибка I рода}) = \\ &= 2\alpha - P(1 \text{ случай}) \cdot P(2 \text{ случай}) = 2\alpha - \alpha^2\end{aligned}$$

Если $\alpha = 0.05$, то $\text{FWER} = 0.0975$

Вывод: случай независимости выборок – почти наихудший с точки зрения FWER, если не применить МПГ

Замечание

Цель МПГ – подобрать такие α_j , являющиеся уровнями значимости критериев(скорректированными значениями p -value), что $\text{FWER} \leq \alpha$

II - 5.2 Методы, контролирующие FWER

1) Метод Бонферрони

Скорректируем α и p -value: $\alpha_j = \frac{\alpha}{m}, \tilde{p}_j = \min(1, m \cdot p_j)$

2) Метод Холма

- Сортируем гипотезы в порядке возрастания p -value
- Идем по возрастанию p -value и берем $\alpha_j = \frac{\alpha}{m-j+1}$

Скорректированные p -value имеют вид

$$\tilde{p}_j = \min(1, \max(\tilde{p}_{j-1}, (m-j+1)p_j))$$

p_j сравниваем с α_j или \tilde{p}_j сравниваем с α

- Пока $p_j \leq \alpha_j$ ($\tilde{p}_j \leq \alpha$), отвергаем, все остальное – не отвергаем

Замечание

Если нет информации о зависимости / независимости, то метод неумлучшаем(отвергаем больше всего с контролем FWER)

3) Метод Шидака

Скорректируем $\alpha : \alpha_j = 1 - \sqrt[m]{1 - \alpha}$

Теорема

Если $S_j = \{T_j(X) \geq c_{\alpha}^j\}$ и $P(T_1 < t_1, \dots, T_m < t_m) \geq \prod_{j=1}^m P(T_j < t_j)$.

Тогда $\text{FWER} \leq \alpha$ в методе Шидака



Пусть $1, \dots, m_0$ – верные гипотезы. Знаем, что $m_0 \in \{0, 1, \dots, m\}$

$$\begin{aligned} \text{FWER} &= P(V_{P,S}(X) > 0) = P\left(\bigcup_{j=1}^{m_0} (T_j(X_j) \geq c_{\alpha,j}^j)\right) = \\ &= 1 - P\left(\bigcap_{j=1}^{m_0} (T_j(X_j) \geq c_{\alpha,j}^j)\right) \leq 1 - \prod_{j=1}^{m_0} [1 - P(T_j(X_j) \geq c_{\alpha,j}^j)] \leq \\ &\leq 1 - \prod_{i=1}^{m_0} (1 - \alpha_j) = 1 - \prod_{j=1}^{m_0} (1 - 1 + \sqrt[m]{1 - \alpha}) = 1 - (1 - \alpha)^{\frac{m_0}{m}} \leq \\ &\leq 1 - (1 - \alpha) = \alpha \end{aligned}$$



4) Методы Шидака-Холма

Процедура аналогична процедуре в методе Холма, только

$$\alpha_j = 1 - \sqrt[m-j+1]{1 - \alpha}$$

Замечание

Метод Шидака можно применять не всегда, а метод Шидака-Холма работает в случае независимых статистик критерия

Задача

Дано, что $p_1 = 0.022, p_2 = 0.041, m = 2, \alpha = 0.05$

- Бонферрони: $\tilde{p}_1 = 0.044$ – отвергаем, $\tilde{p}_2 = 0.082$ – не отвергаем
- Холм: $\tilde{p}_1 = 0.044$ – отвергаем, $\tilde{p}_2 = 0.044$ – отвергаем

Метод Бонферрони отвергает 1 раз, а метод Холма – 2 раза

Задача

Пусть X_1, \dots, X_n – выборка из распределения P

$$H_0 : P \in \mathcal{P}_0 \text{ vs } H_1 P \in \mathcal{P}_1$$

Было решено проверить гипотезы тремя различными критериями, получили следующие значения p -value : 0.0001, 0.0482, 0.7361. Какое решение об отвержении или не отвержении принять для $\alpha = 0.05$?

Решим методом Холма, скорректированные p -value следующие:
0.0003, 0.0964, 0.7361

1 из 3 критериев отвергает H_0 , однако H_0 одна на все случаи и $\text{FWER} = P(V_{P,S}(X) > 0) \leq \alpha$, то есть вероятность ошибиться хотя бы 1 раз $\leq \alpha$

Принимаем решение 1 раз $\Rightarrow \text{FWER} = P(S_{1,2,3}) \leq \alpha \Rightarrow$ можем отвергать H_0

II - 6 Гауссовская линейная модель. Статистические свойства линейной регрессии

II - 6.1 Свойства гауссовских случайных векторов

1) Пусть $\xi = (\xi_1, \dots, \xi_d) \sim \mathcal{N}(a, \Sigma)$ – гауссовский вектор, имеет плотность

$$p(x) = \frac{1}{(2\pi)^{\frac{d}{2}} \sqrt{\det \Sigma}} \exp\left(-\frac{1}{2}(x - a)^T \Sigma^{-1}(x - a)\right)$$

2) $\mathbb{E}\xi = a, \mathbb{D}\xi = \Sigma$

3) Линейная комбинация $B\xi$ гауссовского вектора ξ тоже есть гауссовский вектор, причем

$$B\xi \sim \mathcal{N}(Ba, B\Sigma B^T)$$

4) Если $\xi \sim \mathcal{N}(a, \Sigma)$, то $\Sigma^{-\frac{1}{2}}(\xi - a) \sim \mathcal{N}(0, I_d)$

5)

Теорема (об ортогональном разложении гауссовского вектора)

Пусть $\xi \sim \mathcal{N}(a, \sigma^2 I_n)$ – гауссовский случайный вектор размерности n с независимыми компонентами. Пусть также $L_1 \oplus \dots \oplus L_k = \mathbb{R}^n$ – разложение в сумму ортогональных подпространств и $\eta_j = \text{proj}_{L_j} \xi$ – проекция вектора ξ на L_j

Тогда η_1, \dots, η_k независимы в совокупности, причем

$$\mathbb{E}\eta_j = \text{proj}_{L_j}(a)$$

$$\frac{1}{\sigma^2} \|\eta_j - \mathbb{E}\eta_j\|^2 \sim \chi_d^2, d_j = \dim L_j$$

II - 6.2 Гауссовская линейная модель

$$Y = X\theta + \varepsilon, Y \in \mathbb{R}^n, X \in \mathbb{R}^{n \times d}, \theta \in \mathbb{R}^d, \varepsilon \in \mathbb{R}^n$$

Случайны: Y, ε

Константы: X

Параметры: θ

При этом $\varepsilon \sim \mathcal{N}(0, \sigma^2 I_n)$

То есть шум:

- нормальный
- несмещенный
- гомоскедастичный

Следствие: $Y \sim \mathcal{N}(X\theta, \sigma^2 I_n)$

УТВ

Пусть $\hat{\theta} = (X^T X)^{-1} X^T Y$. тогда

1) $\hat{\theta}$ и $Y - X\hat{\theta}$ независимы

2) $\frac{1}{\sigma^2} \|X\theta - X\hat{\theta}\|^2 \sim \chi_d^2$

3) $\frac{1}{\sigma^2} \|Y - X\hat{\theta}\|^2 \sim \chi_{n-d}^2$



$$L(X) = \{X\theta \mid \theta \in \mathbb{R}^d\}, \dim L(X) = d$$

$$\mathbb{R}^n = L(X) \oplus L^\perp(X)$$

$\text{proj}_{L(X)} Y = X\tilde{\theta}$, где $\tilde{\theta} = \arg \min_{\theta \in \mathbb{R}^d} \|Y - X\theta\|^2 = \hat{\theta}$, так как задача МНК

$$\text{proj}_{L^\perp(X)} Y = Y - X\hat{\theta}$$

По теореме о разложении гауссовского вектора: $X\hat{\theta}$ и $Y - X\hat{\theta}$ независимы

Также $\hat{\theta} = (X^T X)^{-1} (X^T X) \hat{\theta} = \left[(X^T X)^{-1} X^T \right] X\hat{\theta}$, то есть, $\hat{\theta}$ – линейная комбинация $X\hat{\theta} \Rightarrow \hat{\theta}$ и $Y - X\hat{\theta}$ независимы, что доказывает первый пункт

$\frac{1}{\sigma^2} \|X\hat{\theta} - \mathbb{E}X\hat{\theta}\| = \frac{1}{\sigma^2} \|X\hat{\theta} - X\theta\| \sim \chi_d^2$, что доказывает второй пункт

$$\frac{1}{\sigma^2} \|Y - X\hat{\theta} - \mathbb{E}(Y - X\hat{\theta})\|^2 = \frac{1}{\sigma^2} \|Y - X\hat{\theta}\|^2 \sim \chi_{n-d}^2$$



II - 6.3 Доверительные интервалы и критерии для параметров GLM

Замечание

Далее α – уровень значимости критерия, а $1 - \alpha$ – уровень доверия интервала

1. Доверительный интервал для σ^2

Из утверждения $\frac{1}{\sigma^2} \|Y - X\hat{\theta}\|^2 \sim \chi_{n-d}^2$

Несмещенная оценка σ^2 равна $\hat{\sigma}^2 = \frac{1}{n-d} \|Y - X\hat{\theta}\|^2$

$$\frac{(n-d)\hat{\sigma}^2}{\sigma^2} \sim \chi_{n-d}^2$$

$$P\left(\chi_{n-d, \frac{\alpha}{2}}^2 \leq \frac{(n-d)\hat{\sigma}^2}{\sigma^2} \leq \chi_{n-d, 1-\frac{\alpha}{2}}^2\right) = 1 - \alpha$$

$$P\left(\frac{(n-d)\hat{\sigma}^2}{\chi_{n-d, 1-\frac{\alpha}{2}}^2} \leq \sigma^2 \leq \frac{(n-d)\hat{\sigma}^2}{\chi_{n-d, \frac{\alpha}{2}}^2}\right) = 1 - \alpha$$

Тогда $\left(\frac{(n-d)\hat{\sigma}^2}{\chi_{n-d, 1-\frac{\alpha}{2}}^2}, \frac{(n-d)\hat{\sigma}^2}{\chi_{n-d, \frac{\alpha}{2}}^2}\right)$ – доверительный интервал для σ^2 уровня доверия $1 - \alpha$

1. Доверительный интервал для θ_j и критерий для гипотезы $H_0 : \theta_j = 0$

Замечание

Такой критерий также называется критерием о незначимости коэффициента линейной регрессии

УТВ

$$\forall c \in \mathbb{R}^d \quad \frac{c^T(\hat{\theta} - \theta)}{\hat{\sigma} \sqrt{c^T(X^T X)^{-1}c}} \sim T_{n-d}$$



$$\bullet \quad \hat{\theta} \sim \mathcal{N}(\theta, \sigma^2(X^T X)^{-1})$$

$$Y \sim \mathcal{N}(X\theta, \sigma^2 I_n)$$

$$\hat{\theta} = (X^T X)^{-1} X^T Y \Rightarrow \mathbb{E}\hat{\theta} = (X^T X)^{-1} X^T X \theta = \theta$$

$$\mathbb{D}\hat{\theta} = \left((X^T X)^{-1} \sigma^2 I_n (X(X^T X)^{-T})\right) = \sigma^2 I_n$$

$$\bullet \quad c^T \hat{\theta} \sim \mathcal{N}(c^T \theta, \sigma^2 c^T (X^T X)^{-1} c)$$

$$\bullet \quad \xi = \frac{c^T(\hat{\theta} - \theta)}{\sigma \sqrt{c^T(X^T X)^{-1}c}} \sim \mathcal{N}(0, 1)$$

$$\bullet \quad \eta = \frac{(n-d)\hat{\sigma}^2}{\sigma^2} \sim \chi_{n-d}^2$$

Осталось только показать, что $\xi \perp \eta$

ξ зависит только от $\hat{\theta}$, η только от $Y - X\hat{\theta}$, а по утверждению они независимы

$$\text{Тогда } \frac{\xi}{\sqrt{\frac{\eta}{n-d}}} = \frac{c^T(\hat{\theta}-\theta)}{\hat{\sigma}\sqrt{c^T(X^T X)^{-1}c}} \sim T_{n-d}$$



$$\text{Пусть } c_j = \left(0, \dots, 0, \underset{i}{1}, 0, \dots, 0\right)$$

$$\text{Тогда } c_j^T \theta = \theta_j$$

$$\frac{c_j^T(\hat{\theta}-\theta)}{\hat{\sigma}\sqrt{c_j^T(X^T X)^{-1}c_j}} = \frac{\hat{\theta}_j - \theta_j}{\hat{\sigma}((X^T X)^{-1}_{jj})} \sim T_{n-d} \text{ по утверждению}$$

$$P\left(\left|\frac{\hat{\theta}_j - \theta_j}{\hat{\sigma}((X^T X)^{-1}_{jj})}\right| \leq t_{n-d, 1-\frac{\alpha}{2}}\right) = 1 - \alpha$$

Тогда интервал следующий:

$\left(\hat{\theta}_j - \hat{\sigma}\sqrt{(X^T X)^{-1}_{jj}} t_{n-d, 1-\frac{\alpha}{2}}, \hat{\theta}_j + \hat{\sigma}\sqrt{(X^T X)^{-1}_{jj}} t_{n-d, 1-\frac{\alpha}{2}}\right)$ – доверительный интервал уровня доверия $1 - \alpha$ для θ_j

Для $H_0 : \theta_j = 0$

$$\text{Рассмотрим статистику } T_j^0(X, Y) = \frac{\hat{\theta}_j}{\hat{\sigma}\sqrt{(X^T X)^{-1}_{jj}}}$$

$$T_j^0(X, Y) \stackrel{H_0}{\sim} T_{n-d}$$

$$P_0(|T_j^0(X, Y)| > t_{n-d, 1-\frac{\alpha}{2}}) = \alpha$$

$S = \{|T_j^0(X, Y)| > t_{n-d, 1-\frac{\alpha}{2}}\}$ – критерий для проверки $H_0 : \theta_j = 0$ уровня значимости α

3. Доверительная область для $\theta \in \mathbb{R}^d$

Опр

Пусть $\xi \sim \chi_{k_1}^2$, $\eta \sim \chi_{k_2}^2$ и $\xi \perp \eta$

Тогда $\zeta = \frac{k_2 \xi}{k_1 \eta} = \frac{\frac{\xi}{k_1}}{\frac{\eta}{k_2}} \sim F_{k_1, k_2}$ – распределение Фишера со степенями свободы k_1, k_2

Имеем:

- $\xi = \frac{1}{\sigma^2} \|X\hat{\theta} - X\theta\|^2 \sim \chi_d^2$
- $\eta = \frac{1}{\sigma^2} \|Y - X\hat{\theta}\|^2 \sim \chi_{n-d}^2$
- ξ зависит от $X\hat{\theta}$, $\hat{\theta}$ – ЛК $X\hat{\theta}$, η зависит от $Y - X\hat{\theta}$, $\hat{\theta}$ независима с $Y - X\hat{\theta} \Rightarrow \xi \perp \eta$

Тогда $\frac{(n-d)\|X\hat{\theta}-X\theta\|}{d\|Y-X\hat{\theta}\|^2} \sim F_{k_1, k_2}$




График 25: График квантилей распределения Фишера

$$P(F(X, Y) \leq f_{d, n-d, 1-\alpha}) = 1 - \alpha$$

Тогда $\{\theta \in \mathbb{R}^d \mid F(X, Y) \leq f_{d, n-d, 1-\alpha}\}$ – доверительный эллипсоид для θ уровня доверия $1 - \alpha$

II - 7 Гауссовская линейная модель. Семинар

II - 7.1 Гауссовская линейная модель

Пусть $X \in \mathbb{R}^{n \times d}$ – признаки

Y – таргеты

Предполагаемая модель $Y = X\theta + \varepsilon$

При этом $\varepsilon \sim \mathcal{N}(0, \sigma^2 I_n)$

То есть шум:

- нормальный
- несмещенный
- гомоскедастичный

Заполним таблицу

	coeff	stderr	t	$P > t $	[0.025, 0.975]
X_j	$\hat{\theta}_j$	$\sqrt{(\hat{\sigma}^2(X^T X)^{-1})_{jj}}$	$T_j^0(X, Y)$	$P_{T_{n-d}}(T_j^0(X, Y) \geq T_{n-d, 1-\frac{\alpha}{2}})$	$\hat{\theta}_j \pm T_{n-d, 1-\frac{\alpha}{2}} \cdot \hat{\sigma} \sqrt{(X^T X)^{-1}_{jj}}$

1) $\hat{\theta}_j$

$$\hat{\theta} = (X^T X)^{-1} X^T Y, \hat{\theta} \sim \mathcal{N}(\theta, \sigma^2 (X^T X)^{-1})$$

2) Оценка дисперсии ошибки:

$$\hat{\sigma}^2 = \frac{1}{n-d} \|Y - X\theta\|_2^2$$

3) Оценка дисперсии коэффициентов:

$$\frac{1}{n-d} \|Y - X\theta\|_2^2 (X^T X)^{-1}$$

$\hat{\sigma}^2$

4) T -статистика для коэффициента $\hat{\theta}_j$

$$T_j^0(X, Y) = \frac{\hat{\theta}_j - \theta_j}{\hat{\sigma} \sqrt{(X^T X)^{-1}_{jj}}} \sim T_{n-d}$$

$$H_0 : \theta_j = 0$$

$$T_j^0(X, Y) \stackrel{H_0}{=} \frac{\hat{\theta}_j}{\hat{\sigma} \sqrt{(X^T X)^{-1}_{jj}}} \stackrel{H_0}{\sim} T_{n-d}$$

5) Критерий для проверки H_0 :

$$S = \{|T_j^0(X, Y)| > T_{n-d, 1-\frac{\alpha}{2}}\}$$

6) p -value

$$p(t) = P_{T_{n-d}}(|T_j^0(X, Y)| \geq t)$$

7) Доверительный интервал

$$P(|T_j^0(X, Y)| < T_{n-d, 1-\frac{\alpha}{2}}) = 1 - \alpha$$

$$(\hat{\theta}_j - T_{n-d, 1-\frac{\alpha}{2}} \hat{\sigma} \sqrt{(X^T X)^{-1}_{jj}}, \hat{\theta}_j + T_{n-d, 1-\frac{\alpha}{2}} \hat{\sigma} \sqrt{(X^T X)^{-1}_{jj}})$$

II - 7.2 Общий случай линейных гипотез

Опр

$$H_0 : T\theta = \tau, T \in \mathbb{R}^{k \times d}, \tau \in \mathbb{R}^k, \tau = \text{const}, k \leq d$$

Гипотезы такого вида называются линейными

Пример:

$$H_0 = \begin{cases} \theta_1 = 0 \\ \theta_2 = \theta_3 \Leftrightarrow \theta_2 - \theta_3 = 0 \end{cases}$$

$$\theta = \begin{pmatrix} \theta_1 \\ \theta_2 \\ \theta_3 \end{pmatrix}, T = \begin{pmatrix} 1 & 0 & 0 & 0 & \dots & 0 \\ 0 & 1 & -1 & 0 & \dots & 0 \end{pmatrix}, \tau = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$$

1) Строим критерий

$$\hat{\theta} \sim \mathcal{N}(\theta, \sigma^2 (X^T X)^{-1})$$

$$\hat{t} = T\hat{\theta} \sim \mathcal{N}\left(\underbrace{T\theta}_{\tau(H_0)}, \underbrace{\sigma^2 (T(X^T X)^{-1} T^T)}_B\right)$$

$$\frac{B^{-\frac{1}{2}}(\hat{t} - \tau)}{\sigma} \stackrel{H_0}{\sim} \mathcal{N}(0, I_k)$$

$$\frac{(\hat{t} - \tau)^T B^{-1}(\hat{t} - \tau)}{\sigma^2} = \left(\frac{B^{-\frac{1}{2}}(\hat{t} - \tau)}{\sigma} \right)^T \cdot \frac{B^{-\frac{1}{2}}(\hat{t} - \tau)}{\sigma} = \sum_{i=1}^k z_i^2, z_i - \text{координаты вектора}$$

$$\frac{B^{-\frac{1}{2}}(\hat{t} - \tau)}{\sigma}$$

$$\sum_{i=1}^k z_i^2 \stackrel{H_0}{\sim} \chi_k^2, \text{ так как } z_i \stackrel{H_0}{\sim} \mathcal{N}(0, 1)$$

$$\sum_{i=1}^k z_i^2 \text{ зависит от } \hat{\theta}$$

Величина

$$\frac{1}{\sigma^2} \|Y - X\hat{\theta}\|_2^2 \sim \chi_{n-d}^2 \text{ не зависит от } \hat{\theta}$$

$$\text{Тогда } F(X, Y) = \frac{(\hat{t} - \tau)^T B^{-1}(\hat{t} - \tau)}{\|Y - X\hat{\theta}\|_2^2} \cdot \frac{n-d}{k} \sim F_{k, n-d}$$

Теперь построим критерий уровня значимости α , используя распределение Фишера

$$S = \{F(X, Y) > f_{k, n-d, 1-\alpha}\}$$

Задача

$$X_1, \dots, X_n \sim \mathcal{N}((\theta_1, \dots, \theta_1), \sigma^2 I_n)$$

$$Y_1, \dots, Y_m \sim \mathcal{N}((\theta_2, \dots, \theta_2), \sigma^2 I_m)$$

$$X_i = \theta_1 + \varepsilon_i$$

$$Y_i = \theta_2 + \varepsilon_i$$

Мы хотим проверить гипотезу $H_0 : \theta_1 = \theta_2$

Сведем к GLM:

$$W = \begin{pmatrix} X_1 \\ \dots \\ X_n \\ Y_1 \\ \dots \\ Y_m \end{pmatrix}$$

$$Z = \begin{pmatrix} 1 & 0 \\ \vdots & \vdots \\ 1 & 0 \\ 0 & 1 \\ \vdots & \vdots \\ 0 & 1 \end{pmatrix}$$

Размер матрицы $(n + m) \times 2$

$$W = Z\theta + \varepsilon - \text{GLM}$$

$$\theta = \begin{pmatrix} \theta_1 \\ \theta_2 \end{pmatrix}$$

$$\varepsilon \sim \mathcal{N}(0, \sigma^2 I_{n+m})$$

$$\boxed{k = 1}$$

$$T\theta = \tau$$

$$T = \begin{pmatrix} 1 & -1 \end{pmatrix}$$

$$\tau = 0$$

$$\text{GLM: } Y = X\theta + \varepsilon$$

$$Z^T Z = \begin{pmatrix} n & 0 \\ 0 & m \end{pmatrix}$$

$$B = \frac{1}{n} + \frac{1}{m}$$

$$(Z^T Z)^{-1} = \begin{pmatrix} \frac{1}{n} & 0 \\ 0 & \frac{1}{m} \end{pmatrix}$$

$$\hat{t} = T\hat{\theta} = T(Z^T Z)^{-1} Z^T W = \bar{X} - \bar{Y}$$

$$\hat{\theta} = \begin{pmatrix} \bar{X} \\ \bar{Y} \end{pmatrix}$$

Выпишем статистики из предыдущей задачи:

$$\frac{(\hat{t} - \tau)^T B^{-1} (\hat{t} - \tau)}{\sigma^2} = \frac{(\bar{X} - \bar{Y})^T (\frac{1}{n} + \frac{1}{m})^{-1} (\bar{X} - \bar{Y})}{\sigma^2} = \frac{(\bar{X} - \bar{Y})^2}{(\frac{1}{n} + \frac{1}{m}) \sigma^2} \sim \chi_1^2$$

$$\|W - Z\hat{\theta}\|_2^2 = \|X - \hat{\theta}_1\|^2 + \|Y - \hat{\theta}_2\|^2 = n\hat{S}_X^2 + m\hat{S}_Y^2$$

Распишем отдельно каждую из компонент:

$$\frac{\|X - \hat{\theta}_1\|^2}{\sigma^2} \sim \chi_{n-1}^2$$

$$\frac{\|Y - \hat{\theta}_2\|^2}{\sigma^2} \sim \chi_{m-1}^2$$

$$\text{Значит, } \frac{\|W - Z\hat{\theta}\|^2}{\sigma^2} \sim \chi_{n+m-2}^2$$

$$F(Z, W) = \frac{(\bar{X} - \bar{Y})^2 (n+m-2)}{\left(\frac{1}{n} + \frac{1}{m}\right) (n\hat{S}_X^2 + m\hat{S}_Y^2)} \sim F_{1, n+m-2}$$

$$S_F = \{F_{Z,W} > f_{1, n+m-2, 1-\alpha}\}$$

$$\sqrt{\frac{(\bar{X} - \bar{Y})^2}{\left(\frac{1}{n} + \frac{1}{m}\right) \sigma^2}} \sim \mathcal{N}(0, 1)$$

$$T(Z, W) = \frac{(\bar{X} - \bar{Y}) \sqrt{n+m-2}}{\sqrt{\frac{1}{n} + \frac{1}{m}} \sigma \sqrt{n\hat{S}_X^2 + m\hat{S}_Y^2}} \sim T_{n+m-2}$$

$$S_T = \{|T(Z, W)| > t_{n+m-2, 1-\frac{\alpha}{2}}\}$$

II - 8 Подсчет информации Фишера для частных случаев GLM

II - 8.1 Логистическая регрессия

$X_1, \dots, X_n \in \mathbb{R}^d$ – векторы признаков

$Y_1, \dots, Y_n \in \{0, 1\}$ – классы

$$\mu_\theta(x) = \frac{1}{1 + e^{x^\top \theta}}, Y_i \sim \text{Bern}(\mu_\theta(X_i))$$

Запишем функцию правдоподобия

$$\mathcal{L}_X(\theta) = \prod_{i=1}^n \mu_\theta(X_i)^{Y_i} (1 - \mu_\theta(X_i))^{1-Y_i} = \prod_{i=1}^n \sigma(X_i^\top \theta)^{Y_i} (1 - \sigma(X_i^\top \theta))^{1-Y_i}$$

$$\ell_Y = \sum_{i=1}^n (Y_i \ln(X_i^\top \theta) + (1 - Y_i) \ln(1 - \sigma(X_i^\top \theta)))$$

$$\begin{aligned} \nabla \ell_Y(\theta) &= \sum_{i=1}^n \frac{Y_i \sigma(X_i^\top \theta) (1 - \sigma(X_i^\top \theta))}{\sigma(X_i^\top \theta)} X_i + (1 - Y_i) \frac{\sigma(X_i^\top \theta) (1 - \sigma(X_i^\top \theta))}{1 - \sigma(X_i^\top \theta)} (-X_i) = \\ &= \sum_{i=1}^n (Y_i X_i - Y_i X_i \sigma(X_i^\top \theta) - X_i \sigma(X_i^\top \theta) + Y_i X_i \sigma(X_i^\top \theta)) = \sum_{i=1}^n X_i (Y_i - \sigma(X_i^\top \theta)) = \\ &= X^\top (Y - S(\theta)) \end{aligned}$$

$$S(\theta) = \begin{pmatrix} \sigma(X_1^\top \theta) \\ \dots \\ \sigma(X_n^\top \theta) \end{pmatrix}$$

Найдем гессиан

$$\begin{aligned}\nabla^2 \ell_Y(\theta) &= \nabla \sum_{i=1}^n X_i (Y_i - \sigma(X_i^\top \theta)) = - \sum_{i=1}^n X_i \sigma(X_i^\top \theta) (1 - \sigma(X_i^\top \theta)) X_i^\top = \\ &= X^T V(\theta) X\end{aligned}$$

$$V(\theta) = \text{diag}([\sigma(X_i^\top \theta), 1 - \sigma(X_i^\top \theta)]_{i=1}^n)$$

$$I_Y(\theta) = \left(-\mathbb{E}_\theta \frac{\partial^2 \ell_Y(\theta)}{\partial \theta_j \partial \theta_k} \right)_{j=1, k=1}^{d, d} = -\nabla^2 \ell_Y(\theta), \text{ так как } \nabla^2 \ell_Y(\theta) \text{ не зависит от } Y, \text{ то}$$

есть константа

Доверительный интервал тогда будет иметь вид

$$\theta_j \in \left(\hat{\theta}_j - Z_{1-\frac{\alpha}{2}} \sqrt{I_Y^{-1}(\theta)_{jj}}, \hat{\theta}_j + Z_{1-\frac{\alpha}{2}} \sqrt{I_Y^{-1}(\theta)_{jj}} \right)$$

II - 8.2 Пуассоновская регрессия

$$X_1, \dots, X_n \in \mathbb{R}^d, Y_1, \dots, Y_n \in \mathbb{N}_0$$

$$\mu_\theta(x) = e^{x^\top \theta}, Y_i \sim \text{Pois}(\mu_\theta(X_i))$$

Распишем функцию правдоподобия

$$\mathcal{L}_Y(\theta) = \prod_{i=1}^n \frac{\mu_\theta(X_i)^{Y_i}}{Y_i!} e^{-\mu_\theta(X_i)} = \prod_{i=1}^n \frac{e^{X_i^\top \theta Y_i}}{Y_i!} \exp(e^{-X_i^\top \theta})$$

$$\ell_Y(\theta) = \sum_{i=1}^n (X_i^\top \theta Y_i - \ln(Y_i!)) - e^{X_i^\top \theta}$$

$$\nabla \ell_Y(\theta) = \sum_{i=1}^n Y_i X_i - e^{X_i^\top \theta} X_i = X^T (Y - E(\theta))$$

$$E(\theta) = \begin{pmatrix} e^{X_1^\top \theta} \\ \vdots \\ e^{X_n^\top \theta} \end{pmatrix}$$

$$\nabla^2 \ell_Y(\theta) = - \sum_{i=1}^n X_i e^{X_i^\top \theta} X_i = -X^T \text{diag}(E(\theta)) X$$

$$I_Y(\theta) = -\nabla^2 \ell_Y(\theta), \text{ так как } \nabla^2 \ell_Y(\theta) \text{ не зависит от } Y, \text{ то есть - константа}$$

II - 8.3 Линейная регрессия

$$\theta_j \in \left(\hat{\theta}_j \pm Z_{1-\frac{\alpha}{2}} \sqrt{I_Y^{-1}(\theta)_{jj}} \right) - \text{асимптотический доверительный интервал}$$

$$\theta_j \in \left(\hat{\theta}_j \pm t_{n-d, 1-\frac{\alpha}{2}} \sigma \sqrt{X^\top X_{jj}^{-1}} \right) - \text{точный доверительный интервал}$$

$$I_Y(\theta) = \frac{1}{\sigma^2} X^T X$$

II - 9 Калибровка. Семинар

II - 9.1 Калибровка. Определение

Решаем задачу бинарной классификации.

$X_1, \dots, X_n \in \mathbb{R}^d$ – признаки

$Y_1, \dots, Y_n \in \{0, 1\}$ – классы

Пусть \hat{p} – модель, которая выдает вероятность $\hat{p}(x)$ того, что объект x принадлежит классу 1

Опр

Модель \hat{p} идеально скалибрована, если выполнено $\forall \rho$, предсказанного моделью $P(Y = 1 \mid \hat{p}(x) = \rho) = \rho$

Замечание

Смысл: если модель дает объекту x вероятность $\frac{2}{3}$, то среди всех таких объектов x , что $\hat{p}(x) = \frac{2}{3}$ будут действительно из класса 1

II - 9.2 Калибровочная кривая

Замечание

В реальности модель разным x_i дает разные вероятности, поэтому есть некоторые проблемы с оценкой вероятности из определения (вероятность не будет равно ρ)

Решение:

Рассмотрим разбиение $[0, 1] = \bigsqcup_{j=1}^k B_j$

$$B_j = [\xi_{j-1}, \xi_j), B_k = [\xi_{k-1}, 1],$$

$$0 < \xi_0 < \xi_1 < \dots < \xi_n = 1$$

$$\hat{p}_j = \frac{1}{\#B_j} \sum_{\hat{p}(x) \in B_j} \hat{p}(x) \text{ (выдача модели)}$$

$$p_j = \frac{1}{\#B_j} \# \{ \hat{p}(x) \in B_j \mid y = 1 \} \text{ (реальные метки)}$$




График 26: Модель с идеальной калибровкой

Пример:

i

1, 2, 3, 4, 5, 6, 7, 8, 9, 10

\hat{p}

0.1, 0.15, 0.2, 0.4, 0.6, 0.8, 0.85, 0.9, 0.9, 0.95

Y_i

$0, 0, 1, 0, 0, 1, 0, 1, 1, 1$

$B_1 = [0, 0.4), B_2 = [0.4, 0.85), B_3 = [0.85, 1]$

$\hat{p}_1 = 0.15, \hat{p}_2 = 0.6, \hat{p}_3 = 0.9$

$p_1 = \frac{1}{3}, p_2 = \frac{1}{3}, p_3 = \frac{3}{4}$




График 27: Калибровочная кривая №1

Пример:




График 28: Калибровочная кривая №2

Делаем бинарную классификацию с порогом $\frac{1}{2}$

Пример:




График 29: Калибровочная кривая №3

Слишком уверенный классификатор

Пример:




График 30: Калибровочная кривая №4

Слишком неуверенный классификатор

II - 9.3 Метрики калибровки

1) Expected calibration error (ECE)

$$\text{ECE} = \sum_{j=1}^k \frac{\#B_j}{n} |p_j - \hat{p}_j|$$

2) Brier score (BS)

$$\text{BS} = \sum_{i=1}^n (y_i - \hat{p}(x_i))^2$$

$$\widetilde{\text{BS}} = \sum_{i=1}^n y_i \ln \hat{p}(x_i) + (1 - y_i) \ln(1 - \hat{p}(x_i))$$

II - 9.4 Методы калибровки

1) Гистограммная калибровка

- Разбиваем на бины
- Меняем предсказания в конкретном бине B_j (то есть меняем \hat{p} в бине)

$$\hat{p}_j = \underset{\rho}{\operatorname{argmin}} \sum_{\hat{p}(x) \in B_j} (y(x) - \rho)^2 = p_j$$

- Проблема: использовали бины

2) Изотоническая регрессия

- Аналогично гистограммной калибровке, только теперь подбираем трешхолды для бинов:

$$\min_{\substack{0 \leq t_1 \leq \dots \leq t_{k-1} \leq 1 \\ 0 \leq \rho_1 \leq \dots \leq \rho_k \leq 1}} \sum_{i=1}^n (y_i - g_{\rho_i, t}(x_i))^2$$

t_1, \dots, t_{k-1} – пороги для бинов

$$g_{\rho_i, t}(x_i) = \sum_{j=1}^k \rho_j \cdot \mathbb{I}\{\hat{p}(x_i) \in [t_{j-1}, t_j)\}$$

3) Калибровка Платта

- Применим сигмоиды поверх нашей модели (то есть к выходам \hat{p}):

$$\rho(x_i) = \frac{1}{1 + e^{-a\hat{p}(x_i) - b}}$$

a, b получаем, минимизируя логлосс по выборке

II - 10 Информация Фишера

Пусть $X = (X_1, \dots, X_n) \sim P \in \mathcal{P} = \{P_\theta \mid \theta \in \Theta\}$, где \mathcal{P} – доминируемое семейство с плотностью $p_\theta(x)$

$$\ell_X(\theta) = \ln \mathcal{L}_X(\theta) = \ln \left(\prod_{i=1}^n p_\theta(X_i) \right) = \sum_{i=1}^n \ln p_\theta(X_i)$$

Опр

$U_X(\theta) = \frac{\partial \ell_X(\theta)}{\partial \theta}$ – вклад выборки X в оценку θ

Опр

$I_X(\theta) = \mathbb{D}_\theta U_X(\theta)$ – информация Фишера выборки X о параметре θ

Пример:

$X_1, \dots, X_n \sim \text{Bern}(\theta)$

$$\mathcal{L}_X(\theta) = \theta^{\sum_{i=1}^n X_i} (1 - \theta)^{n - \sum_{i=1}^n X_i}$$

$$\ell_X(\theta) = \left(\sum_{i=1}^n X_i \right) \ln \theta + \left(n - \sum_{i=1}^n X_i \right) \ln(1 - \theta)$$

$$U_X(\theta) = \frac{\partial \ell_X(\theta)}{\partial \theta} = \sum_{i=1}^n X_i \cdot \frac{1}{\theta} - \left(n - \sum_{i=1}^n X_i \right) \cdot \frac{1}{1 - \theta} = \frac{\sum_{i=1}^n X_i - n\theta}{\theta(1 - \theta)}$$

$$I_X(\theta) = \mathbb{D} \left(\frac{\sum_{i=1}^n X_i - n\theta}{\theta(1 - \theta)} \right) = \frac{\sum_{i=1}^n \mathbb{D} X_i}{\theta^2(1 - \theta)^2} = \frac{n\theta(1 - \theta)}{\theta^2(1 - \theta)^2} = \frac{n}{\theta(1 - \theta)}$$




График 31: Информация Фишера

Теорема

В условиях регулярности E1-E4 выполняется следующее:

- 1) $\mathbb{E}_\theta U_X(\theta) = 0$
- 2) $I_X(\theta) = \mathbb{E}_\theta U_X^2(\theta)$
- 3) $I_X(\theta) = ni(\theta)$, где $i(\theta)$ – информация Фишера одного элемента
- 4) $I_X(\theta) = -\mathbb{E} \frac{\partial^2 \ell_X(\theta)}{\partial \theta^2}$



1)

$$U_X(\theta) = \frac{\partial}{\partial \theta} \left(\sum_{i=1}^n \ln p_\theta(X_i) \right) = \sum_{i=1}^n \frac{\ln p_\theta(X_i)}{\partial \theta} = \sum_{i=1}^n U_{X_i}(\theta)$$

$$\begin{aligned} \forall i = 1, \dots, n \quad \mathbb{E}_\theta U_{X_i}(\theta) &= \mathbb{E} \frac{\partial \ln p_\theta(X_i)}{\partial \theta} = \int_{\mathbb{R}^d} p_\theta(x) \frac{\partial \ln p_\theta(x)}{\partial \theta} dx = \\ &= \int_{\mathbb{R}^d} \frac{p_\theta(x)}{p_\theta(x)} \frac{\partial}{\partial \theta} p_\theta(x) dx = \int_{\mathbb{R}^d} \frac{\partial}{\partial \theta} p_\theta(x) dx = \\ &= \frac{\partial}{\partial \theta} \int_{\mathbb{R}^d} p_\theta(x) dx = \frac{\partial}{\partial \theta} 1 = 0 \end{aligned}$$

2)

$$I_X(\theta) = \mathbb{D}U_X(\theta) = \mathbb{E}U_X^2(\theta) - (\mathbb{E}U_X(\theta))^2 = \mathbb{E}U_X^2(\theta)$$

3)

$$\begin{aligned} I_X(\theta) &= \mathbb{D}U_X(\theta) = \mathbb{D} \sum_{i=1}^n U_{X_i}(\theta) = \sum_{i=1}^n \mathbb{D}U_{X_i}(\theta) = n\mathbb{D}U_{X_1}(\theta) = \\ &= nI_{X_1}(\theta) = ni(\theta) \end{aligned}$$

4)

$$\begin{aligned} \frac{\partial^2 \ln p_\theta(x)}{\partial \theta^2} &= \frac{\partial}{\partial \theta} \left(\frac{\frac{\partial p_\theta(x)}{\partial \theta}}{p_\theta(x)} \right) = \frac{\frac{\partial^2 p_\theta(x)}{\partial \theta^2}}{p_\theta(x)} - \frac{\left(\frac{\partial p_\theta(x)}{\partial \theta} \right)^2}{p_\theta^2(x)} \Rightarrow \frac{\partial^2 \ell_X(\theta)}{\partial \theta^2} = \\ &= \sum_{i=1}^n \left(\frac{\frac{\partial^2 p_\theta(X_i)}{\partial \theta^2}}{p_\theta(X_i)} - \frac{\left(\frac{\partial p_\theta(X_i)}{\partial \theta} \right)^2}{p_\theta^2(X_i)} \right) \\ \mathbb{E} \frac{\partial^2 \ln p_\theta(x)}{\partial \theta^2} &= \int_{\mathbb{R}^d} \left(\frac{\frac{\partial^2 p_\theta(x)}{\partial \theta^2}}{p_\theta(x)} - \frac{\left(\frac{\partial p_\theta(x)}{\partial \theta} \right)^2}{p_\theta^2(x)} \right) p_\theta(x) dx = \frac{\partial^2}{\partial \theta^2} \int_{\mathbb{R}^d} p_\theta(x) dx - I_{X_i}(\theta) = \\ &= -I_{X_i}(\theta) \\ \text{Тогда } \mathbb{E} \frac{\partial^2 \ln p_\theta(x)}{\partial \theta^2} &= \mathbb{E} \frac{\partial^2 \sum_{i=1}^n \ln p_\theta(X_i)}{\partial \theta^2} = \sum_{i=1}^n \mathbb{E} \frac{\partial^2 \ln p_\theta(X_i)}{\partial \theta^2} = -\sum_{i=1}^n I_{X_i}(\theta) = -I_X(\theta) \end{aligned}$$



II - 11 Энтропия и дивергенция

II - 11.1 1. Дискретный случай

Рассмотрим случай с носителем $\{a_1, \dots, a_k\}$ и вероятностями $\{p_1, \dots, p_k\}$

Замечание

$$0 \ln 0 = 0$$

Опр

$$H(P) = - \sum_{j=1}^k p_j \ln p_j - \text{энтропия}$$

$$H(P, Q) = - \sum_{j=1}^k p_j \ln q_j - \text{кросс-энтропия}$$

$$\text{KL}(P, Q) = H(P, Q) - H(P) = \sum_{j=1}^k p_j \ln \frac{p_j}{q_j} - \text{дивергенция Кульбака — Лейблера}$$

Свойства энтропии:

- 1) $H(P) \geq 0$, при этом $H(P) = 0 \Leftrightarrow P$ – вырожденное

$$0 \leq p_j \leq 1 \Rightarrow \ln p_j \leq 0 \Rightarrow H(P) \geq 0$$

Равенство достигается тогда и только тогда, когда $\forall j \ p_j \ln p_j = 0$

Так как p_j – это вероятности из категориального распределения, то $\exists j' \ p_{j'} = 1$, а остальные равны 0

В обратную сторону очевидно: $\ln p_{j'} = 0$ иначе $p_j = 0$

- 2) $H(P) \leq \ln k$, равенство достигается при $p_1 = \dots = p_k = \frac{1}{k}$

Пусть ξ – случайная величина из распределения P

Тогда

$$\begin{aligned} H(P) &= -\sum_{j=1}^k p_j \ln p_j = -\mathbb{E} \ln p(\xi) = \mathbb{E} \ln \frac{1}{p(\xi)} \leq \ln \mathbb{E} \frac{1}{p(\xi)} = \\ &= \ln \left(\sum_{j=1}^k p_j \frac{1}{p_j} \right) = \ln k \end{aligned}$$

Равенство достигается при $p_1 = \dots = p_k = \frac{1}{k}$

II - 11.2 2. Общий случай

Пусть P, Q – распределения на одном и том же вероятностном пространстве $\xi \sim P$

Опр

$H(P) = -\mathbb{E} \ln p(\xi)$ – энтропия

$H(P, Q) = -\mathbb{E} \ln q(\xi)$ – кросс-энтропия

$KL(P, Q) = H(P, Q) - H(P) = \mathbb{E} \ln \frac{p(\xi)}{q(\xi)}$ – дивергенция Кульбака–Лейблера

Свойства KL дивергенции:

- 1) $KL(P, Q) \geq 0$ при этом $KL(P, Q) = 0 \Leftrightarrow P = Q$

$$-KL(P, Q) = \mathbb{E} \ln \frac{q(\xi)}{p(\xi)} \stackrel{\text{Йенсен}}{\leq} \ln \mathbb{E} \frac{q(\xi)}{p(\xi)} = \ln \int_{\mathcal{X}} p(x) \frac{q(x)}{p(x)} dx = \ln 1 = 0$$

Тогда $KL(P, Q) \geq 0$

- 2) $KL(P, Q) \neq KL(Q, P)$ в общем случае

- 3) Пусть $\mathcal{P} = \{P_\theta \mid \theta \in \Theta\}$ – семейство дискретных распределений и \hat{P}_n – эмпирическая функция распределения P_θ

Тогда

$$\begin{aligned} \text{KL}(\hat{P}_n, P_\theta) &= \mathbb{E}_{\hat{P}_n} = \mathbb{E}_{\hat{P}_n} \ln \frac{\hat{p}_n(X_i)}{p_\theta(X_i)} = \sum_{i=1}^n \frac{1}{n} \ln \frac{\frac{1}{n}}{p_\theta(X_i)} = \\ &= -\ln n - \frac{1}{n} \sum_{i=1}^n \ln p_\theta(X_i) = -\frac{\ell_X(\theta)}{n} - \ln n \end{aligned}$$

Тогда $\text{KL}(\hat{P}_n, P_\theta) \rightarrow \min_{\theta} \Leftrightarrow \ell_X(\theta) \rightarrow \max_{\theta}$

4) Пусть $\|\theta_1 - \theta_2\| \rightarrow 0$

Тогда $\text{KL}(P_{\theta_1}, P_{\theta_2}) = \frac{1}{2}(\theta_1 - \theta_2)^\top i(\theta)(\theta_1 - \theta_2) + o(\|\theta_1 - \theta_2\|^2)$

Разложим KL в окрестности θ_1 по $\theta_2 - \theta_1$

$$\begin{aligned} \text{KL}(P_{\theta_1}, P_{\theta_2}) &= \text{KL}(P_{\theta_1}, P_{\theta_1}) + (\theta_2 - \theta_1)^\top \nabla_{\delta} \text{KL}(P_{\theta_1}, P(\theta_1 + \delta)) \big|_{\delta=0} + \\ &+ (\theta_2 - \theta_1)^\top \nabla_{\delta}^2 \text{KL}(P_{\theta_1}, P_{\theta_1+\delta})(\theta_2 - \theta_1) \big|_{\delta=0} + o(\|\theta_1 - \theta_2\|^2) \end{aligned}$$

- $\text{KL}(P_{\theta_1}, P_{\theta_2}) = 0$
- $\text{KL}(P_{\theta_1}, P_{\theta_1+\delta}) = \nabla_{\theta_1} \text{KL}(P_{\theta_1}, P_{\theta_1}) = 0$, так как

$\forall f \in C^1(\mathcal{X})$ выполнено

$$\frac{df(x+y)}{dy} \big|_{y=0} = [z = x+y] = \frac{df(z)}{dz} \big|_{z=x} \cdot \frac{dz}{dy} \big|_{y=0} = \frac{df(z)}{dz} \big|_{z=x}$$

$$\begin{aligned} \cdot \quad \nabla_{\delta}^2 \text{KL}(P_{\theta_1}, P_{\theta_1+\delta}) \big|_{\delta=0} &= \left(\nabla_{\delta}^2 \int_{\mathcal{X}} p_{\theta_1}(x) \ln \frac{p_{\theta_1}(x)}{p_{\theta_1+\delta}(x)} dx \right) \big|_{\delta=0} = \\ &= \left(- \int_{\mathcal{X}} p_{\theta_1}(x) \nabla_{\delta}^2 \ln p_{\theta_1+\delta}(x) dx \right) \big|_{\delta=0} = -\mathbb{E}_{\theta_1} \nabla_{\theta_1}^2 \ln p_{\theta_1}(x) = i(\theta_1) \end{aligned}$$

Тогда $\text{KL}(P_{\theta_1}, P_{\theta_2}) = \frac{1}{2}(\theta_1 - \theta_2)^\top i(\theta)(\theta_1 - \theta_2) + o(\|\theta_1 - \theta_2\|^2)$

II - 12 Натуральный градиент

Пример:

$$X_1, \dots, X_n \sim \mathcal{N}(a, \sigma^2), S = \sigma^2$$

Нужно найти ОМП градиентным спуском

$$\ell_X(\theta) = -\frac{n}{2} \ln(2\pi S) - \frac{1}{2S} \sum_{i=1}^n (X_i - a)^2$$

$$\frac{\partial \ell_X(\theta)}{\partial a} = \frac{1}{S} \sum_{i=1}^n (X_i - a) = \frac{1}{nS} (\bar{X} - a)$$

$$\frac{\partial \ell_X(\theta)}{\partial S} = -\frac{n}{2S} + \frac{1}{2S^2} \sum_{i=1}^n (X_i - a)^2 = \frac{n}{2S^2} \left(-S + \sum_{i=1}^n \frac{(X_i - a)^2}{n} \right)$$

Шаг градиентного спуска

$$a_{t+1} = a_t + \eta_1 \frac{\bar{X} - a_t}{S_t}$$

$$S_{t+1} = S_t + \eta_2 \frac{\sum_{i=1}^n \frac{(X_i - a_t)^2}{n} - S_t}{S_t^2}$$

Пусть $f: \mathbb{R}^d \rightarrow \mathbb{R}$, тогда $\nabla f = \left(\frac{\partial f}{\partial x_j} \right)_{j=1}^d$

Замечание

Градиент – направление наибольшего роста функции

Пусть $\mathcal{P} = \{P_\theta \mid \theta \in \Theta\}$ – доминируемое семейство распределений и $f(P_\theta)$ – некоторый функционал от распределения

Пример:

$$\mathcal{P} = \{\mathcal{N}(a, \sigma^2) \mid a \in \mathbb{R}, \sigma \in \mathbb{R}_+\}$$

$$1) \theta = (0, 1), \Delta\theta = (1, 0)$$

$$2) \theta = (0, 100^2), \Delta\theta = (1, 0)$$

Схожесть в пространстве параметров не всегда отражает схожесть в пространстве распределений

Хотим получить новое определение градиента, которое отражает близость в пространстве распределений

$$\nabla_N f(P_\theta) \sim \arg \max_{\Delta\theta: \text{KL}(P_\theta, P_{\theta+\Delta\theta}) \leq \varepsilon} f(P_{\theta+\Delta\theta}) - f(P_\theta)$$

$$\left\{ \begin{array}{l} f(P_{\theta+\Delta\theta}) - f(P_\theta) \rightarrow \max_{\Delta\theta} \\ \text{KL}(P_\theta, P_{\theta+\Delta\theta}) \leq \varepsilon \end{array} \right\}$$

$$L(\theta, \Delta\theta, \lambda) = f(P_{\theta+\Delta\theta}) - f(P_\theta) - \lambda(\text{KL}(P_\theta, P_{\theta+\Delta\theta}) - \varepsilon)$$

$$\frac{\partial L}{\partial \Delta\theta} = \nabla_{\Delta\theta} f(P_\theta) - \frac{\lambda}{2} (\nabla_{\Delta\theta} (\Delta\theta_i^\top(\theta) \Delta\theta)) = \nabla_{\Delta\theta} f(P_\theta) - \lambda i(\theta) \Delta\theta$$

$$\Delta\theta = \frac{1}{\lambda} i(\theta)^{-1} \nabla f(P_\theta)$$

Опр

$\nabla_N f(P_\theta) = i(\theta)^{-1} \nabla f(P_\theta)$ – натуральный градиент

В примере тогда имеем $i(\theta) = \begin{pmatrix} \frac{1}{\bar{S}} & 0 \\ 0 & \frac{1}{2\bar{S}^2} \end{pmatrix}$

Тогда $i(\theta)^{-1} = \begin{pmatrix} \bar{S} & 0 \\ 0 & 2\bar{S}^2 \end{pmatrix}$

Тогда $\nabla_N \ell_X(\theta) = \begin{pmatrix} n(\bar{X}-a) \\ n(\widehat{S}^2-\bar{S}) \end{pmatrix}$

Градиентный спуск записывается аналогично

Пример:

Логистическая регрессия

$\nabla \ell_X(\theta) = X^\top (Y - S(\theta)), S(\theta) = (\sigma(X_i^\top \theta))_{i=1}^n$

$I_X(\theta) = X^\top V(\theta)X, V(\theta) = \text{diag}((\sigma(X_i^\top \theta)(1 - \sigma(X_i^\top \theta)))_{i=1}^n)$

$\nabla_N \ell_X(\theta) = i(\theta)^{-1} \nabla \ell_X(\theta) = n(X^\top V(\theta)X)^{-1} X^\top (Y - S(\theta))$

$\theta_{t+1} = \theta_t - \eta \cdot \nabla_N \ell_X(\theta)$ – получился IRLS

II - 13 Свойства ОМП. Семинар

Теорема (о монотонном отношении правдоподобия)

$\forall \theta_0, \theta_1 \in \Theta$ в условиях выполненных L1, L2 имеем:

$$\theta_0 \neq \theta_1 : P_{\theta_0}(\mathcal{L}_X(\theta_0) > \mathcal{L}_X(\theta_1)) \xrightarrow{n \rightarrow \infty} 1$$



$$\mathcal{L}_X(\theta_0) > \mathcal{L}_X(\theta_1) \Leftrightarrow \frac{1}{n} \ln \frac{\mathcal{L}_X(\theta_0)}{\mathcal{L}_X(\theta_1)} > 0$$

$$\frac{1}{n} \ln \frac{\mathcal{L}_X(\theta_0)}{\mathcal{L}_X(\theta_1)} = \frac{1}{n} \sum_{i=1}^n \ln \frac{P_{\theta_0}(X_i)}{P_{\theta_1}(X_i)} \xrightarrow{\text{п.н.}} \mathbb{E}_{\theta_0} \ln \ln \frac{P_{\theta_0}(X_i)}{P_{\theta_1}(X_i)} = \text{KL}(P_{\theta_0}, P_{\theta_1}) > 0$$

Значит $P_{\theta_0}(\mathcal{L}_X(\theta_0) > \mathcal{L}_X(\theta_1)) \rightarrow P_{\theta_0}(\text{KL}(P_{\theta_0}, P_{\theta_1}) > 0) = 1$



Следствие:

Если Θ конечная, то ОМП существует и является состоятельной оценкой



$$\forall \theta_0 \neq \theta_1 P_{\theta_0}(\mathcal{L}_X(\theta_0) > \mathcal{L}_X(\theta_1)) \rightarrow 1$$

Возьмем пересечение конечного числа событий, вероятность каждого из которых $\rightarrow 1$, тогда и у всего пересечения вероятность $\rightarrow 1$

Тем самым с вероятностью $\rightarrow 1$ при больших n максимум достигается на θ_0

Теорема (о состоятельности ОМП)

В условиях выполненных L1-L5 имеем:

Уравнение правдоподобия $\frac{\partial \ell_X(\theta)}{\partial \theta} = 0$ имеет решение $\tilde{\theta}$ – состоятельная оценка



Выберем интервал $(\theta_0 - \varepsilon, \theta_0 + \varepsilon) \subseteq \Theta$ [L4]

Применим теорему о монотонном отношении правдоподобия к краям интервала

$$P_{\theta_0}(\mathcal{L}_X(\theta_0) > \mathcal{L}_X(\theta_0 - \varepsilon)) \rightarrow 1$$

$$P_{\theta_0}(\mathcal{L}_X(\theta_0) > \mathcal{L}_X(\theta_0 + \varepsilon)) \rightarrow 1$$

Тогда выполняется и для пересечения:

$$P_{\theta_0}(\mathcal{L}_X(\theta_0) > \mathcal{L}_X(\theta_0 - \varepsilon), \mathcal{L}_X(\theta_0) > \mathcal{L}_X(\theta_0 + \varepsilon)) \rightarrow 1 \text{ [L5]}$$

На интервале $(\theta_0 - \varepsilon, \theta_0 + \varepsilon)$ возьмем $\tilde{\theta}$ – ближайший к θ_0

Это верно $\forall \varepsilon \ P_{\theta_0}(|\tilde{\theta} - \theta_0| > \varepsilon) \rightarrow 0 \Rightarrow \tilde{\theta}$ – состоятельная оценка



Следствие:

Пусть $\forall n \ \forall x_1, \dots, x_n$ – уравнение правдоподобия имеет единственное решение $\tilde{\theta}$. Тогда $\tilde{\theta}$ – состоятельная оценка θ и $P_{\theta_0}(\tilde{\theta} = \text{ОМП}) \rightarrow 1$ [L1-L5]



Состоятельность следует из теоремы выше.

Вероятность того, что $\tilde{\theta}$ максимизирует $\mathcal{L}_X(\theta)$ стремится к 1 (что есть максимум в интервале), значит $P_{\theta}(\tilde{\theta} = \text{ОМП}) = 1$



Теорема (об асимптотической нормальности) [L1] - [L9]

1) Пусть $\hat{\theta}$ – последовательность решений уравнения правдоподобия, т.ч. $\hat{\theta}$ – состоятельная оценка (\exists по теореме о состоятельности оценки).

Тогда $\hat{\theta}$ – а.н.о θ с асимптотической дисперсией $\frac{1}{i(\theta)}$ (одномерный случай)

2) Пусть $\hat{\theta}$ – асимптотически нормальная оценка с непрерывной асимптотической дисперсией $\sigma^2(\theta)$, тогда $\sigma^2(\theta) \geq \frac{1}{i(\theta)} \forall \theta \in \Theta$



Пусть $\tilde{\theta}$ – состоятельная последовательность решений уравнения правдоподобия. Рассмотрим вклад $U_X(\tilde{\theta}) = \frac{\partial \ell_X(\theta)}{\partial \theta} \big|_{\theta=\tilde{\theta}}$

Разложим вклад по Тейлору с остаточным членом в форме Лагранжа

$$U_X(\tilde{\theta}) = U_X(\theta) + U'_X(\theta)(\tilde{\theta} - \theta) + \frac{1}{2}U''_X(\theta^*)(\tilde{\theta} - \theta)^2$$

θ^* лежит на отрезке $[\tilde{\theta}, \theta]$

$\tilde{\theta}$ – состоятельная оценка θ и $\tilde{\theta} \xrightarrow{P_\theta} \theta \Rightarrow \theta^* \xrightarrow{P_\theta} \theta$

$\tilde{\theta}$ – решение уравнения правдоподобия

$$U_X(\tilde{\theta}) = 0$$

$$\sqrt{n}(\tilde{\theta} - \theta) = \sqrt{n} \frac{-U_X(\theta) \frac{1}{n}}{\frac{1}{n}U'_X(\theta) + \frac{1}{2}U''_X(\theta^*)(\tilde{\theta} - \theta) \frac{1}{n}}$$

$$1) \quad \sqrt{n} \frac{1}{n} U_X(\theta) = \sqrt{n} \left(\frac{1}{n} \sum_{i=1}^n U_{X_i}(\theta) \right) - \mathbb{E}_\theta U_{X_1}(\theta) \xrightarrow{\text{ЦПТ}} \mathcal{N}(0, \mathbb{D} U_X(\theta))$$

$$2) \quad \frac{1}{n} U'_X(\theta) = \frac{1}{n} \sum_{i=1}^n U'_{X_i}(\theta) \xrightarrow{P_\theta} \mathbb{E}_\theta U'_{X_1}(\theta) = \mathbb{E}_\theta \frac{\partial^2 \ell_X(\theta)}{\partial \theta^2} = -i(\theta)$$

$$3) \quad \left| \frac{1}{n} U''_{X(\theta^*)} \right| \leq \frac{1}{n} \sum_{i=1}^n |U''_{X_i}(\theta^*)| = \frac{1}{n} \sum_{i=1}^n \left| \frac{\partial^3 \ln p_{\theta^*}(X_i)}{\partial \theta^3} \right| \leq [\text{L9}] \leq \\ \leq \frac{1}{n} \sum_{i=1}^n H(X_i) \xrightarrow{\text{п.н.}} \mathbb{E}_\theta H(X_1) < +\infty \quad [\text{L9}]$$

Условие, что $\theta^* \in (\theta - c, \theta + c)$ будет выполнено с вероятностью $\rightarrow 1$,
 $\tilde{\theta} \xrightarrow{P_\theta} \theta$

$$\left| \frac{1}{n} U''_{X(\theta^*)} \right| |\tilde{\theta} - \theta| \xrightarrow{P_\theta} 0$$

$$4) \text{ Числитель } \rightarrow \mathcal{N}(0, i(\theta))$$

$$\text{Знаменатель } \xrightarrow{P_\theta} -i(\theta)$$

По лемме Служцкого

$$\sqrt{n}(\tilde{\theta} - \theta) \xrightarrow{d_\theta} \mathcal{N}\left(0, \frac{1}{i(\theta)}\right)$$



Замечание

Если $\tilde{\theta}$ – единственное решение, то оно асимптотически нормальная оценка

Следствие:

ОМП – наилучшая оценка в условиях L1-L9 в асимптотическом подходе

Замечание

Если L1-L9 не выполнены, то могут быть и более хорошие оценки

Пример:

$$X_1, \dots, X_n \sim U(0, \theta)$$

$$\text{ОМП} = X_{(n)}$$

$$n(\theta - X_{(n)}) \xrightarrow{d_\theta} \text{Exp}(1)$$

$$\sqrt{n}(\hat{\theta} - \theta) \xrightarrow{d_\theta} \mathcal{N}(\dots)$$

II - 14 Информация Фишера. Семинар

II - 14.1 Многомерная информация Фишера

Опр

$$U_X(\theta) = \frac{\partial \ell_X(\theta)}{\partial \theta} - \text{вклад}$$

Опр

$$I_X(\theta) = \mathbb{D}_\theta U_X(\theta) - \text{информация Фишера}$$

$$I_X(\theta) = (I_{jk}(\theta))_{j,k=1}^{d,d}, \text{ где } I_{jk}(\theta) = \mathbb{E}_\theta \frac{\partial \ell_X(\theta)}{\partial \theta_j} \cdot \frac{\partial \ell_X(\theta)}{\partial \theta_k} = -\mathbb{E}_\theta \frac{\partial^2 \ell_X(\theta)}{\partial \theta_j \partial \theta_k}$$

Утв:

При справедливости L1-L9 ОМП $\hat{\theta}$ – асимптотически нормальная оценка с асимптотической матрицей ковариаций $I_{X_1}(\theta)^{-1}$

При этом если есть θ^* – асимптотически нормальная оценка с асимптотической матрицей ковариаций $\Sigma(\theta)$, такой что $\Sigma(\theta)$ непрерывна, То

$\Sigma(\theta) - I_{X_1}(\theta)^{-1}$ – неотрицательно определена

Задача

$$X_1, \dots, X_n \sim \mathcal{N}(a, \sigma^2)$$

$$\mathcal{L}_X(\theta) = \prod_{i=1}^n p_\theta(X_i)$$

$$\ell_X(\theta) = \sum_{i=1}^n \ln \left(\frac{1}{\sqrt{2\pi\sigma^2}} \exp \left(-\frac{(X_i - a)^2}{2\sigma^2} \right) \right)$$

$$\frac{\partial \ell_X(\theta)}{\partial a} = \frac{1}{2\sigma^2} \sum_{i=1}^n 2(X_i - a)$$

$$\frac{\partial^2 \ell_X(\theta)}{\partial a^2} = -\frac{n}{\sigma^2}$$

$$\frac{\partial \ell_X(\theta)}{\partial \sigma^2} = -\frac{\sum_{i=1}^n (X_i - a)^2}{\sigma^4} - \frac{n}{2\sigma^2}$$

$$\frac{\partial^2 \ell_X(\theta)}{\partial (\sigma^2)^2} = \frac{n}{2\sigma^4} + \frac{2 \sum_{i=1}^n (X_i - a)^2}{\sigma^6}$$

$$\frac{\partial^2 \ell_X(\theta)}{\partial \sigma^2 \partial a} = -\frac{2}{\sigma^4} \sum_{i=1}^n (a - X_i)$$

$$\tilde{\theta} = \begin{pmatrix} \bar{X} \\ S^2 \end{pmatrix} - \text{ОМП}$$

$$I_{X_1}(\theta) = \begin{pmatrix} \frac{1}{\sigma^2} & 0 \\ 0 & \frac{1}{2\sigma^4} \end{pmatrix}$$

$$I_{X_1}(\theta)^{-1} = \begin{pmatrix} \sigma^2 & 0 \\ 0 & 2\sigma^4 \end{pmatrix}$$

Задача

$X_1, \dots, X_n \sim \mathcal{N}(a, \sigma^2)$. Найти ОМП для $\frac{a}{\sigma}$ и ее асимптотическую дисперсию

Рассмотрим функцию $\tau(x, y) = \frac{x}{\sqrt{y}}$

$$\frac{\partial \tau}{\partial x} = \frac{1}{\sqrt{y}}, \quad \frac{\partial \tau}{\partial y} = -\frac{x}{2y^{\frac{3}{2}}}$$

II - 14.2 Информация Фишера для обобщенных линейных моделей

1) Логистическая регрессия

$$\mu_\theta(x) = \sigma(\theta^\top x)$$

$$I_X(\theta) = \left(-\mathbb{E}_\theta \frac{\partial^2 \ell_Y(\theta)}{\partial \theta_j \partial \theta_k} \right) = X^T V(\theta) X$$

2) Пуассоновская регрессия

$$X_1, \dots, X_n \in \mathbb{R}^d - \text{признаки}$$

$$Y_1, \dots, Y_n \in \mathbb{N}$$

$$\mu_\theta(x) = e^{\theta^\top x}, Y \sim \text{Pois}(\mu_\theta(X))$$

$$I_X(\theta) = X^\top \text{diag}(\mathbb{E}(\theta)) X$$

II - 15 Доказательства теорем

II - 15.1 Критерий χ^2

Теорема (критерий хи-квадрат)

Пусть $X = (X_1, \dots, X_n)$ – выборка из неизвестного распределения P и $H_0 : P = P_0$. Пусть также $\mathcal{X} = \bigsqcup_{j=1}^k B_j$ – разбиение выборочного пространства на непересекающиеся бины. Обозначим $m_j = \#\{X_i \in B_j\} = \sum_{i=1}^n \mathbb{I}\{X_i \in B_j\}$, а также $p_j^0 = P_0(X_i \in B_j)$.

Тогда $\chi(X) = \sum_{j=1}^k \frac{(\mu_j - np_j^0)^2}{np_j^0} \xrightarrow{d_0} \chi_{k-1}^2$



Пусть

$$Y_i = \begin{pmatrix} \mathbb{I}\{X_i \in B_1\} \\ \vdots \\ \mathbb{I}\{X_i \in B_k\} \end{pmatrix} \in \mathbb{R}^k$$

$$\mathbb{E}Y_i = \begin{pmatrix} p_1^0 \\ \vdots \\ p_k^0 \end{pmatrix} = p_0$$

$$\begin{aligned} \text{cov}(\mathbb{I}\{X_1 \in B_j\}, \mathbb{I}\{X_1 \in B_l\}) &= \mathbb{E}\mathbb{I}\{X_1 \in B_j\} \cdot \mathbb{I}\{X_1 \in B_l\} - \\ &\quad - \mathbb{E}\mathbb{I}\{X_1 \in B_j\} \cdot \mathbb{E}\mathbb{I}\{X_1 \in B_l\} = \\ &= p_j \delta_{jl} - p_j p_l \end{aligned}$$

δ_{jl} – символ Кронекера. Тогда получаем, что $\mathbb{D}Y_i = \text{diag}(p_0) - p_0 p_0^\top$

Теперь воспользуемся ЦПТ для Y .

$$\sqrt{n}(\bar{Y} - p_0) \xrightarrow{d_0} \mathcal{N}(0, \text{diag}(p_0) - p_0 p_0^\top)$$

Введем новую случайную величину, $\xi_n = \text{diag}\left(\frac{1}{\sqrt{p_0}}\right) \sqrt{n}(\bar{Y} - p_0)$. По теореме о наследовании сходимостей.

$$\xi_n \xrightarrow{d_0} \mathcal{N}\left(0, \text{diag}\left(\frac{1}{\sqrt{p_0}}\right) (\text{diag}(p_0) - p_0 p_0^\top) \text{diag}\left(\frac{1}{\sqrt{p_0}}\right)\right)$$

$$B = \text{diag}\left(\frac{1}{\sqrt{p_0}}\right) \text{diag}(p_0) \text{diag}\left(\frac{1}{\sqrt{p_0}}\right) - \\ - \left(\text{diag}\left(\frac{1}{\sqrt{p_0}}\right) p_0\right) \left(\text{diag}\left(\frac{1}{\sqrt{p_0}}\right) p_0\right)^\top = \\ = I - \sqrt{p_0}(\sqrt{p_0})^\top$$

Возьмем ортогональную матрицу $V = \begin{pmatrix} \sqrt{p_1^0} & \dots & \sqrt{p_k^0} \\ \vdots & \ddots & \vdots \\ \dots & \dots & \dots \end{pmatrix} \in \mathbb{R}^{k \times k}$

По теореме о наследовании сходимости

$$V\xi_n \xrightarrow{d_0} \mathcal{N}(0, V(I_k - \sqrt{p_0}\sqrt{p_0}^\top)V^\top)$$

$$A = VV^\top - V\sqrt{p_0}\sqrt{p_0}^\top V^\top = I_k - \begin{pmatrix} 1 \\ 0 \\ \vdots \\ 0 \end{pmatrix} \cdot \begin{pmatrix} 1 \\ 0 \\ \vdots \\ 0 \end{pmatrix}^\top = \begin{pmatrix} 0 & 0 & \dots & 0 \\ 0 & 1 & \dots & 0 \\ 0 & 0 & \dots & 1 \end{pmatrix} = I'_k$$

По теореме о наследовании сходимости $\|V\xi_n\|^2 \sim \|\mathcal{N}(0, I'_k)\|^2 = \chi_{k-1}^2$

$$\|V\xi_n\|^2 = \|\xi_n\|^2 = \sum_{j=1}^k \left(\sqrt{n} \frac{1}{\sqrt{p_j^0}} (\bar{Y} - p_j^0) \right)^2 = \sum_{j=1}^k n \left(\frac{1}{p_j^0} \left(\frac{\mu_j}{n} - p_j^0 \right)^2 \right) = \\ = \sum_{j=1}^k \frac{(\mu_j - np_j^0)^2}{np_j^0} = \chi(X)$$



II - 15.2 Лемма Неймана-Пирсона

Теорема (Лемма Неймана-Пирсона)

Пусть X – выборка из неизвестного распределения $P \in \mathcal{P} = \{P_\theta \mid \theta \in \Theta\}$ – доминируемое семейство

Пусть также $\mathcal{L}_X(\theta)$ – функция правдоподобия, а $\Lambda_{\theta_0, \theta_1} = \frac{\mathcal{L}_X(\theta_1)}{\mathcal{L}_X(\theta_0)}$, а исследуемые гипотезы $H_0 : \theta = \theta_0$ vs $H_1 : \theta = \theta_1$.

Тогда если $\exists c_\alpha : P_{\theta_0}(\Lambda_{\theta_0, \theta_1}(X) > c_\alpha) = \alpha$, то критерий

$S = \{ \Lambda_{\theta_0, \theta_1}(x) > c_\alpha \}$ – РНМК среди критериев уровня значимости α



S – критерий уровня значимости α , так как $P(I_S) = P_{\theta_0}(\Lambda_{\theta_0, \theta_1}(X) > c_\alpha) = \alpha$.

Покажем теперь, что он наиболее мощный. $\forall R$ – критерий уровня значимости α выполнено

$$\begin{aligned} P_{\theta_0}(X \in R) &\leq \alpha = P_{\theta_0}(X \in S) \\ (\mathcal{L}_X(\theta_1) - c_\alpha \mathcal{L}_X(\theta_0)) \mathbb{I}\{X \in R\} &\leq \\ &\leq (\mathcal{L}_X(\theta_1) - c_\alpha \mathcal{L}_X(\theta_0)) \mathbb{I}\{X \in R\} \mathbb{I}\left\{ \frac{\mathcal{L}_X(\theta_1)}{\mathcal{L}_X(\theta_0)} \geq c_\alpha \right\} \leq \\ &\leq (\mathcal{L}_X(\theta_0) - c_\alpha \mathcal{L}_X(\theta_1)) \mathbb{I}\{X \in S\} \end{aligned}$$

Тогда

$$\begin{aligned} \int_{\mathcal{X}} \left(\prod_{i=1}^n p_{\theta_1}(x_i) - c_\alpha \prod_{i=1}^n p_{\theta_0}(x_i) \right) \mathbb{I}\{x \in R\} dx_1 \dots dx_n = \\ = P_{\theta_1}(X \in R) - c_\alpha P_{\theta_0}(X \in R) \leq P_{\theta_1}(X \in S) - c_\alpha P_{\theta_0}(X \in S) \end{aligned}$$

Тогда разность мощностей

$$\begin{aligned} \mathfrak{P}_S(\theta_1) - \mathfrak{P}_R(\theta_1) &= P_{\theta_1}(X \in S) - P_{\theta_1}(X \in R) \geq \\ &\geq c_\alpha (P_{\theta_0}(X \in S) - P_{\theta_0}(X \in R)) \geq 0 \end{aligned}$$

Тогда $\forall R$ уровня значимости α $\mathfrak{P}_S(\theta) \geq \mathfrak{P}_R(\theta_1)$, значит S – наиболее мощный критерий уровня значимости α



УТВ

В таком случае мощность будет не меньше ошибки первого рода.

$$P(I_S) < \mathfrak{P}_S(\theta_1)$$



$$S = \{ \Lambda_{\theta_0, \theta_1}(x) > c_\alpha \}$$

1) $c_\alpha \geq 1$.

$$\text{Тогда } \forall X \in S : \mathcal{L}_X(\theta_1) \geq \mathcal{L}_X(\theta_0)$$

$$\int_S \prod_{i=1}^n p_{\theta_1}(x_i) dx_1 \dots dx_n = \underbrace{P_{\theta_1}(X \in S)}_{\mathfrak{P}_S(\theta_1)} \geq \underbrace{P_{\theta_0}(X \in S)}_{P(I_S)}$$

2) $c_\alpha < 1$

Тогда $\forall X \in S : \mathcal{L}_X(\theta_1) < \mathcal{L}_X(\theta_0)$

$$\int_{\bar{S}} \prod_{i=1}^n p_{\theta_1}(x_i) dx_1 \dots dx_n = 1 - P_{\theta_1}(X \in S) \leq 1 - P_{\theta_0}(X \in S)$$

Значит, $\mathfrak{P}_S(\theta_1) = P_{\theta_1}(X \in S) > P_{\theta_0}(X \in S) = P(I_S)$

