

# paper review ds

Demoren

September 2025

В данном обзоре я разберу 3 статьи, которые стали важными этапы развития RL и во многом повлияли на обучение и работу современных агентских LLM.

## 1 Proximal policy optimization.

### 1.1 Обоснование выбора.

В данной статье описывается один из основных алгоритмов RL. PPO является одним из самых популярных одним из самых популярных алгоритмов для обучения с подкреплением. Данный алгоритм достаточно прост в реализации, но при этом остается достаточно эффективным и стабильным.

### 1.2 Формулировка задачи

Основной целью любого RL алгоритма является оптимизация политики для получения максимального reward в течении времени в среднем по всем траекториям:

$$\mathbb{E}_{\tau \sim \pi_{\theta}} \left[ \sum_{t=0}^T \gamma^t r_t \right] \rightarrow \max_{\theta}$$

где  $\tau \sim \pi_{\theta}$  – траектория полученная при использовании политики  $\pi_{\theta}$ ,  $\gamma \in [0, 1]$  – коэффициент дисконтирования.

### 1.3 Основные формулы

Основной идеей является введение новой суррогатной функции, которая устраняет недостатки предыдущих алгоритмов (см. 1.4). Обозначим отношение вероятностей через  $r_t(\theta) = \frac{\pi_{\theta}(a_t|s_t)}{\pi_{\theta_{old}}(a_t|s_t)}$  Новая суррогатная функция имеет вид:

$$L^{CLIP}(\theta) = \hat{\mathbb{E}}_t \left[ \min \left( r_t(\theta) \hat{A}_t, \text{clip}(r_t(\theta), 1 - \varepsilon, 1 + \varepsilon) \hat{A}_t \right) \right]$$

где  $\hat{\mathbb{E}}$  – эмпирическое среднее по батчу,  $\hat{A}_t = r_t + \gamma V(s_{t+1}) - V(s_t)$ ,  $\varepsilon$  – гиперпараметр.

### 1.4 Описание существующих проблем

У классические RL алгоритмов вроде REINFORCE страдают от нестабильности обучения ввиду высокой дисперсии. Вместо них предлагается использовать TRPO, схожий с


PPO алгоритм, с тем отличием, что там вместо клиппинга используется KL дивергенция между политиками, что также не позволяет новой политике сильно отличаться от старой. Но алгоритм TRPO достаточно сложно оптимизировать, так как аппроксимация KL дивергенция требует вычисления сопряженных градиентов для аппроксимации обратного гессиана.

PPO сохраняет преимущество TRPO в виде ограничения на слишком большое обновление политики, но вместо KL дивергенции использует конструкцию с клиппингом, что позволяет использовать оптимизаторы первого рода вроде ADAM или SGD.

## 2 Direct Preference Optimization: Your Language Model is Secretly a Reward Model

### 2.1 Обоснование выбора.

DPO предлагает радикальную альтернативу подходу, основанному на PPO и reward-моделях, полностью исключая этап обучения с подкреплением. В ней предложен новый легкий, стабильный и эффективный метод параметризации reward модели для RLHF.



### 2.2 Формулировка задачи

Основной целью является получение решения следующей задачи оптимизации:

$$\max_{\pi_{\theta}} \mathbb{E}_{x \sim \mathcal{D}, y \sim \pi_{\theta}(y|x)} [r_{\phi}(x, y)] - \beta \mathcal{D}_{KL}(\pi_{\theta}(y|x) || \pi_{ref}(y|x))$$

где  $r_{\phi}$  – reward функция,  $\mathcal{D}$  – датасет.

### 2.3 Основные формулы.

Если бы мы знали правильную reward функцию  $r$ , то решение задачи 2.2 имело бы вид:

$$\pi_r(y|x) = \frac{1}{Z(x)} \pi_{ref}(y|x) \exp \left( \frac{1}{\beta} r(x, y) \right)$$

где  $Z(x) = \sum_y \pi_{ref}(y|x) \exp \left( \frac{1}{\beta} r(x, y) \right)$  – нормировочная константа. Ее вычисление достаточно затратно, эту проблему также пытается решить DPO.

Взяв логарифм с обеих сторон у 2.3, можно получить:

$$r(x, y) = \beta \log \frac{\pi_r(y|x)}{\pi_{ref}(y|x)} + \beta \log Z(x)$$

Далее воспользуемся параметризацией из модели Брэдли-Терри:

$$p^\cdot(y_1 \succ y_2) = \frac{\exp(r^\cdot(x, y_1))}{\exp(r^\cdot(x, y_1)) + \exp(r^\cdot(x, y_2))} = \sigma(r^\cdot(x, y_1) - r^\cdot(x, y_2))$$

Получим такую формулировку уравнения 2.3:

$$p^\cdot(y_1 \succ y_2) = \frac{1}{1 + \exp\left(\beta \log \frac{\pi^\cdot(y_2|x)}{\pi_{ref}(y_2|x)} - \beta \log \frac{\pi^\cdot(y_1|x)}{\pi_{ref}(y_1|x)}\right)}$$

где  $\pi^\cdot$  – оптимальная относительно RLHF политика при условии параметризации Брэдли-Терри. То есть мы связали оценки людей с обновлением политики, причем сложно вычисляемый член  $Z(\cdot)$  сократился.

Осталось превратить 2.3 в суррогатную функцию для обучения политики:

$$\mathcal{L}_{DPO}(\pi_\theta, \pi_{ref}) = -\mathbb{E}_{x, y_w, y_l \sim \mathcal{D}} \left[ \log \sigma \left( \beta \log \frac{\pi_\theta(y_w|x)}{\pi_{ref}(y_w|x)} - \beta \log \frac{\pi_\theta(y_l|x)}{\pi_{ref}(y_l|x)} \right) \right]$$

## 2.4 Описание существующих проблем

DPO заменяет сложный RL-цикл (с оценкой reward-модели, генерацией траекторий и PPO) на прямую оптимизацию параметров языковой модели с помощью стабильной логистической функции потерь, основанной на человеческих предпочтениях